

修士研究 進捗報告

小さな AI を 3 体、話し合わせて“進化”させる

——「議論する AI チーム」は、素朴なやり方に勝てるのか？

Evolutionary Optimization of LoRA Agent Populations
with Team-Level Fitness in Multi-Agent Debate

新潟大学 自然科学研究科 電気情報工学専攻 情報社会デザイン科学コース

舩田 岳 (学籍番号 F25C142E)

2026 年 7 月 9 日

この研究を一言でいうと

「1体の賢い AI」より「3体で話し合う AI」は強いのか？

やったこと

- 同じ小型 AI に 3 つの“性格”を持たせる
- 互いの答えを見せ合って議論させる
- 良い協調をする個体を“進化”で選ぶ

調べたこと

- 議論チームは、単純な多数決に勝てるか
- どんな問題なら議論が効く／効かないか
- うまい／うまくいかない原因はどこにあるか

今日の見どころ

- 本物の会話ログで AI の議論を実演
- 成功する例と、崩れる例の両方
- 正直な結果と、その理由の分析

キーワードは「**多様性**」と「**協調**」。ただし、いいことばかりではありませんでした。

01

背景と問い

なぜ「小さな AI を話し合わせる」のか。先行研究は何と言っているか。

背景①

モデルは「大きくすれば勝ち」なのか？

これまでの AI は、大きくするほど賢くなってきました。

でも大きなモデルは、動かすのにお金も電力もかかる。際限なく大きくする道には限界があります。

そこで別の方向として、**小さなモデルを何体か集めて協力させる**という考え方が注目されています。

小さいモデルなら、手元の安いパソコンでも複数同時に動かせる。“数の力”で単体の限界を補えないか、というわけです。

これまで

 1 体の巨大モデル



この研究

 小さな AI×3 体
で話し合う

背景②

「AI 同士で議論させると賢くなる」という報告

2023 年の有名な研究では、複数の AI に同じ問題を解かせ、互いの答えを見せ合って考え直させると、正答率が上がると報告されました。

たとえば、ある試験で 63.9% → 71.1% へ。「一人で悩むより、視点の違う相手と話した方が良い」——人間にも通じる直感です。

先行研究が言っていること(かみくだくと)

「一人の反省だと同じ考えにこだわりがち。違う視点の相手とぶつけると、“考えの行き詰まり”から抜け出せる」

——ところが「そんなに良くない」という反論も強い

計算量をそろえると勝てない

議論は何度も AI を呼ぶので手間がかかる。同じ手間を“ただ何回も解いて多数決”に使うと、そちらの方が強い、という指摘。

相手に流されて間違える

自信のある正解でも、多数派の空気に合わせて誤答に書き換えてしまう（“同調”による誤りの伝染）。

似た者同士だと意味が薄い

同じモデルのコピー同士で議論しても新しい視点が出ず、非効率で不安定になりやすい。

→ とくに **小さいモデルでは、素朴な議論はうまくいかない可能性が高い**。ここが出発点。

既存研究は「エージェントを固定」して議論のやり方だけ工夫してきた

これまでの改善は、ラウンド数や集約方法など“議論の進め方”をいじるものが中心でした。

でも、議論の良し悪しは**参加するメンバー自身の質と多様性**に強く左右されるはず。だったら——

本研究の問い

メンバー（AI）自身を、“チームへの貢献度”を手がかりに世代交代で鍛えられないか？

02

提案手法

3つの性格をどう作り、どう議論させ、どう“進化”させるか。


手法①

全体像：1 回の議論と、世代をまたぐ進化

① 1 回の議論 (推論のとき)



② 世代をまたぐ進化 (学習の外側で繰り返す)



この②を何世代も回して、「一緒に組んだときに強いメンバー」を育てる

3つの性格 —— わざと“違う考え方”をさせる

批判(けんしょう)

反証・例外・境界を疑う

「本当に？ 反例はないか」と粗を探す役

実務(じつむ)

実現性とコストで判断

「結局どれが使えるか」と地に足をつける
役

探索(たんさく)

仮説と比喻で発想を広げる

「別の見方はないか」と選択肢を増やす
役

実際には、これらは短い日本語の指示文で与えます(付録に原文)。大事なのは“**同じ問題を、あえて違う切り口で見る3体**”を用意したこと。

手法③

貢献度の測り方:「その人が抜けたら、どれだけ困る？」

進化で“良い個体”を選ぶには、個人の成績ではなく**チームへの貢献**を測りたい。

そこで、あらゆる組み合わせでチームを試し、「その1体が居るときと居ないときの差」を平均します。

これは協力ゲーム理論の**シャープレイ値**という考え方。3体なら全7通りを実測でき、近似なしで公平に貢献度を配れます。

実際に起きたこと

ある個体は、**単体の成績は3体で最低**。

でも**チームに入れると成績が最も伸びた**。

→ 個人の点数だけ見ていたら捨てていた個体を、**貢献度は正しく拾い上げた**。

“優秀な個人の寄せ集め＝最強のチーム”とは限らない——アンサンブル学習の古典的な教訓とも一致します。

手法④

進化のしくみ: 重みを“遺伝子”とみなす

各 AI の“性格”は、土台モデルに足す小さな重み (LoRA) で表せます。この重みを遺伝子とみなし、**良い 2 体を掛け合わせ (交叉)、少しゆらす (突然変異)**。

交叉

貢献度の高い 2 体の重みを混ぜ、両方の“良さ”を引き継いだ子を作る

突然変異

重みをランダムに少しだけ変え、新しい可能性を試す

選択

チーム貢献度 (+ 多様性) の高い個体を次の世代に残す

多様性は成績に足し算せず、“**似た者同士は割り引く**”という形で保ちます (理論的に妥当な入れ方)。

03

実際の会話を見る

ここからは本物のログ。AI たちが議論して、正解にたどり着く(時に、崩れる)。

3 体が同じ問題を解き、答えを見せ合って考え直す

① 各自が解く

3 体が別々に問題を解き、それぞれ答えを出す

② 見せ合う

互いの答えと理由を読み、もう一度考え直す

③ まとめる

最終的な答えを多数決(重み付き投票)で決める

これから見せるのは、**すべて実験で実際に記録された会話**です(英語のやりとりを日本語に要約、原文の一部も併記)。
最初は“うまくいく例”から。数学の問題です。

まず問題を確認する

問題(数学)

正解:両方入る

「 $1/4$ と $1/13$ は“カントール集合”に入る？」

カントール集合 = ざっくり言うと「3進数で書いたときに“1”が出てこない数」の集まり。

批判

考え中…

実務

考え中…

探索

考え中…

① 各自が解く —— この時点では“不正解”が多数派

批判

1/13 は 3 進数で 1 が出る…と判断

J ×

1/4 は入る。でも 1/13 は 3 進数にすると“1”が出るはず → 入らない

“...contains a 1, so 1/13 does not belong.”

実務

展開して級数で検算 → 入る

H ○

1/4 は入る。1/13 も 0.00202...(3 進) と展開でき、足し合わせると確かに 1/13。だから入る

“= 2/26 = 1/13 ... only 0s and 2s → belongs.”

探索

批判と同じく“1 が出る”と判断

J ×

1/13 の 3 進展開に“1”が見える → 入らない、と判断

“...contains a 1 ... answers are [1, 0].”

いま多数決すると… 不正解の「J」が 2 票。正解は“実務”1 体だけに埋もれている

② 見せ合う —— 検算を見た 2 体が“訂正”した

批判

実務の検算を自分でも確かめた → 訂正

H ○

$2/27 + 2/729 + \dots$ を自分で計算したら確かに $1/13$ 。“1” は出ない。答えを H に変える

探索

批判の展開ミスに気づいた → 訂正

H ○

さっきの 3 進展開は誤り。正しくは $0.00202\dots$ で“1” を含まない。H に変える

実務

そのまま (正解を主張し続ける)

H ○

展開と検算は合っている。両方コントロール集合に入る = H

正解の「H」が多数派に逆転 —— 少数派だった正解が、検算を通じてチームを動かした

この例が示すこと

多数決だけなら負けていた問題を、議論がひっくり返して正解にした。

なぜうまくいったのか

数学は「答えを確かめられる」領域だから。

相手の主張が正しいかを自分で検算できるので、議論が“なんとなくの同調”ではなく“根拠にもとづく訂正”になる。

逆に言えば、確かめにくい問題では、この良さは出にくい——次はその例。

次は“崩れる”例 —— 常識的な問題

問題(情報・常識)

正解:受信側

「送信側で暗号化されたメッセージは、どこで復号(元に戻す)される？」

批判

受信者が中身を読む必要 → 受信側

受信側 ○

暗号化は送信側。中身を読むのは受け取る側だから、復号は受信側

探索

宛先＝受信側(F か H で少し迷う)

受信側 ○

宛先で使える必要がある → 受信側。ただ“端末側”とも言えるか…

実務

端末＝クライアント側では？

端末側 ×

実際に復号するのは受け手の端末。クライアント側だと思う

① 各自が解く:正解「受信側」が2票 —— ここまでは正しい

② 見せ合う —— “もっともらしい深読み”に流された

批判

よく考えると端末側かも… → 転向

端末側 ×

実際に復号するのは端末＝クライアント側では、と考え直す。答えを変える

探索

アプリの例を思いつき → 転向

端末側 ×

Signal や WhatsApp はスマホ側で復号する。だから“端末側”が精密だ

“...decrypt on the user's phone ... client site is more precise.”

実務

受信側でよい(正解を維持)

受信側 ○

宛先＝受信側で問題ない

不正解の「端末側」が 2 票に —— 正しかった多数派が、深読みで崩れた

2つのデモが示すこと

成功 (数学)

- 答えを確かめられる
- 検算で“根拠ある訂正”
- 少数派の正解が勝った

失敗 (常識)

- 答えを確かめにくい
- 深読みで“同調”が起きる
- 正しい多数派が崩れた

同じ“議論”でも、結果は問題の性質で正反対になる。

この「領域による効き方の違い」こそ、実験でも一番はっきり出た発見でした。

04

実験と結果

何を、どんな環境で測ったか。そして、正直な結果。

何を・どこで・どう測ったか

使った AI

- Qwen3-4B（40 億パラメータ級の小型・公開モデル）
- 土台は 1 体、性格ごとに小さな追加重み（LoRA）

計算環境

- クラウド上の GPU で学習・評価を実施
- 途中で止まっても再開できる設計

3 種類のテスト

- 一般知識・推論（MMLU-Pro）
- 数学（MATH-500）
- 大学院レベルの科学（SuperGPQA）


比べた相手

- ベース単体／多数決 9 回（SC@9）
- 素の議論／LoRA チーム／進化後チーム

公平さのため、同じ問題で条件どうしを“対戦”させ、統計検定（多重比較の補正つき）で判定。乱数の種を変えても結果が変わらないかも確認しました。

発見①

議論が効く問題・効かない問題がある(領域依存)



同じ「素の議論」でも、**問題の種類で結果が逆転**しました。

数学や科学では議論すると上がる。でも一般知識では、むしろ下がってしまう。


鍵は「**答えを確かめられるか**」。確かめられる問題では、議論が正しい方向に働く(さっきの数学デモと同じ)。

この“反転”は、先行研究の食い違い(議論は効く／効かない)も説明できます。


発見②

“性格”を教えると賢さが削れる —— そして治せる

① 思考が短くなり



② 数学が解けなくなる




性格をむりに教え込むと、**考える途中の説明が半分に縮み**、その分だけ数学が解けなくなっていました。

原因は「短い答え方」を覚えすぎたこと。

対策は**元のモデル自身の“長い解答”を混ぜて学び直す**こと。これで賢さを取り戻せました。

最終結果 ①

処方の効果：壊れたチームは“元どおり”まで回復した




旧チーム (オレンジ) はベースより下がっていた。

処方後の新チーム (青) は3種目すべてで持ち直し、**ベース単体と互角**に。

数学では**多数決9回 (SC@9)**に肩を並べた。

最終結果 ②

正直な結論：治せた。でも“多数決 9 回”には届かなかった



要点

○ 処方で +3.2 点の改善

○ ベースと互角まで回復

× 多数決 9 回には - 3.0 点

= “工夫を尽くしても素朴な強敵に勝てなかった” という結果

これは“ダメだった”ではなく、「条件をほとんど公平にすると議論の優位は消える」という批判を、最も丁寧に確かめた結果。

05

考察・結論・今後


なぜこうなったのか。何が言えて、次に何をするか。

考察①

なぜ勝てないのか？でも、どこに価値があるのか？

多数決9回 (SC@9)


同じモデルが9回バラバラに解いて多数決



独立な9票 (多様だが同じ視点)

議論チーム (本研究)

3つの性格 × 2ラウンド、途中で答えを見せ合う



実質3つの視点 (少数だが多様)

多数決 9 回は、**独立した 9 票**の“数の力”が強い。

チームは実質 3 つの視点しかなく、議論でその差を埋めきれなかった。

ただし**数学では互角**。確かめられる問題では、少ない視点でも議論が補える。

要するに——“数で押す”のが有利な問題と、“話し合い”が活きる問題は別。使い分けが本質。

2つの“気づき”——進化の正体と、評価の落とし穴

進化は「選抜」ではなく「修復」だった

世代を回すと重みの“向き”だけが回転し、性格を教えたときの傷が打ち消されていた。つまり進化＝壊れた能力の回復。ただし同じ回復は、学び直し(リプレイ)の方が安く確実にできた。

同じ設定でも“測る環境”で点数が動く

評価プログラムを入れ替えただけで、同じ問題・同じ設定なのに6点ほどズレる現象を発見。しかもベース側だけ過小評価されやすい。→ 比較は必ず同じ環境で。ここは方法論としての教訓。

この研究で分かったこと

1

チームレベルの貢献度で進化させる枠組みを作り、実際に動かした

3 体なら貢献度を近似なしで公平に測れる。仕組みとして初めて形にした。

2

議論の効き方は「領域」で決まる

確かめられる問題では効き、そうでない問題では逆効果。統一的に説明できた。

3

失敗の原因を分解し、処方で“治せる”ことを示した

能力の毀損を特定し、学び直しでベース水準まで回復させた (+3.2 点)。

4

それでも“多数決 9 回”には勝てない、を厳密に確認 (正直な負け)

条件を公平にし、環境の罠も統制した上での結論。数学だけは互角。

次にやること

▶ “いいところ取り”を試す

各メンバーが数回ずつ解いてから議論する(数の力+話し合いの合わせ技)。今回の結果が指す最有力の次の一手。

▶ 進化のやり方を鍛え直す

選抜のノイズを抑える改良版で、進化が“修復”を超えて“発見”になるかを検証する。

▶ 違う性格・違うモデルを混ぜる

似た者同士ではなく、本当に異質なメンバーを組ませて多様性を最大化する。

まとめ

小さな AI を 3 体、話し合わせて進化させた。

議論には“効く問題”と“効かない問題”があり、

失敗は診断でき、処方で治せた。

——ただし、素朴な強敵に勝つのはこれからの宿題。

ご清聴ありがとうございました。

06

付録

数値の詳細・用語・再現性

最終結果の数値表(正答率 %・測定環境を統一)

条件	一般知識	数学	科学	備考
ベース単体	72.7	81.8	43.1	1 体で 1 回
多数決 9 回 (SC@9)	74.0	87.3	48.6	最強の比較相手
旧チーム (処方前)	68.5	79.3	42.0	ベース以下に低下
新チーム (処方後)	71.6	86.7	43.1	ベースと互角に回復

- 数学 (MATH-500) では新チームが多数決 9 回と統計的に互角 (差 - 0.7 点 , 有意差なし) 。
- 総合 (6,000 問) では新チームが多数決 9 回に - 3.0 点 (有意) 。ベース単体とは互角 (+0.3 点) 。
- 多数決 9 回とベース／新チームは 6 シード、旧チームは 3 シードで測定。

3つの性格に与えた実際の指示文

批判

「あなたは厳密な検証を重視する批判的思考家。反証・例外・境界条件に敏感。」

実務

「あなたは応用志向の実務家。意思決定に役立つ実装可能性とコストを重視。」

探索

「あなたは創発を促す発想家。仮説生成と多角的比喩で発想を広げる。」

たった1文ずつ。これだけで、デモで見たような異なる解き方が生まれます。

用語ニニ辞典

LoRA

土台モデルに足す小さな“追加重み”。少ない容量で性格や技能を足せる。

SC@9 / 多数決 9 回

同じ AI に 9 回バラバラに解かせ、多数決を取る素朴で強い方法。

Shapley 値 (貢献度)

「その人が抜けたらどれだけ困るか」を全組み合わせで公平に測った値。

MMLU-Pro / MATH-500 /
SuperGPQA

順に、一般知識・推論／数学／大学院級科学の標準テスト。

進化 (交叉・突然変異)

良い個体の重みを掛け合わせ・少し変えて次世代を作る最適化。