

令和〇年度 修士論文

マルチエージェント議論における  
チームレベル適応度を用いた  
LoRA エージェント集団の進化的最適化

Evolutionary Optimization of LoRA Agent Populations  
with Team-Level Fitness in Multi-Agent Debate

2026 年 9 月 30 日

指導教員 余俊 助教

新潟大学 自然科学研究科  
電気情報工学専攻 情報社会デザイン科学コース

学生番号 F25C142E

舩田 岳

Gaku Masuda



# 概要

大規模言語モデル (LLM) の複数体を議論させるマルチエージェント推論は、単一モデルの限界を超える手段として注目されるが、小型モデルでは「計算量を揃えた多数決 (Self-Consistency) に勝てない」という強い批判がある。本研究は、4B 級モデル (Qwen3-4B-Instruct-2507) に LoRA で異なるペルソナを焼き込んだ 3 体のエージェント集団を構成し、(1) 議論によるチーム推論が生成回数を揃えた Self-Consistency@9 (SC@9) を上回れるか、(2) チームレベル適応度 (厳密 Shapley 値  $\times$  fitness sharing) による重み空間の進化的最適化が寄与するかを、3 ベンチマーク (MMLU-Pro  $\cdot$  MATH-500  $\cdot$  SuperGPQA)  $\times$  3 シードの対応あり検定 (問題 ID クラスタリングを考慮した置換検定  $\cdot$  ブートストラップ + Holm 補正) で検証した。

実験 1 (主実験) の結果、議論の効果はベンチマーク依存に反転することが判明した。素の議論は数学 (+4.2pt) と高難度科学 (+3.1pt) で有意に有効だが MMLU-Pro では有意に有害 (-4.1pt) であり、重みペルソナチームは逆に MMLU-Pro のみで有効 (対ベース +4.5pt) だった。この反転は「多様性の利得」と「ペルソナ注入による能力毀損」の 2 軸トレードオフとして整理できる (ただし反転を問題の検証可能性に帰する解釈はベンチマーク内のカテゴリ別分析では支持されず、仮説にとどまる)。診断分析により、(i) ペルソナ SFT が思考連鎖を半減させ長い導出能力を選択的に破壊すること、(ii) 3 体の誰かが正解している問題の最大 13% 分を多数決集約が取りこぼすこと、(iii) 進化は適応度測定ノイズ (100 問で  $\pm 4.9$ pt) 下の勝者の呪いにより選抜として機能しなかったうえ、進化前後の  $\Delta W$  が cosine 類似度 0.9997 以上とほぼ同一——すなわち進化演算子が重み空間をほとんど動かしていなかったことを明らかにした。

実験 2 では診断に基づく処方——ベースモデル自己生成の検証済み長 CoT リプレイ混合 (38%) による再学習、自己誤り特定時のみ回答変更を許す条件付き議論、発言匿名化、logprob 重み付き投票——を、事前定義した合格基準を持つ実測ゲート方式で検証した。この過程で評価コンテナイメージ間の系統差 (同一問題  $\cdot$  同一設定で +6pt 級、ベースモデルの素の生成に選択的に作用) を検出したため、主要 4 条件を同一環境で全面再測定して統制した。最終評価において、処方はペルソナ SFT が生んだ能力毀損をベース単体との同等性 (等価マージン  $\pm 2$ pt) が成立する水準まで回復させ (対旧チーム +2.7pt,  $p = 0.0003$ ; MATH-500 では対ベース +3.4pt 有意優位)、一方で SC@9 には -3.5pt ( $p < 10^{-4}$ ) と有意に及ばなかった。

本研究の貢献は、(a) 小型 LLM 議論チームの成否を 2 軸トレードオフと損失分解で説明する診断枠組み、(b) 進化ループの機能不全（探索・多様性圧・選抜の三重の不全）の実測による特定と選抜ノイズの定量化、(c) 能力毀損を回復させる処方の実証と、それを尽くしてもなお生成回数を揃えた多数サンプリングに及ばないという統制された負の結果、(d) 評価環境の系統差がベースライン側を選択的に過小評価しチーム手法を見かけ上優位にするバイアスの発見、である。数学（MATH-500）では議論チームがベース単体を有意に上回り続けており、マルチエージェント議論の価値が残る条件を実測に基づいて画定した。



# 目次

|                             |           |
|-----------------------------|-----------|
| <b>第1章 序論</b>               | <b>9</b>  |
| 1.1 研究背景                    | 9         |
| 1.1.1 単一モデルの拡大から小型モデル集団の協調へ | 9         |
| 1.1.2 マルチエージェント議論の登場とその限界   | 10        |
| 1.2 研究課題                    | 10        |
| 1.3 提案手法の要点と本研究の貢献          | 11        |
| 1.4 本論文の構成                  | 13        |
| <b>第2章 関連研究</b>             | <b>14</b> |
| 2.1 マルチエージェント議論と集約          | 14        |
| 2.1.1 議論の原典と批判              | 14        |
| 2.1.2 同調と多様性                | 15        |
| 2.1.3 回答の集約                 | 16        |
| 2.2 ペルソナと役割                 | 16        |
| 2.2.1 ペルソナ付与の効果と限界          | 16        |
| 2.2.2 人間のチーム役割理論            | 17        |
| 2.2.3 役割の割り当てと選抜            | 18        |
| 2.3 議論と自己生成データからの学習         | 18        |
| 2.4 進化的モデル最適化               | 19        |
| 2.4.1 重み空間の集団最適化            | 19        |
| 2.4.2 重み合成の前提条件             | 20        |
| 2.5 チームへの貢献の定量化             | 22        |
| 2.6 評価の信頼性                  | 23        |
| 2.7 本研究の位置づけ                | 24        |
| <b>第3章 提案手法</b>             | <b>26</b> |
| 3.1 問題定式化                   | 26        |

|              |                                               |           |
|--------------|-----------------------------------------------|-----------|
| 3.1.1        | ベースモデルと LoRA 個体 . . . . .                     | 26        |
| 3.1.2        | 役割・エージェント・チーム . . . . .                       | 27        |
| 3.1.3        | 議論プロトコルと特性関数 . . . . .                        | 27        |
| 3.2          | 議論プロトコル . . . . .                             | 27        |
| 3.3          | 適応度関数 . . . . .                               | 29        |
| 3.3.1        | 特性関数と厳密 Shapley 値 . . . . .                   | 29        |
| 3.3.2        | Fitness sharing と行動距離 . . . . .               | 30        |
| 3.3.3        | 多様性を加算しない設計判断 . . . . .                       | 31        |
| 3.4          | 進化アルゴリズム . . . . .                            | 32        |
| 3.4.1        | 協調的共進化の構造 . . . . .                           | 32        |
| 3.4.2        | 選抜とエリート保存 . . . . .                           | 32        |
| 3.4.3        | 交叉: $\Delta W$ 空間ブレンドとランダム化 SVD 再分解 . . . . . | 33        |
| 3.4.4        | ガウス突然変異 . . . . .                             | 34        |
| 3.4.5        | 世代ループ全体 . . . . .                             | 34        |
| 3.5          | 計算量の分析 . . . . .                              | 34        |
| <b>第 4 章</b> | <b>評価実験</b>                                   | <b>37</b> |
| 4.1          | 実装 . . . . .                                  | 37        |
| 4.1.1        | ベースモデルと QLoRA 学習 . . . . .                    | 37        |
| 4.1.2        | vLLM Multi-LoRA サービング . . . . .               | 38        |
| 4.1.3        | Vertex AI Spot 構成とプリエンプション耐性 . . . . .        | 39        |
| 4.2          | ベンチマークと評価プロトコル . . . . .                      | 39        |
| 4.2.1        | ベンチマーク選定 . . . . .                            | 39        |
| 4.2.2        | 生成型評価と回答抽出 . . . . .                          | 40        |
| 4.2.3        | 進化ループ内の適応度セット . . . . .                       | 40        |
| 4.3          | 比較条件 . . . . .                                | 41        |
| 4.4          | 統計設計 . . . . .                                | 41        |
| 4.5          | ハイパーパラメータ . . . . .                           | 44        |
| 4.6          | 実験結果 . . . . .                                | 46        |
| 4.6.1        | 実験 1: 主実験の結果 . . . . .                        | 47        |
| 4.6.2        | 実験 1 の診断: 損失分解 . . . . .                      | 48        |
| 4.6.3        | 実験 2: 処方の検証 (ゲート方式) . . . . .                 | 49        |
| 4.6.4        | 測定環境の系統差の発見と統制 . . . . .                      | 50        |

|              |                                    |           |
|--------------|------------------------------------|-----------|
| 4.6.5        | 実験 2: 最終評価（同一測定環境）                 | 51        |
| 4.6.6        | 追加分析: sharing の事後検証・カテゴリ別効果・計算量の実測 | 52        |
| <b>第 5 章</b> | <b>考察</b>                          | <b>54</b> |
| 5.1          | 実験結果の解釈: 議論の効果は 2 軸のトレードオフで決まる     | 54        |
| 5.2          | 損失分解が導いた処方とその効果                    | 55        |
| 5.3          | 進化的最適化の再解釈: 選抜ではなく修復               | 56        |
| 5.4          | Self-Consistency との比較の最終形          | 57        |
| 5.5          | 本研究の限界                             | 58        |
| <b>第 6 章</b> | <b>結論</b>                          | <b>60</b> |
| 6.1          | まとめ                                | 60        |
| 6.2          | 今後の課題                              | 61        |
|              | <b>謝辞</b>                          | <b>63</b> |
|              | <b>参考文献</b>                        | <b>64</b> |

# 第1章 序論

## 1.1 研究背景

### 1.1.1 単一モデルの拡大から小型モデル集団の協調へ

大規模言語モデル（LLM）の性能は、パラメータ数・データ量・計算量の拡大によって向上してきた。しかし、モデル規模の拡大は学習・推論コストの急激な増大を伴い、単一モデルの能力を際限なく引き上げるアプローチには経済的・工学的な制約が存在する。この制約を背景として、近年、「個の拡大」に代わる方向性として「集団の協調」への関心が高まっている。すなわち、単一の巨大モデルにすべての能力を担わせるのではなく、複数のモデル（あるいは複数のインスタンス）を相互作用させ、その集合としての振る舞いから単体を超える性能を引き出すという考え方である。実際、複数のサンプル生成と多数決という最も素朴な協調形態であっても、エージェント数の増加に伴い性能が単調に向上するスケール特性が報告されている [1]。また、配備済みモデルの重みやプロンプト、エージェント構成そのものを実行後に継続的に改善していく「自己進化エージェント」という枠組みが体系化されつつあり、モデルを静的な成果物ではなく進化し続ける集団として扱う視点が整理されている [2, 3]。

この潮流は、小型モデルにとって特に重要な意味を持つ。数十億パラメータ級（以下、4B 級と表記する）の小型モデルは、単体では最先端の巨大モデルに及ばないものの、ローカル環境や安価な計算資源上で複数個を同時に運用できるため、「複数の特化した小型モデルの協調」によって単体性能の限界を補うという設計が現実的な選択肢となる。さらに、パラメータ効率的微調整手法である LoRA（Low-Rank Adaptation）[4] を用いれば、単一のベースモデルの上に複数の軽量アダプタを載せ替えるだけで多様な「人格（ペルソナ）」や役割を持つエージェント群を構成でき、メモリコストを抑えたまま集団を形成できる。本研究はこの構図、すなわち「共有ベースモデル＋役割別 LoRA アダプタ群」による小型モデル協調を対象とする。

### 1.1.2 マルチエージェント議論の登場とその限界

複数の LLM エージェントを協調させる代表的なプロトコルが、マルチエージェント議論 (Multi-Agent Debate; MAD) である。Du ら [5] は、複数の LLM インスタンスが互いの回答を参照しながら複数ラウンドにわたり回答を更新し、最終的に合意された回答を採用する手続きにより、3 エージェント × 2 ラウンドの構成で GSM8K の精度を 77 から 85 へ、MMLU を 63.9 から 71.1 へ改善できることを示した。また Liang ら [6] は、単一モデルの自己反省が同一の思考に固執する「思考の退化 (Degeneration-of-Thought)」に陥ることを指摘し、異なる視点を持つエージェント間の対立的議論がその回避に有効であることを示した。

しかし、その後の検証研究は MAD の効果に重大な留保を付けている。Smit ら [7] は、MAD が Self-Consistency[8] などの単純なアンサンブル手法に対して計算量を揃えた比較では安定して勝てないことを示した。さらに、議論の中で他者の回答に同調して正答を誤答へ書き換えてしまう追従性 (sycophancy) による誤りの伝染 [9]、同一モデルの複製からなる同質なエージェント集団では議論が非効率かつ不安定になるという報告 [10] が続いている。Zhang ら [11] は既存 MAD 研究の評価上の不備を系統的に指摘したうえで、MAD を機能させる鍵はエージェント間の異質性の活用にあると論じた。すなわち、MAD の成否は「議論に参加するエージェント集団の質と多様性」に強く依存するにもかかわらず、既存研究の多くはエージェント側を固定し、プロトコル (ラウンド数・集約方式・プロンプト) の工夫のみで改善を図ってきたのである。

## 1.2 研究課題

以上の背景から、本研究は次の三つの課題を出発点とする。

(a) 既存の MAD 研究はエージェントを固定し、協調の質そのものを最適化していない。MAD の性能はエージェント集団の構成に依存するにもかかわらず、既存研究の主流は与えられたモデルを所与として議論プロトコルを調整するものであった。議論への貢献度を報酬としてモデル自体を訓練する試みは MAPoRL[12] などの強化学習ベースの研究に限られ、「議論チームへの貢献」を選択圧としてエージェント集団 (の重み) を世代交替的に進化させる研究は、著者の知る限り報告されていない。

(b) 既存の LoRA 集団進化は個体性能のみを適応度とする．LoRA アダプタの重みを遺伝子とみなし，交叉・突然変異・選択によって集団を進化させる研究系統が近年急速に発展している（GENOME[13]，PopuLoRA[14] など）．しかしこれらの適応度は個体単独のタスク性能（あるいは敵対的 self-play の勝敗）であり，「チームの一員としてどれだけ協調に寄与するか」を測る適応度は用いられていない．個体として優秀なエージェントの集合が優れたチームになるとは限らない，というアンサンブル学習の古典的知見 [15] に照らせば，これは本質的な欠落である．

(c) 多様性を適応度に加算する素朴な設計には理論的問題がある．チームの多様性が重要であるならば，「性能  $+\lambda \times$  多様性」の形で適応度に多様性項を加算すればよいと考えたくなる．しかし，品質多様性（Quality-Diversity）研究は多様性を目的関数に混ぜるのではなくアーカイブ構造で分離して保持すべきことを示しており（MAP-Elites[16]），アンサンブル多様性の統一理論もまた，多様性が bias・variance と並ぶトレードオフ管理の対象であって無条件に加算してよい量ではないことを示している [17]．したがって，協調と多様性を扱う適応度設計には，加重和に代わる理論的に正当化された構成が必要である．

### 1.3 提案手法の要点と本研究の貢献

本研究は，上記の課題に対し，マルチエージェント議論のチームレベル適応度——厳密 Shapley 値によって測られる協調寄与——を選択圧として，ペルソナ LoRA 集団を進化的に最適化する枠組みを提案する．対象は Qwen3-4B-Instruct[18] を共有ベースモデルとする 3 役割（批判的検証者・実務的意思決定者・発散的探索者）の LoRA エージェント集団であり，協調的共進化 [19] の枠組みに従って役割別サブ集団を維持しながら，世代ごとに (i) 各候補 LoRA を代表チームに組み込んだ議論評価，(ii) Shapley 値に基づく貢献度の算出，(iii)  $\Delta W$  空間での交叉と突然変異による次世代生成，を繰り返す．

適応度の中核には協力ゲーム理論の Shapley 値 [20] を採用する．Shapley 値は効率性・対称性・null player・線形性の公理を一意に満たす貢献配分であり [21]，一般には連合数が指数的に増えるため近似を要するが [22]，本研究の 3 エージェント構成では全 7 連合の議論評価によって近似なしの厳密計算が可能である．また，課題 (c) を踏まえ，多様性は適応度への加算項とせず，fitness sharing[23] による乗法ペナルティ——回答不一致率で測った行動距離に基づき，同一ニッチに密集した

個体の適応度を割り引く——として組み込む。

本研究の貢献は以下の4点である。

1. **厳密 Shapley 値による協調寄与を LoRA 集団進化の適応度に組み込む初の定式化.** 議論チームへの限界貢献を、3 エージェント構成において全連合の実測から近似なしに計算可能な Shapley 値として定式化し、これを選択圧とする進化的最適化の枠組みを提示する。Shapley 値は個体単独の性能（単独連合の価値）を内包するため、性能項と協調項の恣意的な加重和を必要としない点で、既存の適応度設計と理論的に区別される。
2. **協調的共進化の枠組みによる MAD チーム最適化手法の提案.** Potter と De Jong[19] の役割別サブ集団と協力者評価の考え方を LLM エージェント集団に移植し、役割内の  $\Delta W$  空間交叉（LoRA 因子の素朴な補間が持つ交差項問題を回避するため、 $\Delta W = BA$  を明示的に構成して補間し SVD で低ランクに再分解する方式；Stoica ら [24] の知見に基づく）と fitness sharing を組み合わせた世代交代アルゴリズムを設計する。ただし fitness sharing はサブ集団サイズ  $K = 2$  の本実験構成では選抜に作用しないことが事後検証で判明しており（§3.3.2, §4.6.6）、実際に働いた選択圧は Shapley 値のみである。
3. **4B 級小型モデルにおける「議論が機能する条件」の実証分析と損失分解による診断枠組み.** 7～8B 級の同質エージェントによる素の議論は非効率・不安定であり [10]、評価設計の不備を正すと MAD の優位が消えるという批判 [11] も踏まえると、4B 級では素の議論は機能しない可能性が高い。本研究は、生成回数を揃えた Self-Consistency ベースラインおよびプロンプトのみのペルソナ付与との統制比較によって議論チームの成否を3ベンチマークで測定し、その効果が「多様性の利得」と「ペルソナ注入による能力毀損」の2軸トレードオフとしてベンチマーク依存に反転することを示す（この反転を「検証可能性」で統一的に説明する解釈は、ベンチマーク内のカテゴリ別分析では支持されず、仮説の域を出ない；§4.6.6）。さらにチーム誤差を個体能力損失と集約損失に分解する診断（oracle 上限分析）を提案する。
4. **診断に基づく処方の実測ゲート検証と、統制された負の結果.** 上記の診断が特定した損失（思考連鎖の圧縮による能力毀損・正解が少数派の問題での集約失敗・適応度測定ノイズによる選抜の無情報化）のそれぞれに対し、能力保持リプレイ再学習・検証型集約・議論プロトコル改良という処方を設計し、事

前定義した合格基準を持つゲート方式で検証する。処方は旧チームを +2.7pt (問題 ID クラスタ解析,  $p = 0.0003$ ) 有意に改善し, ベース単体との同等性 (等価マージン  $\pm 2\text{pt}$ ) を回復させたが, 生成回数を揃えた Self-Consistency には  $-3.5\text{pt}$  ( $p < 10^{-4}$ ) と有意に及ばなかった。この過程で評価環境の系統差 (同一設定・同一問題でイメージ差のみにより +6pt 級) を検出・統制しており, 負の結果の確定と評価再現性の警鐘を含めて報告する。

## 1.4 本論文の構成

本論文の構成は以下の通りである。第2章では, マルチエージェント議論, モデルマージと LoRA 合成の理論, 進化的モデル最適化, 協調の定量化と適応度設計の理論という4つの研究系統を整理し, 本研究の位置づけを明確化する。第3章では, 提案手法——Shapley 値に基づくチームレベル適応度, fitness sharing,  $\Delta W$  空間交叉を含む協調的共進化アルゴリズム, および議論プロトコル——を定式化する。第4章では, ベンチマーク・比較条件・統計的検定を含む実験設計を述べ, 実験結果を報告する。第5章では実験結果に対する考察と本研究の限界を論じ, 第6章で結論と今後の展望を述べる。

## 第2章 関連研究

本章では、本研究に關係する研究を6つの系統に分けて整理する．2.1節ではマルチエージェント議論と回答の集約を，2.2節ではペルソナと役割の設計を，2.3節では議論や自己生成データからの学習を，2.4節では進化的なモデル最適化と重み合成の前提条件を，2.5節ではチームへの貢献の定量化を，2.6節では評価の信頼性を扱う．最後に2.7節で本研究の位置づけを述べる．

### 2.1 マルチエージェント議論と集約

#### 2.1.1 議論の原典と批判

マルチエージェント議論 (Multi-Agent Debate; MAD) の原典とされる Du ら [5] の手続きでは，複数の LLM インスタンスがまず独立に回答する．続くラウンドでは，各インスタンスが自分の前回の回答を会話の文脈に保持したまま他者の回答を読み，自分の回答を更新する．同研究は，この手続きによって数学の文章題や事実性の課題で単体より精度が上がることを示した．Liang ら [6] は，単一モデルの自己反省が初期解に固執する「思考の退化」を指摘し，異なる立場を与えたエージェント同士の議論がこれを避けるのに必要だと論じた．

その後，MAD の効果は計算量を揃えた比較で大きく縮むことが示された．Smit ら [7] は複数の MAD 戦略を同じ枠組みで比較し，複数の推論経路の多数決をとる Self-Consistency (SC) [8] などの単純な手法に，MAD が安定して勝てないことを示した．サンプリングと投票だけでも，エージェント数に応じて性能は伸びる [1]．Zhang ら [11] も既存研究の評価設計の弱さを指摘し，公平な条件では MAD の優位が小さいこと，モデルの異質性を活かすべきことを論じている．したがって MAD の効果は，生成回数を揃えた SC と比べて初めて評価できる．

小型モデルでは，単純な反復サンプリングの優位がさらに明確である．1.5B～7B のモデルと数学課題による 36 の比較では，同じトークン数の反復サンプリングより確実に良い手法は一つもなく，自己点検型の手法の 18 比較はすべて負けで

あった [25]. 7~8B 級の同一モデル 10 体による議論では、同調率が最大 85.5% に達した. チームの誰かが正解しているのに最終回答が誤る差 (oracle との差) は最大 32.3pt に開き、議論は孤立した自己訂正の 2.1~3.4 倍のトークンを消費した [10].

議論の利得の源泉は、回答の更新そのものより最終段の投票にあるとする分析もある. Choi ら [26] は、MAD の利得の大半が多数決で説明でき、議論による信念の更新は期待値の上で正答率を改善しないマルチンゲールになることを示した. Kaesberg ら [27] は、推論課題では投票型の決定方式が他の方式より 13.2% 高く、投票前の議論ラウンドを増やすと性能が下がることを報告している. MAD 戦略のサーベイ [28] は、分野の手法が「全結合・逐語共有・短い記憶・投票による決着」という狭い型に慣習的に収束していると指摘する.

### 2.1.2 同調と多様性

議論の主な失敗様式は同調である. Wynn ら [9] は、正答していたエージェントが他者の推論に引きずられて誤答へ移る現象を報告した. MachineSoM [29] は、性格と思考様式の異なるエージェントからなる「社会」に、同調や合意形成といった人間の社会心理学的な振る舞いが現れることを示した. 論理推論で条件を統制した Wu ら [30] は、個体の推論能力と集団の多様性が議論の成否を主に決め、多数派の圧力が独立な訂正を抑えると結論している. Okawa [31] は、同調性が臨界点を超えると集団が偏った合意へ相転移し、温度サンプリングのノイズがこれを増幅し、異質性が抑制することを示した. 自己組織化したチームが専門家と非専門家の意見を平均してしまい、最良の個人より最大 41.1% 劣るという報告もある [32].

議論に効く多様性は、性格よりも推論の手続きとモデルそのものの違いから生じる. DMAD [33] は、全員が同じ推論手法を使う議論は同じ誤りから抜け出せない (mental set) と指摘した. そして Chain-of-Thought, Step-Back, Program-of-Thought といった異なる推論手法を各エージェントに割り当て、全員が同じ手法の議論を上回った (GPT-4o-mini の集計値で 55.47 から 56.54). ReConcile [34] は、異なるモデル同士の議論で MATH を 8% 改善し、モデルの違いに由来する多様性が性能に決定的であると述べている. Zhu ら [35] は、初期回答の多様性を高める初期化と、確信度に条件づけた更新によって、議論が正解側へ流れることを示した.

ただし、多様性は品質を損なわない範囲でのみ価値を持つ. Li ら [36] は、異なるモデルを混ぜるより、最も強い単一モデルの複数の出力を集約する方が多くの

場合に優れることを示し、混合が有効なのは構成モデルの品質が拮抗する場合に限られると分析した。

### 2.1.3 回答の集約

最終回答は、多数決のほか、モデル自身に候補を比べさせる方法でも決められる。GenSelect[37] は、 $N$  個の候補解をモデルに長い推論で比較させ、最良の 1 つを選ばせる。RSA[38] は、候補の部分集合を集約して改良した解を作る操作を再帰的に繰り返す。ただし RSA の原著でも、本研究と同じ Qwen3-4B-Instruct-2507 による SuperGPQA では、予算を揃えた多数決 (48.2) が RSA (10 ステップで 47.39) とベース (41.85) を上回った。著者らは、多肢選択形式では多数決が特に強いと述べている。

候補を見せて更新させる操作が効くかどうかは、候補に含まれる正解の数に依存する。Farmanfarmaian[39] は、Qwen3-4B による競技数学で、同じ予算で新しく解き直す対照と比べ、候補に正解が 2 つ以上あれば正答率が +0.290 上がり、全員が誤っていれば -0.123 下がることを示した。Fortuna と Bertalanic[40] は、誰か 1 人が正解すれば足りる課題では、チームを大きくすると潜在的な上限 (oracle) が 5~20pt 増える一方、単純多数の投票は単体比で 0.5pt 以内しか回収しないことを報告した。同研究では複数ラウンドの改訂が大きく効き、その利得は相手が 1 体でも 29 体でもほぼ同じであった。

以上をまとめると、議論の効果は、生成回数を揃えた SC との比較、同調の抑制、推論手続きの多様性、集約の設計の 4 点に左右される。本研究はこれらを前提条件として扱い、議論の手続きと集約を固定したうえで、生成回数を考慮した SC との比較を評価に含める。

## 2.2 ペルソナと役割

### 2.2.1 ペルソナ付与の効果と限界

システムプロンプトでペルソナを与えても、客観的な課題の精度は上がらないことが多い。Zheng ら [41] は、162 種類の役割、4 系列のモデル、2,410 問の事実問題を調べ、ペルソナの効果はほぼランダムであり、最良のペルソナを自動で選ぶ方法もランダムな選択と大差ないことを示した。Kim ら [42] は、Llama3 で役割演

技のプロンプトが12データセット中7つで推論を劣化させたと報告している。専門家のペルソナは、好みや安全性への整合を改善する一方で、知識を問う課題の精度を損なう [43]。

小型のモデルでは、複雑なペルソナの指示そのものが機能しにくい。複数のペルソナによる自己協働 (Solo Performance Prompting) の効果は GPT-4 でのみ現れ、GPT-3.5-turbo や Llama2-13b-chat では現れなかった [44]。

性格の効果は、課題の構造と同調のしやすさを通じて現れる。Keluskar ら [45] は、協調性の低い性格が発話を大きく変えても、構造化された課題 (コーディング) の成果にはほとんど影響しないことを示した。重み空間で性格特性を扱った Persona Cartography [46] では、特性ごとの LoRA がほぼ加法的に合成でき、協調性 (agreeableness) の軸が追従 (sycophancy) を左右した。これらは、多肢選択や数学のような構造化された課題では、ペルソナを性格のラベルではなく推論の手続きとして定義すべきことを示唆する。

## 2.2.2 人間のチーム役割理論

人間の問題解決チームの役割を分類した代表的な理論に、Belbin のチーム役割がある [47, 48]。Belbin は、思考系の Plant, Monitor Evaluator, Specialist, 行動系の Shaper, Implementer, Completer Finisher, 対人系の Co-ordinator, Teamworker, Resource Investigator の 9 役割を定義し (Specialist は 1993 年に追加)、役割のそろったチームほど成果が高いと主張した。

ただし、Belbin の理論の実証的な妥当性には留保がある。Furnham ら [49] は、役割を測る自己評価尺度の信頼性係数が高くなく、因子構造も想定どおりに現れないことを示した。Senior [50] は 11 チームの調査で役割のバランスと成果の関連に部分的な支持を得ており、Aritzeta ら [51] は 43 の実証研究をもとに構成概念の妥当性を総括している。したがって Belbin の理論は、チームの成果を予測する法則としてではなく、人間のチームの役割を網羅的に列挙する分類として用いるのが妥当である。同様の分類として、de Bono の 6 つの思考モード [52] も、議論における役割付与の一類型として参照されている [28]。

個人の能力と集団の多様性の関係については、Hong と Page [53] が、多様な問題解決者の集団が個人成績上位者の集団を上回りうることを計算モデルで示した。候補者が多いと、上位者どうしが互いに似てしまうためである。この結果には Thompson [54] による数学的な批判と、Kuehn [55] による反論がある。単独の成績

が高い個体を集めてもチームとして最適とは限らないという問題提起は、チームへの貢献でメンバーを選ぶ本研究の動機の一つである。

### 2.2.3 役割の割り当てと選抜

LLM のチームでは、役割の割り当て方が結果を大きく左右する。Zhang ら [56] は、議論の各役割にどのモデルを置くかを候補どうしの予備的な議論で採点して決め、全役割に同じモデルを置く場合を最大 74.8%、ランダムな配置を最大 29.7% 上回った。DyLAN[57] は、予備試行で各エージェントの重要度 (Agent Importance Score) を集計して候補からチームを選び、MMLU では 7 体を 4 体に絞りつつ、科目によって最大 25% 改善した。

役割や構成そのものを探索する研究もある。EvoAgent[58] は、エージェントの設定を変異・交叉・選択で進化させて多エージェント系を自動生成する。MASS[59] は、プロンプトとトポロジーの両方が多エージェント系の性能を決めるとして、両者を段階的に最適化する。EvoMAS[60] は、多エージェント系の構成を、実行の記録に基づく変異と交叉で進化させる。これらはプロンプトや構成の空間での探索であり、モデルの重みは変えない。

役割を推論の手続きとして具体化するには、確立したプロンプト手法が使える。原理や定義へ一段抽象化してから解く Step-Back[61]、計画を立てて小問に分けて解く Plan-and-Solve[62] と Least-to-Most[63]、得た解を逆向きに検証する Self-Verification[64]、類似の問題を自ら想起して適用する Analogical prompting[65] などである。本研究は第 3 章で、Belbin の 9 役割をこれらの手続きに対応づけ、世代 0 のペルソナの候補とする。

## 2.3 議論と自己生成データからの学習

正解ラベルのある問題で、モデル自身が生成した推論のうち正解に至ったものを学習する自己学習は、単一モデルで確立している。STaR[66] は、正解した推論で微調整を繰り返し、解けなかった問題では正解をヒントとして与えて推論を作り直す (rationalization)。RFT[67] は、複数回サンプリングした推論のうち正解のものを集めて微調整し、互いに異なる推論経路が多いほど効果が大きいことを示した。

議論の相互作用から得たデータで、複数のモデルを別々に学習させる研究もある。Multiagent Finetuning[68] は、同じベースモデルから始めた複数のモデルを、モデル間の相互作用で生成したデータでそれぞれ別々に学習させた。その結果、推論の多様性を保ったまま、単一モデルの自己改善より多くの反復にわたって改善が続いた。MACA[69] は、議論の多数派と少数派の推論を区別するように事後学習し、単体の自己一貫性と議論の活用をともに高めた。CANON[70] は、多数派に到達した解を教師側だけが参照できる文脈として使うラベルなしの自己蒸留で、pass@1 を最大 12pt 改善した。

強化学習で議論への適応を学ぶ研究も増えている。MAPoRL[12] は、議論の協調を報酬として複数のモデルを共同で学習させる。SDRL[71] は、初期回答と、議論を条件にした回答を同時に最適化する。MADA-RL[72] は、1.5B モデルの LoRA を生成役と批評役に特化させ、批評役の利得を生成役の合意に対する反実仮想で定義することで、数学の精度を 39.9% から 41.9% に上げた。これらはいずれも勾配による学習であり、チームへの貢献で個体を選抜する集団の仕組みは持たない。

学習で獲得した形質を子へ受け渡す進化は、ラマルクの進化と呼ばれる。進化計算では、局所探索で改良した解を遺伝子型に書き戻す方式として、書き戻さない方式（ボールドウィン効果）と対比して調べられてきた [73]。深層学習の Population Based Training[74] も、性能の低い個体に性能の高い個体の重みを複製させ、ハイパーパラメータに摂動を加えて学習を続けさせることで、学習と選抜を交互に行う。人間の文化は、遺伝ではなく他者からの社会学習によって世代を越えて伝わり、蓄積する [75]。本研究の進化的社会学習は、議論で正解に至った自他の発話から学ぶ個体の学習と、チームへの貢献による選抜を組み合わせるものであり、これらの系譜に位置づけられる。

## 2.4 進化的モデル最適化

### 2.4.1 重み空間の集団最適化

進化計算を LLM の重みや合成レシピに適用する研究は、一つの系統をなしている。Akiba ら [76] は CMA-ES で既存モデルのマージレシピを探索し、LoraHub[77] は既存の LoRA の合成係数を勾配なしで最適化した。いずれも既存のモデルを素材とする 1 点の探索であり、集団の世代交代は行わない。

重み空間を集団で探索する研究も現れた。Model Swarms[78] は、LoRA の専門家を粒子とみなし、粒子群最適化 (PSO) で重み空間を探索する。GENOME (およびその拡張の GENOME+) [13] は、交叉・変異・選択・継承・アンサンブルからなる世代交代を LLM の重みに適用し、専門家の重みのランダムな線形結合で初期集団を多様化する。ただし適応度は個体の少数ショット精度である。EvoPref[79] は、LoRA の集団を NSGA-II で進化させ、多様な整合を探索する。PopuLoRA[14] は、共有ベース上の LoRA 集団を出題者と解答者の対戦で共進化させる。同研究は、テンソルの標準偏差の 0.1~0.15 倍の変異や外挿型の交叉を含む 17 種類の演算子を試し、子が短い学習で親の水準へ戻れない演算子を除いた。

大規模なモデルでも、勾配を使わない進化戦略 (ES) が有効な場合がある。ES at Scale[80] は、全パラメータに対する ES を 30 個体の摂動集団で行い、適応度を貪欲デコードで評価した。Countdown では Qwen2.5-7B の GRPO (57.5) を上回る 66.8 を得た。

チームとしての評価を重み集団の最適化に組み込んだ研究もある。Heterogeneous Swarms[81] は、複数の LLM をつなぐ有向非巡回グラフ (DAG) の役割と、各モデルの重みを PSO で交互に最適化する。各モデルの貢献を測る JFK-score は、最良の DAG の各位置にモデルをランダムに割り当てる試行を繰り返し、効用を登場頻度で重み付けして平均したもので、周辺貢献ではない。同研究は 15 のベースラインに対して 12 課題の平均で 18.5% の改善を報告したが、生成回数を揃えた SC との比較は含まない。AC/DC[82] は、タスクベクトルの内挿による交叉と特異値へのノイズによる変異でモデルの集団を作り、合成課題の集団と共進化させる。そのうえで、誰か 1 体が正解する割合 (カバレッジ) が最大となるチームを事後的に選んだ (3 体で専門家比 +1.34%)。品質多様性 (QD) [16] の枠組みで、重みのマージによる交叉と SVD による変異を行う CycleQD[83] もこの系統に属する。主要な研究の対比を表 2.1 に示す。

#### 2.4.2 重み合成の前提条件

重みの交叉が意味を持つには、親どうしが損失地形の上で線形に接続されている必要がある。Model Soups[84] は、同じ事前学習モデルから微調整した複数のモデルの重みを平均すると精度が上がることを示した。Task Arithmetic[85] は、微調整による重みの差分  $\Delta W$  をタスクベクトルとみなし、その加減算で能力を合成できることを示した。TIES-Merging[86] は差分の符号の衝突を解消し、DARE[87]

表 2.1: 重み空間の集団最適化に関する主要な研究の対比

| 研究                          | 最適化の対象                    | 探索の方式                            | 世代交代 | 適応度・貢献の測り方                                | 個体間の相互作用                       |
|-----------------------------|---------------------------|----------------------------------|------|-------------------------------------------|--------------------------------|
| 進化的モデル<br>マージ [76]          | マージレシビ                    | CMA-ES                           | なし   | 合成したモデル単体の性能                              | なし                             |
| Model<br>Swarms[78]         | LoRA 専門家の<br>重み           | PSO                              | なし   | 個体の効用                                     | なし                             |
| GENOME[13]                  | LLM の重み                   | GA (交叉・変異・<br>選択・継承)             | あり   | 個体の少数ショット<br>精度                           | アンサンブル<br>(投票)                 |
| PopuLoRA[14]                | LoRA の集団                  | 演算子と勾配学<br>習の併用                  | あり   | 対 戦 成 績<br>(TrueSkill)                    | 敵対的な自己<br>対戦                   |
| Heterogeneous<br>Swarms[81] | DAG の役割と<br>各モデルの重み       | PSO                              | なし   | JFK-score (ランダ<br>ムな割り当ての平<br>均効用)        | DAG 上のメッ<br>セージ伝達              |
| AC/DC[82]                   | モデルの集団<br>(課題の集団と<br>共進化) | 内挿による交叉,<br>特異値ノイズに<br>よる変異      | あり   | 新規性とスキル.<br>チームはカバレッ<br>ジで事後に選抜           | best-of-N<br>(judge による<br>選択) |
| <b>本研究</b>                  | 役割ごとのペル<br>ソナ LoRA        | 議論からの社会<br>学習 (勾配), 兄<br>弟交叉, 選抜 | あり   | <b>議論チームへの全<br/>連合実測の Shap-<br/>ley 値</b> | <b>協調的な議論</b>                  |

は差分の冗長性を利用して, 合成時の干渉を減らす. 体系的な整理は Yang ら [88] のサーベイにある.

LoRA[4] では, この前提が崩れやすい. KnOTS[24] は, LoRA で得た  $\Delta W$  はフル微調整に比べてモデル間の整合が低く, 素朴な平均で性能が落ちることを示し, SVD で共通の基底に揃えてから合成する方法を提案した. CoTo[89] は, 同じ課題を異なる乱数シードで独立に学習した 2 つの LoRA を重み空間で内挿すると, 中点で通常の LoRA の精度が 39% まで落ちる (CoTo の学習法では 79%) ことを示した. 一方, Seeded LoRA[90] は, 共通の種となるアダプタから学習を始めると, その後の独立な学習が同じ部分空間に留まり, 合成できるようになることを示した.

LoRA の低ランク因子  $A, B$  を別々に補間する方式には, 交差項の問題もある. 2 つのアダプタ  $B_1A_1, B_2A_2$  の因子を係数  $\alpha$  で別々に補間すると

$$\begin{aligned}
 & ((1 - \alpha)B_1 + \alpha B_2)((1 - \alpha)A_1 + \alpha A_2) \\
 &= (1 - \alpha)^2 B_1A_1 + \alpha^2 B_2A_2 + \alpha(1 - \alpha)(B_1A_2 + B_2A_1)
 \end{aligned} \tag{2.1}$$

となり, 意図した凸結合  $(1 - \alpha)B_1A_1 + \alpha B_2A_2$  とは一致せず, 意味を持たない交差項  $B_1A_2, B_2A_1$  が混入する. また  $BA = (BR)(R^{-1}A)$  という再パラメータ化の不定性があるため, 因子空間での補間は分解の取り方に依存する. したがって LoRA

の交叉は  $\Delta W$  の空間で定義し、必要に応じて SVD で低ランクに再分解するのが妥当である。本研究の兄弟交叉（第3章）は、同じ親から学習した2つの子の  $\Delta W$  を平均し、SVD で再分解する。共通の親から分岐した子どもを合成する点でも、上記の前提に沿った設計である。

## 2.5 チームへの貢献の定量化

協力ゲーム理論の Shapley 値 [20] は、連合の価値関数  $v$  のもとで、各プレイヤーの貢献を、あらゆる部分連合への限界貢献の重み付き平均として配分する。効率性・対称性・ナルプレイヤー・線形性の公理を満たす唯一の配分であり、機械学習ではデータの価値評価 [21] をはじめ広く使われている [22]。計算には一般に  $2^n$  個の連合の評価が必要なため近似法が発達したが、3体のチームなら全7連合を実測でき、連合の列挙に伴う近似は要らない。ただし各連合の価値は有限個の問題での精度として推定されるため、推定の誤差は残る。

Banzhaf 値 [91] は、限界貢献を部分連合について等しい重みで平均する別の配分である。Wang と Jia [92] は、学習の確率性によって効用にノイズが乗ると Shapley 値や LOO による順位が不安定になり、準値 (semivalue) の中では Banzhaf 値が順位の頑健性 (safety margin) を最大にすることを示した。3体の全連合を実測すれば、両者は同じデータから追加の費用なしに計算できる。

個体の貢献を「その個体がない場合」との差で測る考え方は、進化計算とマルチエージェント学習に古くからある。Wolpert と Tumer [93] の集合知の枠組みや、Agogino と Tumer [94] の差分評価は、全体の評価と整合し、かつ各個体の寄与に敏感な評価関数を設計する。COMA [95] は、反実仮定のベースラインを方策勾配に取り入れた。集団の性能への周辺貢献を適応度とするスパイキングニューラルネットワークのアンサンブルの共進化が、単体の進化や事後的なアンサンブルより良い結果を得たという報告もある [96]。

役割ごとの部分集団を、他の部分集団の代表と組ませて評価する方法は、協調的共進化 [19] として確立している。ただし協力者の選び方は結果を左右する [97]。代表との組合せだけで評価すると、最適ではないがどの協力者とも無難に機能する個体を選ばれやすい相対的過汎化が起こりうる [98]。

LLM の多エージェント系でも、貢献を学習や選抜の信号にする研究が増えている。SHARP [99] はあるエージェントを除いた軌跡との報酬の差を、C3 [100] は1つ

の発話を差し替えて最後まで続けた反実仮想を、それぞれ強化学習の credit に用いる。Agents that Matter[101] は、除去に基づく帰属 (LOO) が組合せ的な方法と同等にボトルネックを特定できることを示し、貢献の低いエージェントの基盤モデルを差し替えて最大 17% 改善し、費用を 35% 削減した。MoCA[102] は、相補性に基づく貪欲な選択でチームを構成する。その原型は、モデルのライブラリから前向きに選択するアンサンブル選択 [103] にさかのぼる。

チームの利得を多様性の指標で代替することには限界がある。アンサンブルの誤差は、構成員の平均誤差から構成員間の不一致を引いた形に分解でき [15]、多様性は誤差の独立した次元として扱える [17]。しかし Kim[104] は、MMLU-Pro で 30 の LLM から作った 3 体の部分集合のうち、多数決が最強の構成員を上回ったのは 9.98% にすぎず、よく使われる多様性の指標が構成員の能力の代理になっていることを示した。連合ごとにチームの成果そのものを測る Shapley 値や Banzhaf 値は、この交絡を避けられる。

## 2.6 評価の信頼性

LLM の評価で条件間の差を検定するには、問題を単位とした対応のある比較と、問題間の相関を考慮した標準誤差が推奨されている [105]。NLP における有意性検定の使い分けは Dror ら [106] が整理しており、複数の比較には Holm の方法 [107] などで族全体の誤り率を制御する。

評価値の揺れには、問題の標本抽出によるノイズと、同じ問題での生成のノイズがある。Wang[108] は、後者が前者を通常上回り、同じ問題で予測を繰り返して平均すると検出力が大きく上がることを示した。

ノイズのある評価で候補を選ぶと、選ばれた候補の評価値は楽観的に偏る。進化計算では、ノイズのある適応度への対処として、再サンプリングや再評価などが整理されている [109, 110]。LLM の評価でも、適応的な調整の後に得た勝者のスコアは過大になるため、候補を凍結し、選抜と評価に別のデータを使う必要がある [111]。少数の問題による評価については、IRT で選んだ約 100 問と IRT による推定を組み合わせれば全体との誤差が約 2% に収まる [112]。ただしこの結果は、無作為に選んだ少数の問題には当てはまらない。

評価の環境も結果を変えうる。同じモデルと同じプロンプトでも、GPU のアーキテクチャが違えば、浮動小数点演算の非結合性とカーネルの選択によって出力

が変わる [113]. vLLM の推論設定の違いが精度にまで影響しうることも報告されている [114].

正誤の判定は、生成文から回答を取り出す抽出と、取り出した回答を正解と照合する判定の 2 段からなる．数学の自由記述では、分数・根号・単位などの表記の揺れがあるため、文字列の一致ではなく記号的な同値判定が必要となり、Math-Verify[115] のような規則ベースの検証器が使われている．抽出や判定の誤りが条件によって偏れば、条件間の比較そのものが歪む．したがって採点器は評価の前に固定し、条件ごとに誤りを監査する必要がある．

## 2.7 本研究の位置づけ

表 2.2 に、隣接する研究系統と本研究の差分を示す．

表 2.2: 隣接する研究系統と本研究の位置づけ

| 系統                | 代表的な研究                                                      | 更新する対象         | 最適化の信号                           | 本研究との差分                |
|-------------------|-------------------------------------------------------------|----------------|----------------------------------|------------------------|
| 議論の手続き・集約の改良      | 文献 [5, 33, 37, 38]                                          | 推論時の手続き        | —                                | エージェント自体を学習・選抜しない      |
| 役割・構成の探索と選抜       | DyLAN[57], EvoAgent[58], MASS[59], 文献 [56]                  | プロンプト・構成・配置    | 貢献度・検証性能                         | 重みを学習しない               |
| 議論からの学習           | Multiagent Finetuning[68], MACA[69], CANON[70], MADA-RL[72] | 重み（勾配）         | 議論のデータ・合意・報酬                     | チームへの貢献による集団の選抜を持たない   |
| 重み集団の進化           | GENOME[13], PopuLoRA[14], Model Swarms[78]                  | 重み・LoRA の集団    | 個体の性能・対戦成績                       | 適応度がチームへの貢献でない         |
| チームの評価による重み集団の最適化 | Heterogeneous Swarms[81], AC/DC[82]                         | 役割と重み, モデルの集団  | JFK-score, カバレッジ                 | 周辺貢献で測らない. 議論を価値関数としない |
| 貢献に基づく強化学習        | SHARP[99], C3[100]                                          | 重み（勾配）         | LOO・反実仮想の credit                 | 集団の選抜でない               |
| 本研究               | —                                                           | 役割ごとのパーソナ LoRA | 議論の正解発話（学習）と全連合実測の Shapley 値（選抜） | —                      |

本研究を構成する要素の多くには先行例がある．チーム内の貢献で重み集団の最

適化を導く考え方は Heterogeneous Swarms[81] が、議論の相互作用から得たデータで複数のモデルを別々に学習させる考え方は Multiagent Finetuning[68] が、すでに扱っている。周辺貢献を共進化の適応度とする考え方は差分評価の系譜 [94, 96] に、貢献に基づくチームの選抜は DyLAN[57] や Agents that Matter[101] に先行例がある。本研究は、これらの要素のいずれかを初めて提案するものではない。

一方、2026 年 9 月 30 日時点で著者が行った文献探索（arXiv と主要な国際会議の論文を対象としたキーワード検索と、本章で挙げた文献の引用の追跡）の範囲では、次の 4 点を同時に満たす研究は見つからなかった。

- (i) 人間のチーム役割理論から網羅的に作った候補を推論の手続きとして操作化し、チームへの貢献で世代 0 のペルソナを選ぶこと。
- (ii) 議論で正解に至った自分と他者の発話から、各ペルソナの LoRA を親から継続して学習させること（ラマルクの継承）。
- (iii) 議論の多数決による精度を価値関数とし、全連合を実測した Shapley 値で次世代の代表を選ぶこと。
- (iv) 選抜なし、単独精度による選抜、ペルソナと議論を用いない単一モデルの自己学習、生成回数を考慮した SC を対照とし、事前に固定した統計計画で比較すること。

本研究の新規性の主張は、この組合せと、その統制された検証に限る。

評価の面では、2.1 節の批判を受けて、生成回数と出力トークン数を考慮した SC を基準に置く。また 2.6 節の知見に従い、選抜に使う問題と最終評価の問題を分け、問題をクラスタとした検定で結論を導く。

## 第3章 提案手法

本章では、マルチエージェント議論 (Multi-Agent Debate; MAD) のチームレベル適応度を選択圧としてペルソナ LoRA 集団を進化させる提案手法を定式化する。まず 3.1 節で問題を形式的に定義し、3.2 節で議論プロトコル、3.3 節で適応度関数、3.4 節で進化アルゴリズムを述べ、3.5 節で計算量を分析する。本章の記述はすべて公開実装 (`src/evalx/debate.py`, `src/evalx/shapley.py`, `src/evolve/loop.py`, `src/models/lora_ops.py`) と一対一に対応する。

### 3.1 問題定式化

#### 3.1.1 ベースモデルと LoRA 個体

凍結されたベースモデル  $\mathcal{M}_{\theta_0}$  (本研究では Qwen3-4B-Instruct-2507[18]) を共有し、その上に付加する LoRA (Low-Rank Adaptation) [4] アダプタを進化の対象となる「個体」とする。LoRA は対象モジュール  $m \in \mathcal{L}$  (本実装では各 Transformer 層の  $q, k, v, o$  射影および gate, up, down 射影) の重み  $W_0^{(m)} \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$  に対し、低ランク行列対  $B^{(m)} \in \mathbb{R}^{d_{\text{out}} \times r}$ ,  $A^{(m)} \in \mathbb{R}^{r \times d_{\text{in}}}$  による更新

$$W^{(m)} = W_0^{(m)} + \gamma B^{(m)} A^{(m)}, \quad \gamma = \frac{\alpha_{\text{LoRA}}}{r} \quad (3.1)$$

を与える ( $r = 32$ ,  $\alpha_{\text{LoRA}} = 2r$ , したがって  $\gamma = 2$  で全個体共通・固定)。個体  $x$  は行列対の集合  $x = \{(A^{(m)}, B^{(m)})\}_{m \in \mathcal{L}}$  として定義され、その実効的な表現型は各モジュールの更新行列 (タスクベクトル [85])

$$\Delta W^{(m)}(x) = B^{(m)} A^{(m)} \quad (3.2)$$

の集合である。全個体は同一のベースモデル・同一の rank・同一の対象モジュール集合を共有するため、後述の交叉演算が層ごとに well-defined になる。

### 3.1.2 役割・エージェント・チーム

役割集合を  $\mathcal{R} = \{\text{critic}, \text{pragmatist}, \text{explorer}\}$  (批判的検証者・実務的意思決定者・発散的探索者) とし, 各役割  $r$  に固有のペルソナプロンプト  $\pi_r$  (システムプロンプトとして与える短い役割記述) を割り当てる. エージェントは個体と役割プロンプトの組  $a = (x, \pi_r)$  である. 役割ごとのペルソナは, 初期化時に役割別 SFT データで重み空間にも焼き込まれる (第 4 章).

世代  $t$  における役割  $r$  のサブ集団を  $P_r^{(t)} = \{c_{r,1}^{(t)}, \dots, c_{r,K}^{(t)}\}$  (本実装では  $K = 2$ ), その代表個体を  $\rho_r^{(t)} \in P_r^{(t)}$  と書く. 候補個体  $c \in P_r^{(t)}$  の評価は, 他役割の代表と組んだ代表チーム文脈

$$T(c) = \{c\} \cup \{\rho_{r'}^{(t)} \mid r' \in \mathcal{R}, r' \neq r\} \quad (3.3)$$

で行う. これは協調的共進化 (Cooperative Coevolution) [19] における「協力者 (collaborator) を固定した部分解評価」に相当する.

### 3.1.3 議論プロトコルと特性関数

質問  $q$  と正解  $y^*$  の組からなる固定の適応度セットを  $D_{\text{fit}} = \{(q_j, y_j^*)\}_{j=1}^{N_{\text{fit}}}$  ( $N_{\text{fit}} = 100$ ) とする. エージェント集合 (連合)  $S$  に対し, 3.2 節の議論プロトコルを  $R$  ラウンド実行して多数決回答を返す演算子を  $\mathcal{D}_R(S, q)$  と書く ( $|S| = 1$  のときは単独の Chain-of-Thought 回答). 連合  $S$  の**特性関数** (characteristic function) を適応度セット上の精度

$$v(S) = \frac{1}{N_{\text{fit}}} \sum_{j=1}^{N_{\text{fit}}} \mathbf{1} [\mathcal{D}_R(S, q_j) = y_j^*], \quad v(\emptyset) = 0 \quad (3.4)$$

と定義する. 定義より  $v(\{i\})$  は個体  $i$  の solo 精度に一致する. 以上の記号を表 3.1 にまとめる.

## 3.2 議論プロトコル

議論プロトコルは Du らの MAD 原型 [5] に準拠し, 近年の系統的検証 [26, 27, 35] の知見に基づいて簡素化した以下の構造を採用.

**ラウンド構造.** 各問題  $q$  に対し:

表 3.1: 記号表

| 記号                                    | 意味                                           |
|---------------------------------------|----------------------------------------------|
| $\mathcal{M}_{\theta_0}$              | 凍結ベースモデル (Qwen3-4B-Instruct-2507)            |
| $x = \{(A^{(m)}, B^{(m)})\}$          | LoRA 個体 (rank $r = 32$ , $\gamma = 2$ )      |
| $\Delta W^{(m)}(x) = B^{(m)} A^{(m)}$ | モジュール $m$ の実効更新行列                            |
| $\mathcal{R}, \pi_r$                  | 役割集合 (3 役割), 役割別ペルソナプロンプト                    |
| $P_r^{(t)}, K$                        | 世代 $t$ ・役割 $r$ のサブ集団, その規模 ( $K = 2$ )       |
| $\rho_r^{(t)}$                        | 役割 $r$ の代表個体 (前世代の役割内最良)                     |
| $T(c)$                                | 候補 $c$ の代表チーム文脈 (3 エージェント)                   |
| $D_{\text{fit}}, N_{\text{fit}}$      | 適応度セット, その問題数 (100)                          |
| $\mathcal{D}_R(S, q)$                 | 連合 $S$ による $R$ ラウンド議論の多数決回答                  |
| $v(S)$                                | 特性関数 (連合 $S$ の適応度セット精度, $v(\emptyset) = 0$ ) |
| $\phi_c$                              | 候補 $c$ の厳密 Shapley 値                         |
| $d(c, c')$                            | 行動距離 (solo 予測の不一致率)                          |
| $\sigma_{\text{share}}$               | fitness sharing の niche 半径 (0.3)             |
| $F(c)$                                | 最終適応度 $\phi_c \cdot s(c)$                    |
| $G, R$                                | 世代数 (6), 議論ラウンド数 (1)                         |

- **round 0 (独立回答)** : 各エージェント  $a_i = (x_i, \pi_{r_i})$  は, システムプロンプト (ペルソナ  $\pi_{r_i}$  + 回答形式指示) と質問のみを入力として独立に段階的推論と回答を生成する. 初期回答の多様性が MAD 成功の主要条件であるとの報告 [35] に従い, 独立生成を厳格に保つ.
- **round 1...R (批判的更新)** : 各エージェントに, **他エージェントの直前ラウンドの発話全文**を提示し, 「他者の推論の誤りを指摘した上で, 自身の解答を更新 (または維持) せよ」と指示して回答を再生成する. 自己の過去発話は再提示せず, 各ラウンドは対話履歴を持たない独立の単一ターン呼び出しとして実装する. ラウンド数はラウンド追加が逆効果になるとの報告 [27] に基づき  $R \in \{1, 2\}$ , 既定  $R = 1$  とする.

各生成には温度  $\tau = 0.7 \cdot \text{top-p } 0.9$  のサンプリングを用い, 乱数シードはエージェント添字  $i$  とラウンド添字  $\rho$  に応じて  $\text{seed}' = \text{seed} \cdot 10^4 + 100i + \rho$  と系統的にずらす. これにより同一重み・同一プロンプトの構成 (第 4 章の温度サンプリング対照条件) でも初期回答の多様性が確保され, かつ全実行が再現可能になる.

**回答抽出と集約.** 各エージェントの最終ラウンド発話から, 厳密な書式指示 ANSWER: <値>に対する正規表現で最終回答を抽出する (抽出不能な発話は無効

票とする)。集約は**最終ラウンド回答の多数決**であり、同数の場合は候補を辞書順に整列した上でシード付き乱数により一様を選ぶ。

judge（審判）エージェントによる集約を採用しない根拠は二つある。第一に、MAD の性能利得の大半は議論そのものではなく多数決集約で説明されるという分析 [26]、および推論タスクでは合意形成プロトコルより投票が一貫して優れるという比較実験 [27] があり、集約規則としての多数決の優位が示されている。第二に、議論の最終決定を担うエージェントの判定能力がチーム性能を左右する（意思決定者がボトルネックとなる）ことが報告されており [116]、本研究のように 4B 級の小型モデルのみでチームを構成する設定では特に深刻である。また、言語化された確信度（confidence）は過信バイアスを持つため主集約には用いない。

なお  $|S| = 2$  の連合では多数決が常に同数となり得るため、実効的には「一致すればその回答、不一致ならシード付き乱数で一方を選択」という規則になる。これは Shapley 値算出（3.3 節）に必要な中間連合の評価としてプロトコルの一貫性を優先した設計である。

## 3.3 適応度関数

### 3.3.1 特性関数と厳密 Shapley 値

候補  $c$ （役割  $r$ ）の適応度の中核は、代表チーム文脈  $T(c) = \{c, \rho_1, \rho_2\}$ （ $\rho_1, \rho_2$  は他 2 役割の代表）上の**厳密 Shapley 値** [20] である：

$$\phi_c = \sum_{S \subseteq T(c) \setminus \{c\}} \frac{|S|!(n - |S| - 1)!}{n!} (v(S \cup \{c\}) - v(S)), \quad n = 3. \quad (3.5)$$

$n = 3$  を展開すると、係数は  $|S| = 0, 1, 2$  に対しそれぞれ  $\frac{1}{3}, \frac{1}{6}, \frac{1}{3}$  であり、

$$\begin{aligned} \phi_c = & \frac{1}{3}v(\{c\}) + \frac{1}{6}[v(\{c, \rho_1\}) - v(\{\rho_1\})] + \frac{1}{6}[v(\{c, \rho_2\}) - v(\{\rho_2\})] \\ & + \frac{1}{3}[v(T(c)) - v(\{\rho_1, \rho_2\})] \end{aligned} \quad (3.6)$$

となる。必要な特性関数値は 3 エージェントの全非空連合  $2^3 - 1 = 7$  個であり、本研究ではこれを**すべて実測**する。すなわち Monte Carlo 近似や Leave-One-Out (LOO) 近似 [22] を一切用いず、公理的に一意的な貢献配分を厳密に得る。エージェント数を 3 に限定した設計判断は、(i) Du らの標準構成であり奇数のため多数決

が機能しやすいこと, (ii)  $2^n$  に指数増加する連合評価が  $n = 3$  でのみ実測可能な規模に収まること, の二点による.

Shapley 値を採る理論的根拠は, 効率性 ( $\sum_i \phi_i = v(N) - v(\emptyset)$ )・対称性・null player・線形性の 4 公理を同時に満たす唯一の配分規則である点にある [20, 21]. 特に LOO 型の寄与度  $v(N) - v(N \setminus \{c\})$  は, 行動が同型な個体 (複製) が連合に共存すると双方に寄与 0 を割り当てるという既知の欠陥を持つ [21]. 進化計算では集団内に類似個体が発生しやすいため, この欠陥は選択圧を系統的に歪める. Shapley 値はすべての部分連合にわたる限界貢献の加重平均であるため複製に対しても頑健である.

また, 式 (3.6) の第 1 項が示すとおりの  $\phi_c$  は  $v(\{c\})$  (solo 精度) を重み  $\frac{1}{3}$  で内包する. したがって個体タスク性能を別項として適応度に加算する必要はなく, 「個体性能 + 協調寄与」が単一のスカラーに公理的に統合される. これが個体性能のみを適応度とする先行研究 (GENOME[13]) との本質的な差分であり, この差分はアブレーション A1 (適応度を  $v(\{c\})$  に置換) として直接検証可能な設計とした (実施状況は §4.3).

### 3.3.2 Fitness sharing と行動距離

Shapley 値のみを選択圧とすると, 役割内の個体が同一の行動様式に収束し, 進化の探索が早期に停滞する恐れがある. そこで Goldberg と Richardson の fitness sharing[23] による乗法ペナルティを導入する. 同役割サブ集団内の個体間の**行動距離**を, 適応度セット上の solo 予測の不一致率

$$d(c, c') = \frac{1}{|D_{\text{fit}}|} \sum_j \mathbf{1}[\hat{y}_j(c) \neq \hat{y}_j(c')] \quad (3.7)$$

( $\hat{y}_j(\cdot)$  は問題  $j$  に対する solo 抽出回答) と定義し, sharing 係数を

$$s(c) = \frac{1}{1 + \sum_{c' \in P_r^{(t)} \setminus \{c\}} \max\left(0, 1 - \frac{d(c, c')}{\sigma_{\text{share}}}\right)}, \quad \sigma_{\text{share}} = 0.3 \quad (3.8)$$

とする. 分母は  $c$  の属する niche の実効個体数 (niche count) であり, 行動距離が  $\sigma_{\text{share}}$  未満の同役割個体が近くに多いほど適応度が割り引かれる. 最終的な適応度は

$$F(c) = \phi_c \cdot s(c) \quad (3.9)$$

である．行動距離の計算に必要な solo 予測は Shapley 値算出時の単独連合評価 ( $v(\{c\})$  の実測) の副産物として得られるため，追加の推論コストは発生しない．重み空間のパラメータ距離ではなく行動空間の距離を用いるのは，LoRA の再パラメータ化不変性 (3.4.3 項) によりパラメータ距離が表現型の差を反映しないためである．

**重要な注意 (実装構成による選抜中立性)：** 本実験の役割内サブ集団は  $K = 2$  である (§3.4)．このとき式 (3.8) の和は相手 1 個体との距離のみからなり， $d(a, b) = d(b, a)$  の対称性から **2 個体の sharing 係数は常に同値**になる．乗法ペナルティは正の定数倍として順位を保存するため，役割内選抜 ( $\arg \max_c F(c)$ ) は Shapley 値のみの選抜と完全に一致する．すなわち **fitness sharing は  $K = 2$  の本構成では選抜に作用しない**．この帰結は執筆後の検証で判明したものであり，実際の進化ログにおける事後検証 (全 18 ケースで係数が役割内同値・選抜順位不変) を §4.6.6 に示す．sharing を設計意図どおり機能させるには  $K \geq 3$  が必要であり，本章の記述は「導入した設計」として残すが，実験結果の解釈において sharing の効果を主張することはできない．

### 3.3.3 多様性を加算しない設計判断

多様性の扱いとして「適応度 = 性能 +  $\lambda$  · 多様性」という加重和がしばしば用いられるが，本研究はこれを採用しない．根拠は二系統ある．第一に，Quality-Diversity 文献の中核である MAP-Elites[16] は，多様性を目的関数に加算するのではなく行動記述子による niche 分離 (アーカイブ) として性能最適化から構造的に分離すべきであると論じており，Novelty Search[117] 以来の知見として，加重和は探索の欺瞞性 (deception) を単に係数  $\lambda$  の調整問題にすり替えるに過ぎない．第二に，アンサンブル学習の統一理論 [17] は，多様性が bias · variance と並ぶ第三の項として汎化誤差分解に現れる**トレードオフの管理対象**であり，無条件に最大化・加算すべき量ではないことを数学的に示した．加重和はさらに，目的間のスケール不整合と係数の恣意性，非凸 Pareto 前線を表現できないという多目的最適化上の既知の限界 [118] も抱える．

そこで本研究は，(i) 選択圧そのものはチーム貢献  $\phi_c$  に一元化し，(ii) 多様性は fitness sharing の**乗法ペナルティ**として「同一 niche への密集」を抑制する形でのみ作用させる，という分離設計を採用．乗法形式は性能と多様性の単位の混合を避け， $\phi_c$  の順位構造を niche 内でのみ再調整する．ただし前項末尾に述べたとお

り、この設計は  $K = 2$  の本実験構成では選抜中立であり（アブレーション A2 の sharing 無効化も同構成では自明に無差になる）、多様性維持機構としての実効性の検証は  $K \geq 3$  での再実験に委ねられる。

## 3.4 進化アルゴリズム

### 3.4.1 協調的共進化の構造

全体構造は Potter と De Jong の協調的共進化 [19] に従い、3 役割それぞれに独立のサブ集団  $P_r^{(t)}$ （各  $K = 2$  個体、計 6 LoRA）を保持する。各候補の評価は 3.1.2 項の代表チーム文脈で行う。すなわち候補  $c$  は「他役割の現代表  $\rho_{r'}$  と組んだときにチームへどれだけ貢献するか」で測られ、役割間の相互適応がチームレベルの選択圧として実現される。代表を固定する評価方式は、Population Based Training[74] の exploit（良い個体の活用）に対応し、評価対象の組合せ爆発を防ぐ。

**初期化（世代 0）**．役割別 SFT データ（各 60 例）で QLoRA 学習した 3 個体を各役割の初期代表とし、さらに各個体に全テンソル対象のガウス突然変異（変異率  $\rho_{\text{mut}} = 1.0$ 、3.4.4 項と同一の相対ノイズ幅）を施した変異体を 1 個体ずつ加え、各役割  $K = 2$  の初期サブ集団を構成する。

### 3.4.2 選抜とエリート保存

世代  $t$  において、役割  $r$  の全候補の適応度  $F(c)$  を計算した後、役割内で最良の個体を次期代表に選ぶ:

$$\rho_r^{(t+1)} = \arg \max_{c \in P_r^{(t)}} F(c). \quad (3.10)$$

選ばれた代表は**エリート保存**により無変更のまま次世代サブ集団に残る。これは突然変異による劣化がチーム全体へ伝播することを防ぐための設計である。ただし候補の適応度は「他役割の**現代表**と組んだ文脈」で測られ、この評価文脈（他役割の代表と sharing の対象個体）は世代ごとに変わるため、エリート保存があっても代表系列の適応度の単調非減少は保証されない点に注意する（実測でも同一個体の測定チーム精度は世代間で  $\pm 4 \sim 7$ pt 変動した; §4.6.2）。

### 3.4.3 交叉: $\Delta W$ 空間ブレンドとランダム化SVD再分解

**交差項問題.** LoRA 個体の交叉として最も素朴なのは, 行列  $A, B$  を別々に線形補間する方式 (naive 方式) である:

$$A' = (1 - \alpha)A_1 + \alpha A_2, \quad B' = (1 - \alpha)B_1 + \alpha B_2. \quad (3.11)$$

しかしこのとき実効更新は

$$\Delta W_{\text{naive}} = B'A' = (1 - \alpha)^2 B_1 A_1 + \alpha^2 B_2 A_2 + \alpha(1 - \alpha)(B_1 A_2 + B_2 A_1) \quad (3.12)$$

となり, 意図した補間  $(1 - \alpha)\Delta W_1 + \alpha\Delta W_2$  とは一致しない. 両親の寄与が二乗係数で縮み ( $\alpha = 0.5$  で各 0.25), さらに意味を持たない交差項  $B_1 A_2, B_2 A_1$  が混入する. 加えて LoRA 分解には再パラメータ化の自由度があり, 任意の正則行列  $R$  に対して  $BA = (BR)(R^{-1}A)$  が同一の  $\Delta W$  を与えるため,  $A, B$  を別々に扱う演算は同一個体の等価な表現の間でも結果が変わってしまう. KnOTS[24] は, 独立に学習された LoRA 由来の  $\Delta W$  は互いの整合 (alignment) が低く, この種の素朴なパラメータ空間マージが性能劣化の主因になることを示している.

**提案する交叉 ( $\Delta W$  空間ブレンド + SVD 再分解).** 本研究の主方式は, 補間を再パラメータ化不変な  $\Delta W$  空間で行う. 各モジュール  $m$  について:

1. 実効更新行列を補間する:

$$\Delta W'^{(m)} = (1 - \alpha) B_1^{(m)} A_1^{(m)} + \alpha B_2^{(m)} A_2^{(m)}, \quad \alpha \sim \mathcal{U}(0.3, 0.7). \quad (3.13)$$

2.  $\Delta W'^{(m)}$  をランダム化SVD[119] (oversampling  $q = \min(r+8, \min(d_{\text{out}}, d_{\text{in}}))$ , power iteration 4 回) で分解し, 上位  $r$  成分  $U_r \Sigma_r V_r^\top$  に切り詰めて子の LoRA 行列対を再構成する:

$$B'^{(m)} = U_r \Sigma_r^{1/2}, \quad A'^{(m)} = \Sigma_r^{1/2} V_r^\top. \quad (3.14)$$

これにより子の実効更新  $B'A' = U_r \Sigma_r V_r^\top$  は, 補間された  $\Delta W'$  の Frobenius ノルム最良 rank- $r$  近似 (Eckart–Young の意味で, ランダム化SVDによる近似精度の範囲内) となり, 交差項の混入と再パラメータ化依存性の両方が排除される. 特異値の平方根を  $A, B$  に均等配分するのは, 両行列のスケールを揃え後続の突然変異ノイズ (テンソルの標準偏差に対する相対スケール) が偏らないようにするた

めである．親同士の rank と対象モジュール集合の一致は実行時に検証する．naive 方式は実装内に保持し，アブレーション A3 として比較可能な形にした．

**交叉の親選択．** 役割  $r$  の子は，次期代表  $\rho_r^{(t+1)}$  を第一親，同役割サブ集団の残余個体のうち適応度最良のものを第二親として生成する（ $K = 2$  では残余は 1 個体）．混合比  $\alpha$  は世代・役割ごとに  $\mathcal{U}(0.3, 0.7)$  から再抽出する．

### 3.4.4 ガウス突然変異

交叉で得た子アダプタの各テンソル  $W_k$  に対し，独立に確率  $\rho_{\text{mut}} = 0.3$  で加法的ガウスノイズを付加する：

$$W_k \leftarrow W_k + \varepsilon_k, \quad \varepsilon_k \sim \mathcal{N}(0, (\sigma_{\text{mut}} \cdot \text{std}(W_k))^2 I), \quad \sigma_{\text{mut}} = 0.02. \quad (3.15)$$

ノイズ幅を各テンソルの経験標準偏差  $\text{std}(W_k)$  に対する相対値とすることで，層・モジュールごとに大きく異なるパラメータスケールに自動適応する．突然変異はシード指定により完全に再現可能である．

### 3.4.5 世代ループ全体

以上を統合した手続きを Algorithm 1 に示す．世代数は  $G = 6$  とする．次世代サブ集団は各役割とも「エリート代表 1 + 交叉・突然変異による子 1」の  $K = 2$  構成である．

全個体は vLLM の動的 LoRA ロード API により同一サーバへ世代ごとに登録され，進化は勾配計算を一切伴わない（重み操作は交叉・突然変異のみ）．世代ごとの評価ログ（各候補の  $\phi_c$ ，solo 精度，チーム精度，全連合精度，sharing 距離，選抜結果）は JSON として逐次永続化され，Spot インスタンスのプリエンプション後も再開可能である．

## 3.5 計算量の分析

**連合評価数．** 本手法の支配的コストは LLM 推論による連合評価である．候補 1 個体あたり必要な連合は  $2^3 - 1 = 7$  だが，代表チーム文脈の構造上，多くの連合が候補間で共有される．世代内の連合評価キャッシュを用いると，代表のみからなる連合（solo 3 + 対 3 + 3 体 1 の計 7 個）は全候補で共有され，代表でない候補（各

---

**Algorithm 1** チームレベル Shapley 適応度による協調的共進化

---

**Require:** 役割別 SFT 済み LoRA  $\{x_r\}_{r \in \mathcal{R}}$ , 適応度セット  $D_{\text{fit}}$ , 世代数  $G$ , ラウンド数

$R, \sigma_{\text{share}}, \rho_{\text{mut}}, \sigma_{\text{mut}}$

**Ensure:** 最終世代の代表チーム  $\{\rho_r^{(G)}\}_{r \in \mathcal{R}}$

```
1: for  $r \in \mathcal{R}$  do
2:    $P_r \leftarrow \{x_r, \text{Mutate}(x_r; \rho=1.0, \sigma_{\text{mut}})\}$ ;  $\rho_r \leftarrow x_r$  { 世代 0 の初期化 }
3: end for
4: for  $t = 0, \dots, G - 1$  do
5:   連合評価 キャッシュ  $C \leftarrow \emptyset$ 
6:   for  $r \in \mathcal{R}, c \in P_r$  do
7:      $T(c) \leftarrow \{c\} \cup \{\rho_{r'} \mid r' \neq r\}$  { 適応度評価 }
8:     for all  $S \subseteq T(c), S \neq \emptyset$  do
9:       if  $S \notin C$  then
10:         $C[S] \leftarrow v(S)$  { debate/solo を実測 }
11:       end if
12:     end for
13:      $\phi_c \leftarrow \text{Shapley}(c, \{C[S]\})$  { 式 (3.5) }
14:   end for
15:   for  $r \in \mathcal{R}, c \in P_r$  do
16:      $d(c, c') \leftarrow \text{solo 予測不一致率 } (C \text{ の副産物})$  { fitness sharing }
17:      $F(c) \leftarrow \phi_c \cdot s(c)$  { 式 (3.8), 式 (3.9) }
18:   end for
19:   for  $r \in \mathcal{R}$  do
20:      $\rho_r \leftarrow \arg \max_{c \in P_r} F(c)$  { 選抜 (エリート保存) }
21:   end for
22:   if  $t < G - 1$  then
23:     for  $r \in \mathcal{R}$  do
24:        $p \leftarrow \arg \max_{c \in P_r \setminus \{\rho_r\}} F(c)$  { 次世代生成 }
25:        $\alpha \sim \mathcal{U}(0.3, 0.7)$ 
26:        $child \leftarrow \text{Mutate}(\text{DeltaBlendSVD}(\rho_r, p, \alpha); \rho_{\text{mut}}, \sigma_{\text{mut}})$ 
27:        $P_r \leftarrow \{\rho_r, child\}$ 
28:     end for
29:   end if
30: end for
31: return  $\{\rho_r\}_{r \in \mathcal{R}}$ 
```

---

役割の子，計  $m$  個体）だけが固有の連合（自身の solo 1，代表との対 2，3 体 1 の計 4 個）を追加する．したがって世代あたりの実評価数は

$$N_{\text{coal}} = 7 + 4m \quad (3.16)$$

であり， $K = 2$ （役割あたり非代表候補 1）では  $m = 3$ ， $N_{\text{coal}} = 19$  となる．キャッシュがなければ  $6 \times 7 = 42$  評価が必要であり，共有キャッシュにより約 55% が削減される．なおエリート代表自身も候補として評価されるが，その代表チーム文脈は代表のみの 7 連合と完全に一致するため追加コストを生まない．

**LLM 呼び出し数．** 連合  $S$  の 1 問題あたりの生成回数は  $|S| \cdot (R + 1)$ （round 0 +  $R$  ラウンド，各ラウンドで全員が 1 生成）である． $R = 1$ ， $N_{\text{fit}} = 100$  のとき，世代あたりの呼び出し数は

$$\underbrace{100 \times (3 \cdot 1 + 3 \cdot 4 + 1 \cdot 6)}_{\text{代表のみの 7 連合}} + \underbrace{3 \times 100 \times (1 \cdot 1 + 2 \cdot 4 + 1 \cdot 6)}_{\text{子 3 個体の固有 12 連合}} = 2,100 + 4,500 = 6,600 \quad (3.17)$$

であり， $G = 6$  世代の進化全体で約  $4.0 \times 10^4$  回（各生成は最大 512 トークン）となる．問題間は独立なため，クライアント側で問題単位に並列化（既定 16 並列）し，vLLM サーバの連続バッチングで吸収する．

**その他のコスト．** 厳密 Shapley 値の計算自体は  $n = 3$  の全部分集合和で  $O(2^n)$  だが  $n = 3$  では無視できる．fitness sharing の行動距離は solo 評価の per-item 予測を再利用するため追加推論はゼロである．交叉のランダム化 SVD は各モジュールの  $d_{\text{out}} \times d_{\text{in}}$  行列に対する rank- $(r + 8)$  分解であり，全体で CPU 数十秒程度と，推論コストに対して無視できる．進化全体で学習（勾配更新）は世代 0 の QLoRA 学習のみに限られる点が，RL による議論最適化（MAPoRL[12]）と対照的な本手法の計算的特徴である．

## 第4章 評価実験

本章では、第3章の提案手法を検証するための実装、ベンチマークと評価プロトコル、比較条件、統計設計、およびハイパーパラメータを述べる。本章の記述はすべて公開実装（`scripts/train_lora_persona.py`, `scripts/run_evolution.py`, `scripts/run_eval.py`, `scripts/run_eval_battery.py`, `scripts/cloud/`）と一致する。未実施の実験結果には言及しない。

### 4.1 実装

#### 4.1.1 ベースモデルと QLoRA 学習

ベースモデルには **Qwen3-4B-Instruct-2507**[18]（Apache-2.0, Hugging Face 上でゲートなし公開）を用いる。4B級を選ぶ理由は、(i) 同規模帯では「素の debate が性能を悪化させる」ことが報告されており [11, 10]、チームレベル選択圧が debate を機能させるかという研究課題の検証に適した困難条件であること、(ii) 公表ベンチマーク値（MMLU-Pro 69.6, SuperGPQA 42.8）に改善余地が残ること、(iii) 進化ループで多数の LoRA を単一 GPU 上に同時サービングできる計算規模であることによる。

世代0の3個体（critic / pragmatist / explorer）は、役割別 SFT データ（各60会話例, JSONL形式, チャットテンプレート適用）を用いた **QLoRA**[120] で学習する。設定は以下のとおりである。

- **量子化**: ベースモデルを 4bit NF4 (double quantization 有効) でロードし、計算 dtype は GPU に応じて bfloat16 (A100 等) または float16 (T4, compute capability 7.5 のため bf16 非対応) へ自動フォールバックする。
- **LoRA 構成**: rank  $r = 32$ ,  $\alpha_{\text{LoRA}} = 2r = 64$ , dropout 0.05, 対象モジュールは全層の q\_proj, k\_proj, v\_proj, o\_proj, gate\_proj, up\_proj, down\_proj の7種。

- **最適化:** 学習率  $2 \times 10^{-4}$ , エポック数 3 (Vertex AI ジョブ投入設定. 学習スクリプト単体の既定値は 1), デバイスあたりバッチサイズ 1, 勾配累積 16, `paged_adamw_32bit`, `gradient_checkpointing` 有効 (学習時は KV キャッシュを無効化して競合を回避), `packing` 無効.
- **再現性:** グローバルシード 1234 (Python / NumPy / PyTorch / CUDA を統一固定). 学習コマンド・シード・ハードウェア構成は `metadata.json` として成果物に同梱する.

各役割のペルソナは, SFT により重み空間に焼き込まれると同時に, 推論時にも短い役割記述 (例: 批判的検証者「厳密な検証を重視する批判的思考家. 反証・例外・境界条件に敏感」) をシステムプロンプトとして与える.

#### 4.1.2 vLLM Multi-LoRA サービング

全推論 (進化ループの連合評価・最終評価とも) は vLLM[121] の OpenAI 互換 API を通じて行う. サーバは `--enable-lora`, `--max_loras 8`, `--max_lora_rank 64`, `--max-model-len 32768`, `tensor` 並列 1 で起動し, ベースモデルを 1 つだけ GPU に常駐させたまま, リクエストの `model` フィールドで LoRA アダプタを問い合わせ単位に切り替える. 進化ループで世代ごとに生成される子アダプタは, 動的 LoRA ロード API (`/v1/load_lora_adapter`, `VLLM_ALLOW_RUNTIME_LORA_UPDATING=True`) でサーバ再起動なしに登録する.

生成パラメータは, 進化ループ内では `temperature 0.7`・`top-p 0.9`・最大 512 トークン, 最終評価では Qwen3 の公式推奨に従い `temperature 0.7`・`top-p 0.8`・`top-k 20`・最大 8,192 トークンとし, いずれもシード指定付きとする (エージェント × ラウンド, および Self-Consistency のサンプル添字ごとに決定的にオフセット. 第 3 章 3.2 節). 進化ループと最終評価で生成条件が異なる点は本研究の限界として第 5 章で述べる. クライアントは問題単位で 16 並列のリクエストを発行し, vLLM サーバ側の連続バッチングで GPU 利用率を確保する. API 呼び出しは最大 3 回の線形バックオフ付きリトライで保護する.

### 4.1.3 Vertex AI Spot 構成とプリエンブション耐性

計算は GCP Vertex AI Custom Training の **Spot**（プリエンブティブル）ジョブとして実行する（プロジェクトのクォータ上、オンデマンド GPU VM は利用不可）。工程ごとの構成を表 4.1 に示す。

表 4.1: Vertex AI Spot ジョブの工程別マシン構成

| 工程             | マシン構成                                             | 理由                                                                                     |
|----------------|---------------------------------------------------|----------------------------------------------------------------------------------------|
| QLoRA 学習（世代 0） | n1-standard-8 +<br>NVIDIA T4 ×1（Spot）             | 4bit 量子化により 6GB 級で学習可能。fp16 フォールバックで対応                                                 |
| 進化ループ／最終評価     | a2-highgpu-1g（A100<br>40GB ×1, Spot, us-central1） | vLLM の Multi-LoRA カーネル（Punica/Triton）が compute capability $\geq 8.0$ を要求し T4 では動作しないため |

成果物（アダプタ・評価 JSON・世代ログ）は GCS バケットに Cloud Storage FUSE マウント（/gcs/...）経由で保存する。Spot はいつでもプリエンブトされるため、すべての評価ランナーは**問題単位の逐次 JSONL キャッシュ**を持ち、再実行時には評価済み問題 ID をスキップして途中から再開する。最終評価は複数条件を 1 ジョブにまとめるバッチリードライバで実行し、完了済みエントリの JSON が存在すれば条件ごとスキップする。進化ループも世代ごとに全ログを JSON へ書き出し、任意の世代から再開可能である。

## 4.2 ベンチマークと評価プロトコル

### 4.2.1 ベンチマーク選定

最終評価は表 4.2 に示す 3 ベンチマークで行う。いずれも Hugging Face 上でゲートなしに取得できる（認証トークン不要の方針を維持する）。

GSM8K[126] はベースモデルで 80–92% と飽和しているため配管確認（スモークテスト）専用とし、主張には用いない。GPQA-Diamond[127] はデータセットが HF ゲート付きであるため不採用とする。

表 4.2: 最終評価に用いるベンチマーク

| ベンチマーク                       | 抽出方法              | 問題数 | 選定根拠                                                      |
|------------------------------|-------------------|-----|-----------------------------------------------------------|
| MMLU-Pro[122]                | test 分割から固定ランダム抽出 | 500 | ベースの公表値 69.6 で飽和しておらず, MAD による改善報告と接続可能. 10 択で当て推量の影響が小さい |
| MATH-500[123, 124] Level 4-5 | Level 4 以上に限定して抽出 | 200 | 数学推論は MAD の改善効果が最大と報告される領域. 高難度に限定して天井効果を回避               |
| SuperGPQA[125]               | 固定ランダム抽出          | 300 | ベースの公表値 42.8 と最も余地が大きい. 大学院水準の広分野知識推論                     |

#### 4.2.2 生成型評価と回答抽出

評価は lm-evaluation-harness 型の選択肢対数尤度方式ではなく, **生成型 (generative) 評価**で統一する. solo 条件と debate 条件を同一プロトコル・同一抽出口ジックで比較するためには, 両者とも自由生成テキストから回答を取り出す必要があるからである. 全エージェントに厳密な書式指示

Think step by step. Then give your final answer on the last line in exactly this format:

ANSWER: <letter | number | final simplified answer>

を与え, 出力末尾の ANSWER: 行を正規表現で最優先抽出する. ANSWER: 行が欠落した場合に限り, 文脈条件付きのフォールバック (選択肢タスクでは “answer is (X)” 等のパターン, 数値タスクでは最後の数値, 数式タスクでは最後の `\boxed{}`) を適用する. 数式回答は LaTeX 表記の正規化 (`\frac`→`/`, `\sqrt`→`sqrt()`), 数値の同値判定 (`12.0 = 12` 等) を経て比較する. 抽出不能な出力は無効票 (多数決から除外) とし, 単独評価では不正解として扱う. **すべての比較条件で同一の抽出・正規化・採点コードを共有し, 条件間の差が抽出ロジックの差に混入しないことを保証する.**

#### 4.2.3 進化ループ内の適応度セット

進化ループの選択圧 (第 3 章の  $v(S)$  計測) には, MMLU-Pro test 分割 (約 12,000 問) から専用シード (777) で抽出した**固定 100 問**を全世代共通で用いる. 100 問という規模は, tinyBenchmarks[112] が示した「キュレートされた 100 例でフルベンチマークのスコアを平均誤差約 2% で推定できる」という結果に基づく. 適応度

セットは世代間の順位付け専用であり、その絶対値は主張に用いない。最終評価とはシード系列を分離して抽出するため（最終評価はシード 1–3）、標本の系統的な共有はないが、母集合が共通のため偶発的な重複は起こりうる（期待重複は 500 問抽出あたり約 4 問、1%未満）。適応度セットへの選択圧の過適合（進化版の「テストへの学習」）が疑われる場合に備え、最終評価がこの 100 問を含まない形でも集計できるよう問題 ID を全ログに記録する。

## 4.3 比較条件

最終評価は表 4.3 に示す 8 条件で行う（研究設計書 §6.2 の条件 1–6 に、プロンプトペルソナの寄与を分離する条件 3' と実験 2 の条件 7<sup>‡</sup> を追加。設計書の条件 7 = solo 適応度進化 A1 は未実施）。全条件で同一の問題集合・同一シード・同一抽出ロジックを用い、問題単位で対応づけ（paired）が可能な設計とする。debate 条件のラウンド数は  $R = 1$  に統一する。

なお研究設計段階では solo 適応度への置換（A1）、fitness sharing 無効化（A2）、naive 交叉（A3）のアブレーションを計画し実行フラグとして実装したが（第 3 章参照）、実験 1 で進化の寄与自体が限定的（§4.6.1）と判明したため、計算資源を実験 2（処方箋の検証）に振り向け、これらは未実施である。この判断の含意は第 5 章で論じる。

## 4.4 統計設計

統計処理は Miller[105] の評価統計 5 原則（標準誤差の併記・クラスタ構造の考慮・リサンプルの扱い・paired 分析・検出力設計）に準拠する。

- **シードと反復**: 主要比較は  $K = 3$  シード (1, 2, 3) で反復する。各（シード、問題）対は両条件で同一の生成条件を共有するため、対応ありデータとして扱う。
- **主検定（クラスタ構造の考慮）**: 同一問題への複数シードの回答は関連する反復測定であり、（シード、問題）対を独立観測とみなしてプールする検定は独立性の仮定を満たさない [105]。そこで主解析は問題 ID をクラスタ単位とし、問題ごとにシード平均を取った精度差  $\Delta_i$  に対するクラスタ符号反転置

表 4.3: 最終評価の比較条件

| #              | 条件                          | 構成                                                         | 目的                                                                                                                                                                                                           |
|----------------|-----------------------------|------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1              | ベース solo CoT                | ベースモデル単体, ペルソナなし                                           | 絶対的な基準線                                                                                                                                                                                                      |
| 2              | <b>Self-Consistency@9</b>   | ベースモデルから 9 サンプル → 多数決 [8]                                  | 生成回数を揃えた非協調ベースライン. 3 エージェント × 最大 3 生成 (round 0 + 2 ラウンド) = 9 生成に相当. 既定 $R = 1$ では debate 側は 6 生成/問であり, SC@9 はベースライン側に生成回数で有利な保守的設定 (実測トークンでも SC@9 が総量で上回る; §4.6.6). 「MAD は計算量を揃えた SC に勝てない」という批判 [7] への直接の対処 |
| 3              | ベース ×3 温度サンプリング debate      | 同一ベースモデル 3 体 (ペルソナプロンプトなし, シードオフセットのみ)                     | サンプリング多様性のみの debate (Self-MoA 型対照)                                                                                                                                                                           |
| 3'             | ベース ×3 プロンプトペルソナ debate     | 同一ベースモデル 3 体 + 役割プロンプト                                     | プロンプトによるペルソナ付与の寄与を分離 (重み焼き込み vs プロンプトの対照)                                                                                                                                                                    |
| 4              | gen-0 LoRA チーム debate       | SFT 直後の 3 ペルソナ LoRA                                        | 進化前のチーム性能. 条件 5 との差が進化の寄与                                                                                                                                                                                    |
| 5              | <b>進化後チーム debate (主要条件)</b> | 提案手法 (Shapley + sharing, $G = 6$ 世代) の最終代表チーム              | 本研究の主張の中核                                                                                                                                                                                                    |
| 6              | 進化後 LoRA solo ×3            | 条件 5 の各個体を単独評価                                             | チーム効果 (協調による上乘せ) と個体改善の分離                                                                                                                                                                                    |
| 7 <sup>‡</sup> | 再学習チーム debate (実験 2)        | 能力保持リプレイで再学習した 3 ペルソナ LoRA + 条件付き更新 + 匿名化 + logprob 重み付き投票 | 実験 1 の診断 (§4.6.2) に基づく処方の検証. ゲート方式 (§4.6.3) で各構成要素を検収した上での最終形                                                                                                                                                |

換検定 (20,000 回) で  $p$  値を、クラスタブートストラップ (問題単位の再抽出, 10,000 回) で 95%信頼区間を求める. 参考値として (シード, 問題) 対プールの McNemar 正確検定 [106] も併記するが, その  $p$  値は反保守的であるため結論には用いない<sup>1</sup>.

- **同等性の主張:** 差の検定で有意でないことは同等性の証拠にならないため, 同等性を主張する場合は等価マージンを  $\pm 2\text{pt}$  (本研究で意味があるとみなす最小効果量より小さい値) と定義した TOST 型判定——クラスタブートストラップの 90%信頼区間が  $\pm 2\text{pt}$  に収まるか——を用いる.
- **多重比較補正:** 主要な仮説検定は各実験でプール比較 6 件とし, **Holm–Bonferroni 法** [107] で family-wise error rate を 5%に制御する. ベンチマーク別の内訳検定およびそれ以外の比較は探索的分析と位置づける.
- **頑健性確認:** 実験 2 の主検定 (条件 7<sup>‡</sup> vs SC@9) が 3 シードで境界的 ( $p = 0.053$ ) となったため, **効果の維持を確認する目的を事前に明記した上で** seed 4–6 を追加し, 3 シード単独と 6 シード合算の両方を報告する. このシード追加は結果を見た後の逐次的な標本拡大 (optional stopping) に該当するため, 6 シード合算の  $p$  値を確認的検定として扱うには本来逐次検定補正を要する. 本研究では補正を行わない代わりにこの経緯を明示し, かつ最終的な結論 (条件 7<sup>‡</sup> の有意な劣位) が標本拡大により**棄却側に不利な方向へ**確定した——すなわち optional stopping が偽陽性を利する典型的な構図とは逆である——ことを付記する.
- **開発と評価の分離:** 実験 2 の全ての設計選択 (リプレイ比率・集約方式・議論プロトコル) は, 最終評価と重複しない検収セット (seed 9) 上のゲート (§4.6.3) で確定してから最終評価に進んでおり, 最終評価セットへの適合を構造的に排除している.
- **検出可能効果量:** 対応あり検定 ( $\alpha = 0.05$ , 検出力 80%) の目安は  $+10\text{pt} \rightarrow N \approx 180$ ,  $+7\text{pt} \rightarrow N \approx 360$ ,  $+5\text{pt} \rightarrow N \approx 700$  である. 3 ベンチマーク統合 ( $N = 500 + 200 + 300 = 1,000$  問,  $K = 3$  シードによる分散低減を含

---

<sup>1</sup>初稿では (シード, 問題) プールの McNemar 検定を主解析としていたが, 反復測定の間接相関を無視する点が不適切であるため, 問題 ID クラスタリングを考慮した解析へ差し替えた. 有意性の判定はいずれの解析でも変わらなかった. なお両者は推定対象が僅かに異なる (プールは観測単位, クラスタ解析は問題単位の平均差) ため点推定値も僅かに異なる.

む) では+4~5pt 程度の効果が検出可能であり, Du らが報告する MAD の効果量 (7~15pt) に対して十分な感度を持つ.

- **実行記録と再現性の限界:** 全実行についてシード・モデル revision・vLLM バージョン・生成パラメータ・問題 ID リストを結果 JSON に記録する. ただし同一シードを指定しても vLLM の生成は並列実行状態に依存して完全には再現しない (§4.6.4) ため, これらの記録が担保するのは監査可能性であり, ビット単位の再現ではない.

議論品質の LLM-as-judge 評価と世代を通じた行動多様性の推移分析は副次評価として計画したが, 測定環境の統制 (§4.6.4) に伴う再測定を優先したため未実施である.

## 4.5 ハイパーパラメータ

以下の値はすべて実装のデフォルト値 (コマンドライン引数の既定値, および Vertex ジョブ投入スクリプトの設定値) と一致する. QLoRA 学習の設定を表 4.4 に, 議論・生成の設定を表 4.5 に, 進化ループの設定を表 4.6 に, 最終評価の設定を表 4.7 に, サービング・インフラの設定を表 4.8 に示す.

表 4.4: QLoRA 学習 (世代 0) のハイパーパラメータ

| 項目                                               | 値                                                         |
|--------------------------------------------------|-----------------------------------------------------------|
| ベースモデル                                           | Qwen/Qwen3-4B-Instruct-2507                               |
| 量子化                                              | 4bit NF4, double quantization, 計算 dtype bf16 (T4 では fp16) |
| LoRA rank $r$ / $\alpha_{\text{LoRA}}$ / dropout | 32 / 64 / 0.05                                            |
| 対象モジュール                                          | q, k, v, o, gate, up, down の各射影 (全層)                      |
| 学習率/エポック                                         | $2 \times 10^{-4}$ / 3 (Vertex 投入設定; スクリプト既定 1)           |
| バッチサイズ/勾配累積                                      | 1 / 16                                                    |
| 最適化器                                             | paged_adamw_32bit (gradient checkpointing 有効, packing 無効) |
| SFT データ                                          | 役割別 60 会話例 $\times$ 3 役割                                  |
| シード                                              | 1234                                                      |

表 4.5: 議論・生成のハイパーパラメータ

| 項目                           | 値                                                                                                       |
|------------------------------|---------------------------------------------------------------------------------------------------------|
| temperature / top-p / 最大トークン | 0.7 / 0.9 / 512                                                                                         |
| 議論ラウンド数 $R$                  | 1 (round 0 の独立回答 + 1 更新ラウンド)                                                                            |
| 集約                           | 最終ラウンド多数決 (同数はシード付き乱数, 無効票は除外)                                                                          |
| シードオフセット                     | エージェント $\times$ ラウンド: $\text{seed} \cdot 10^4 + 100i + \rho$ ;<br>SC サンプル: $\text{seed} \cdot 10^3 + k$ |
| クライアント並列数 / リトライ             | 16 / 3 回 (線形バックオフ)                                                                                      |

表 4.6: 進化ループのハイパーパラメータ

| 項目                                                  | 値                                                                 |
|-----------------------------------------------------|-------------------------------------------------------------------|
| 世代数 $G$                                             | 6                                                                 |
| サブ集団構成                                              | 3 役割 $\times K = 2$ (エリート + 子) = 6 LoRA                           |
| 適応度                                                 | 厳密 Shapley 値 $\times$ fitness sharing<br>(--fitness-mode shapley) |
| 適応度セット                                              | MMLU-Pro 100 問, シード 777 (最終評価とシード分離)                              |
| sharing $\sigma_{\text{share}}$                     | 0.3                                                               |
| 交叉                                                  | $\Delta W$ 空間ブレンド + ランダム化 SVD 再分解<br>(delta)                      |
| 混合比 $\alpha$                                        | $\mathcal{U}(0.3, 0.7)$ から世代・役割ごとに抽出                              |
| SVD                                                 | oversampling +8, power iteration 4 回, rank 32 に切詰め                |
| 突然変異率 $\rho_{\text{mut}}$ / 幅 $\sigma_{\text{mut}}$ | 0.3 / 0.02 (テンソル標準偏差に対する相対値)                                      |
| 世代 0 変異体                                            | $\rho_{\text{mut}} = 1.0$ , $\sigma_{\text{mut}} = 0.02$          |
| 進化シード                                               | 1234                                                              |

表 4.7: 最終評価の設定

| 項目               | 値                                                          |
|------------------|------------------------------------------------------------|
| ベンチマーク           | MMLU-Pro 500 / MATH-500 (Level 4–5) 200<br>/ SuperGPQA 300 |
| シード              | $K = 3$ (1, 2, 3. 問題抽出・生成・同数決着に<br>共通使用)                   |
| Self-Consistency | $k = 9$                                                    |
| bootstrap 反復     | $B = 10,000$                                               |
| 多重比較補正           | Holm–Bonferroni (各実験のプール比較 6 件)                            |

表 4.8: サービング・インフラの設定

| 項目       | 値                                                                                |
|----------|----------------------------------------------------------------------------------|
| vLLM     | --enable-lora --max_loras 8<br>--max_lora_rank 64 --max-model-len<br>32768, TP=1 |
| 動的ロード    | /v1/load_lora_adapter<br>(VLLM_ALLOW_RUNTIME_LORA_UPDATING=True)                 |
| 学習ジョブ    | Vertex AI Spot, n1-standard-8 + T4 ×1                                            |
| 進化・評価ジョブ | Vertex AI Spot, a2-highgpu-1g (A100 40GB<br>×1), us-central1                     |
| 成果物保存    | GCS (Cloud Storage FUSE マウント), 問題<br>単位 JSONL 逐次追記による再開設計                        |

実験 2 (再学習, §4.6.3) で表 4.4 から変更した項目を表 4.9 に示す。学習関連の変更は忘却の抑制 (rank・エポック・学習率の低減は LoRA の忘却がこれらとともに増加するという知見に基づく) とリプレイ長 CoT の切り捨て防止 (学習系列長) を, 議論・集約関連の変更は §4.6.3 の処方をそれぞれ目的とする。

表 4.9: 実験 2 の再学習で変更したハイパーパラメータ

| 項目                   | 実験 1 (世代 0)            | 実験 2 (再学習)                     |
|----------------------|------------------------|--------------------------------|
| 学習データ                | ペルソナ例 60 例             | ペルソナ例 60 例 + リプレイ 36 例 (約 30%) |
| LoRA rank / $\alpha$ | 32 / 64                | 16 / 32                        |
| エポック数                | 3                      | 2                              |
| 学習率                  | $2 \times 10^{-4}$     | $1 \times 10^{-4}$             |
| 学習系列長上限              | 1,024 トークン (フレームワーク既定) | 8,192 トークン                     |
| 議論の更新指示              | 標準 (自由更新)              | 条件付き (自己誤り特定時のみ変更可)            |
| 発言の提示                | 役割名付き                  | 匿名化 + 提示順シャッフル                 |
| チーム集約                | 多数決                    | logprob 重み付き投票                 |

## 4.6 実験結果

本節では実験を 2 段階に分けて報告する。**実験 1** は §4.3 の比較条件による主実験であり, チーム化の効果と進化的最適化の寄与を測定するとともに, 敗因の診断

(損失分解)を行う。実験2は実験1の診断に基づく処方(能力保持リプレイ・検証型集約・議論プロトコル改良)を、実測ゲート方式で検証する追加実験である。

#### 4.6.1 実験1: 主実験の結果

表4.10に全条件の精度( $K=3$ シード平均)を示す。いずれの条件も回答抽出失敗率は3%以下であり、条件間の非対称性はない。

表 4.10: 実験1の主要結果(精度,  $K=3$ シード平均)

| 条件                    | MMLU-Pro     | MATH-500     | SuperGPQA    |
|-----------------------|--------------|--------------|--------------|
| 1: ベース solo           | 0.639        | 0.830        | 0.436        |
| 2: Self-Consistency@9 | 0.667        | 0.862        | <b>0.467</b> |
| 3: 素の議論               | 0.598        | <b>0.870</b> | <b>0.467</b> |
| 3': プロンプトペルソナ議論       | 0.624        | 0.860        | 0.466        |
| 4: gen-0 LoRA チーム     | <b>0.684</b> | 0.770        | 0.407        |
| 5: 進化後 LoRA チーム       | 0.683        | 0.813        | 0.399        |
| 6: 進化後 solo 最良        | 0.661        | 0.698        | 0.364        |

主要な検定結果(問題IDクラスタの符号反転置換検定, §4.4)は以下のとおりである。

- **チーム化の効果(MMLU-Pro)**: LoRA ペルソナチーム(条件4)はベース単体に対し+4.3pt [+2.0, +6.6] ( $p=0.0004$ )、素の議論に対し+8.4pt 相当の有意な優位を示した。
- **生成回数を揃えた比較**: 進化後チーム(条件5)はSC@9に対しMMLU-Proで+1.6pt(非有意)だが、3ベンチマーク全体では-1.8pt [-3.5, -0.2] ( $p=0.028$ )と**有意に劣った**。
- **進化の寄与**: 条件5と条件4の差はMATH-500の+4.3pt [+1.9, +6.8] ( $p=0.0005$ )のみ有意で、全体では+0.2pt(非有意)であった。
- **ベンチマーク依存性**: 素の議論はMATH-500で+4.2pt ( $p=0.0003$ )・SuperGPQAで+3.1pt ( $p=0.020$ )と有意に有効だが、MMLU-Proでは-4.1pt ( $p=0.001$ )と有意に有害だった。

すなわち実験1の結論は「LoRA ペルソナチームは知識推論（MMLU-Pro）でのみ有効であり，生成回数を揃えた Self-Consistency には総合で及ばない」である．

#### 4.6.2 実験1の診断：損失分解

敗因を特定するため，各問題について「3体のうち少なくとも1体が正解した場合」（oracle 上限）を計算し，チーム誤差を（i）個体能力の損失，（ii）集約の損失に分解した（表 4.11）．

表 4.11: 損失分解（seed 1）：oracle 上限と集約損失

| ベンチマーク    | solo 平均 | oracle       | 多数決   | 議論後   | 集約損失   |
|-----------|---------|--------------|-------|-------|--------|
| SuperGPQA | 0.335   | <b>0.517</b> | 0.363 | 0.387 | -0.130 |
| MMLU-Pro  | 0.673   | 0.800        | 0.702 | 0.714 | -0.086 |
| MATH-500  | 0.667   | 0.815        | 0.705 | 0.810 | -0.005 |

全列 seed 1 の値．「多数決」は 3 体の solo 回答の多数決で，票が同数に割れた場合は固定シードの  
一様乱択でタイブレイクする．

3つの発見が得られた．第一に，**個体能力の毀損**である．ペルソナ SFT 後の solo 精度はベース単体に対し SuperGPQA で -7.2pt，MATH-500 の Level 5 層で -27pt 低下していた．診断用に収集した生成ログの分析から，ペルソナ SFT（平均 779 字の短い応答のみで学習）がベースモデルの思考連鎖を中央値 2,423 字から 1,188 字へ圧縮しており，長い導出を要する問題で選択的に失敗することが確認された．第二に，**集約の損失**である．SuperGPQA では毀損した 3 体ですら oracle 上限が 0.517 とベース単体（seed 1 で 0.407）を +11pt 上回るにもかかわらず，多数決＋議論はその 38.7% しか回収していない．正解が少数派に留まる問題では多数決は構造的に失敗するうえ，議論が正しい多数派を崩す事例も確認された（MMLU-Pro 500 問中，議論前に多数派が正解だった問題のうち 26 問が議論後に不正解へ転じた）．一方 MATH-500 では集約損失がほぼゼロであり，検証可能な領域では正しい解が議論を通じて自然に採択されることを示す．第三に，**選抜ノイズ**である．進化ログの再分析により，適応度セット 100 問での測定は標準誤差  $\pm 4.9$ pt を持ち，同一個体の測定チーム精度が世代間で  $\pm 4 \sim 7$ pt 変動していた．毎世代の最大値選抜はノイズの上振れを拾う正のバイアス（勝者の呪い）を持ち，開発セットでの +12pt の改善が最終評価で  $\pm 0$  に消えた現象を説明する．さらに進化前後のアダプタを直接比較すると， $\Delta W$  の Frobenius ノルム比は全役割で 1.000 であるだけでな

く、 $\Delta W$  同士の cosine 類似度も全役割・全 252 モジュールで 0.9996 以上（連結  $\Delta W$  で 0.9999–1.0001）であった．すなわち進化後の最終チームのアダプタは、重みとしては SFT 直後の gen-0 アダプタと実質的に同一である．演算子単位で測っても、突然変異 1 回で  $\cos = 0.9997$ ，交叉 1 回で  $\cos = 0.9998$ ，gen-1 から gen-5 までの 4 世代分でも  $\cos = 0.9998$  であり、本実験の進化演算子（ノルム保存の相対スケール変異と  $\alpha \in [0.3, 0.7]$  の内挿交叉）は重み空間をほとんど動かしていなかった．したがって MATH-500 で観測された進化の寄与 +4.3pt は、重み空間における意味のある移動（たとえば損傷成分の打ち消し）によるものとは考えにくく、固定された極小の重み摂動に対して生成過程が敏感に応答した結果——同一設定でも生成環境の違いにより +6pt 級の系統差が生じるという §4.6.4 の観察と同種の感度——として説明するのが最も保守的である（第 5 章で詳述）．

#### 4.6.3 実験 2: 処方の検証（ゲート方式）

実験 1 の診断に基づき、以下の処方を実測ゲート方式（各段階に事前定義した合格基準を設け、不合格の変更は採用しない）で検証した．

**G0（能力保持リプレイの生成）** ベースモデル自身に MATH 訓練 split Level 4–5 および MMLU-Pro 検証 split の問題を解かせ、正解が検証できた長い思考連鎖 36 例（平均 6,503 字）を採取した．

**G1（再学習と個体能力の検収）** 既存ペルソナ例 60 例にリプレイ 36 例（約 38%）を混合し、rank 16・2 エポック・学習率  $1 \times 10^{-4}$ ・系列長 8,192 トークンで 3 ペルソナを再学習した（run002）．solo 精度は MMLU-Pro 0.665–0.695，MATH-500 0.775–0.845，SuperGPQA 0.405–0.440 となり、全ベンチマークで事前基準（0.63/0.75/0.37）を満たした．**能力毀損は事前基準を満たす水準まで回復し、一部はベース単体を上回った．**

**G2（集約方式の選定）** 議論プロトコルに条件付き更新（自己の誤りを特定できた場合のみ回答変更を許可）と発言の匿名化を導入した上で、SuperGPQA 150 問で集約方式を比較した．結果は多数決 0.433・logprob 重み付き投票 0.440・GenSelect 型裁定 0.433 であり、重み付き投票を採用した（裁定型の上積みは確認されなかった）．

**G3 (チーム性能の確認)** 再学習チーム (以下**条件 7<sup>‡</sup>**: リプレイ再学習 × 条件付き議論 × 匿名化 × 重み付き投票) を seed 1 の 3 ベンチマークで評価し, MMLU-Pro 0.754 · MATH-500 0.855 · SuperGPQA 0.430 を得てゲートを通過した (この時点の比較対象は実験 1 の測定値であり, 後述 §4.6.4 の環境統制前である点に注意) .

#### 4.6.4 測定環境の系統差の発見と統制

実験 2 の初期評価 (条件 7<sup>‡</sup> を 3 シードで評価し実験 1 の測定値と比較) では, 条件 7<sup>‡</sup> が SC@9 をプールで +1.3pt 上回る ( $p = 0.053$ ; MMLU-Pro 単独では +5.5pt 相当) という境界的な結果が得られた. 効果の維持を確認する目的で seed 4–6 を追加したところ優位が消失し, さらに SC@9 の絶対精度がシード群間で不連続に変化する (MMLU-Pro で 0.66–0.69 → 0.71–0.76) という不自然なパターンが観察された. シード群の境界は評価用コンテナイメージの再ビルド時点と一致していた.

そこで同一問題・同一シード・同一生成設定で SC@9 を新旧両イメージで実行する統制実験を行った結果, **同一の 500 問に対し旧イメージ 0.688 ・新イメージ 0.752 と, イメージ差のみで +6pt 級の系統差が確認された** (予測の一致率は 86% に留まり, 生成自体が変化している). vLLM 本体のバージョンは固定 (v0.8.5) であり, 差はイメージ再ビルド時に更新された依存ライブラリに起因すると推定される. 興味深いことに, この系統差は**ベースモデルの素の生成に強く現れ (+8pt 級)**, **LoRA アダプタを適用した生成にはほとんど現れない** (旧チーム = 条件 5 の実験 1 進化後チームの MMLU-Pro は旧 0.714/新 0.712 とほぼ不変. 以下, 条件 5 を「旧チーム」, 条件 7<sup>‡</sup> を「再学習チーム」と呼ぶ) .

この発見を受け, 主要 4 条件 (ベース単体・SC@9・旧チーム・再学習チーム) を**新イメージに統一して全面的に再測定**し, 以降の比較はすべて同一環境の測定値のみで行う. なお実験 1 の内部比較 (§4.6.1–4.6.2) はすべて旧イメージ内の対応あり比較であるため結論は影響を受けないが, 実験 1 と実験 2 の数値の直接比較は不能である. また同一 seed を指定しても vLLM の生成は並列実行状態に依存して完全には再現しないことも確認しており, 評価インフラの再現性は小型 LLM 評価の系統誤差要因として軽視できない.

#### 4.6.5 実験 2: 最終評価（同一測定環境）

新イメージに統一した最終結果を表 4.12 に示す. SC@9 と条件 7<sup>‡</sup> は 6 シード (1–6), ベース単体と旧チームは 3 シード (1–3) で評価した.

表 4.12: 実験 2 の最終結果（同一測定環境, 精度）

| 条件                      | MMLU-Pro     | MATH-500     | SuperGPQA    | シード数 |
|-------------------------|--------------|--------------|--------------|------|
| 1: ベース単体                | 0.727        | 0.818        | 0.431        | 3    |
| 2: SC@9                 | <b>0.740</b> | <b>0.873</b> | <b>0.486</b> | 6    |
| 5: 進化後チーム（実験 1 の構成）     | 0.685        | 0.793        | 0.420        | 3    |
| 7 <sup>‡</sup> : 再学習チーム | 0.716        | 0.867        | 0.431        | 6    |

主要な検定結果（問題 ID クラスタの符号反転置換検定,  $[\cdot, \cdot]$  はクラスタブートストラップ 95%信頼区間, Holm 補正後いずれも判定不変）:

- **主検定（対 SC@9, 6 シード・固有問題 4,683 件）**: 条件 7<sup>‡</sup> は  $-3.49\text{pt}$   $[-4.50, -2.56]$  ( $p < 10^{-4}$ ) と**有意に劣った**. ベンチマーク別では MMLU-Pro  $-2.4\text{pt}$   $[-3.6, -1.3]$  ( $p = 0.0001$ ), MATH-500  $-0.8\text{pt}$   $[-2.4, +0.7]$  ( $p = 0.35$ , 差は検出されず), SuperGPQA  $-5.5\text{pt}$   $[-7.4, -3.7]$  ( $p < 10^{-4}$ ) である<sup>2</sup>.
- **処方の効果（対旧チーム, 3 シード・固有問題 2,584 件）**: 条件 7<sup>‡</sup> は旧チームに対し  $+2.68\text{pt}$   $[+1.23, +4.13]$  ( $p = 0.0003$ , Holm 補正後有意) と**一貫して優った** (MMLU-Pro  $+3.7\text{pt}$ ・MATH-500  $+6.1\text{pt}$ ・SuperGPQA  $\pm 0.0\text{pt}$ ). 診断に基づく処方（リプレイ再学習・条件付き議論・匿名化・重み付き投票）の効果は測定環境の統制後も頑健である.
- **対ベース単体**: 条件 7<sup>‡</sup> は  $-0.32\text{pt}$   $[-1.66, +1.04]$  ( $p = 0.65$ ) で差は検出されず, 事前定義した等価マージン  $\pm 2\text{pt}$  に対する同等性判定 (90%信頼区間  $[-1.47, +0.81] \subset \pm 2\text{pt}$ ) により**同等性が成立した**. 実験 1 で確認された「ペルソナ SFT チームの能力毀損」(旧チームはベースに  $-3.00\text{pt}$ ,  $p = 0.0001$  で有意に劣る) はベース水準まで回復している. ベンチマーク別では MATH-500 のみ  $+3.4\text{pt}$   $[+0.8, +6.0]$  ( $p = 0.010$ ) と有意に上回る.

<sup>2</sup>参考: (シード, 問題) プールの McNemar 正確検定では  $-2.98\text{pt}$  (勝ち 223 問, 負け 402 問,  $p < 10^{-6}$ ). 点推定の差はクラスタ解析が各問題を等重み平均するのに対しプールが各観測を等重み平均することによる.

なお「MATH-500でSC@9と同等」という表現については、差は検出されなかったものの90%信頼区間 $[-2.13, +0.45]$ の下限が等価マージン $-2\text{pt}$ をわずかに超えるため、**同等性は未確定**である（差がないとも $2\text{pt}$ 以上劣るとも断定できない）。

計算量の観点では、条件7<sup>‡</sup>は1問あたり6生成とSC@9の9生成より少ないが、議論の第2ラウンドは他エージェントの発話全文を入力に含むため入力トークン数は生成回数に比例しない。実トークン数の集計は§4.6.6に示す。本比較は「生成回数がより少ない相手に負けた」ことを示すが、厳密な compute-matched 比較（総トークン・GPU時間の一致）ではない点に注意されたい。実験2の到達点は「処方によりチームをベース単体と同等（数学では有意に優位）まで回復させたが、生成回数マッチの Self-Consistency には及ばない」である。

#### 4.6.6 追加分析: sharing の事後検証・カテゴリ別効果・計算量の 実測

査読的観点からの再検証として、以下の3つの追加分析を行った。

(a) **fitness sharing の事後検証** — 本実験の構成では選抜に作用しなかった §3.3 の fitness sharing は、役割内サブ集団が  $K = 2$  の場合、行動距離の対称性 ( $d(a, b) = d(b, a)$ ) により2個体の sharing 係数が常に同値となり、 $\arg \max_c \phi_c s(c) = \arg \max_c \phi_c$ , すなわち**役割内選抜に一切影響しない**。進化ログの全記録（6世代 $\times$ 3役割 = 18ケース）を検証した結果、係数は全ケースで役割内同値であり、raw 適応度（Shapley 値）による順位と sharing 適用後の順位は完全に一致していた。さらに18ケース中16ケースでは行動距離が niche 半径  $\sigma_{\text{share}} = 0.3$  を超えており、係数自体が1.0（割引の不発動）であった。したがって**本実験で実際に働いた選択圧は Shapley 値のみ**であり、「fitness sharing により多様性を維持した」という設計意図は  $K = 2$  の構成では機能していない。この設計上の欠陥は本研究の重要な反省点であり、sharing を有効に作用させるには  $K \geq 3$  のサブ集団が必要である（Shapley 値は負になり得るため、その場合は非負化など sharing との整合にも別途注意を要する）。

(b) **MMLU-Pro のカテゴリ別分析** — 「検証可能性」仮説はベンチマーク内では**再現しない**。実験1で観察された議論効果の反転（MATH-500・SuperGPQA で正、MMLU-Pro で負）を「検証可能な領域では議論が有効」と解釈できるかを検証するため、MMLU-Pro の14分野を定量系（math, physics, chemistry, engineering,

computer science: 検算可能性が高い) と知識系 (law, history, philosophy 等) に事後的に分け、問題 ID クラスタ解析で素の議論 (条件 3) のベース比の効果を分野別に測定した。結果は仮説の予測と**一致しなかった**: 定量系  $-3.4\text{pt}$  ( $p = 0.11$ )・知識系  $-4.7\text{pt}$  ( $p = 0.002$ ) でグループ間差は非有意 ( $p = 0.61$ ) であり、特に MMLU-Pro の math カテゴリでは議論により  $-9.3\text{pt}$  ( $p = 0.04$ ) と**悪化**した (MATH-500 では  $+4.2\text{pt}$  の改善であるにもかかわらず)。すなわち、実験 1 で観察された反転は問題内容の「検証可能性」よりも**ベンチマーク単位の特性** (出題形式・難易度分布・選択肢の有無などの複合) に結びついており、本論文の「検証可能性による統一的説明」は**ベンチマーク間の観察に基づく仮説の域を出ない**。この分析はカテゴリ分けを事後に定義した探索的なものであるが、仮説の適用限界を示す証拠として報告する。

(c) 計算量の実測 — 「生成回数マッチ」の実態 「生成回数を揃えた比較は compute-matched と言えるのか」という疑問に答えるため、LLM 呼び出しの完全記録 (入力メッセージ全文と生成全文) から、新環境の全呼び出しについて Qwen3-4B の実トークナイズで入出力トークン数を集計した (表 4.13)。議論の第 2 ラウンドは他エージェントの発話全文を入力に含むため、条件 7<sup>‡</sup> の入力 は SC@9 の約 5 倍に達する。一方、自己回帰生成の計算コストを支配する**出力トークンは SC@9 が約 2.8 倍多く**、入出力合計でも SC@9 (18,419 トークン/問) が条件 7<sup>‡</sup> (15,804 トークン/問) を上回った。したがって本比較は厳密な compute-matched ではないものの、**チーム側が計算量の点で優遇されていた比較ではなく**、SC@9 は総トークンでもチームを上回る強いベースラインであった。本論文では両条件の関係を「生成回数を揃えた比較 (チーム 6 生成 < SC@9 の 9 生成)」と表現し、トークン実測値を上記のとおり併記する。

表 4.13: 計算量の実測 (新環境・1 問あたり平均トークン数)

| 条件                                  | 呼び出し数 | 入力トークン | 出力トークン | 合計     |
|-------------------------------------|-------|--------|--------|--------|
| 7 <sup>‡</sup> : 再学習チーム (議論 2 ラウンド) | 6.0   | 9,925  | 5,879  | 15,804 |
| 2: SC@9                             | 9.0   | 1,955  | 16,464 | 18,419 |

条件 7<sup>‡</sup> は 6 シード 6,000 問 (36,000 呼び出し) の平均。SC@9 は条件 2 のみを含むジョブ

(recheck・robust, 計 3,500 問・31,500 呼び出し、ベンチマーク構成比は本評価と同一) の平均。

## 第5章 考察

### 5.1 実験結果の解釈: 議論の効果は2軸のトレードオフで決まる

実験1の最も重要な発見は、マルチエージェント議論の効果が単一の符号を持たず、ベンチマークによって系統的に反転することである。素の議論は MATH-500 で +4.2pt・SuperGPQA で +3.1pt と有意に有効だが、MMLU-Pro では -4.1pt と有意に有害だった（いずれも問題 ID クラスタ解析; §4.4）。逆に LoRA ペルソナチームは MMLU-Pro でのみ有効だった。この対照は、議論チームの性能を (i) **多様性の利得**（異なる推論経路が正解を発見する確率の向上）と (ii) **個体能力の毀損**（ペルソナ注入が支払うコスト）という2軸のトレードオフとして整理すると一貫して説明できる。

MMLU-Pro のような知識推論では、温度サンプリングだけでは推論経路の多様性が乏しく（実験1で素の議論はベース単体より悪化）、重みに焼き込まれたペルソナが供給する視点の多様性が利得をもたらす。一方でペルソナ SFT の能力毀損は比較的軽微であり、差し引きで正となる。MATH-500 や SuperGPQA のような長い導出を要する領域では、多様性は温度サンプリングでも十分に確保できる（素の議論や SC@9 が強い）一方、SFT による能力毀損が致命的となり、差し引きが負に転じる。

この整理は先行研究間の見かけ上の矛盾（「議論は多数決に劣る」とする報告と「議論が小型モデルで有効」とする報告の併存）を説明しうる。特に MATH-500 における素の議論の有意な効果は、「議論単体は信念のマルチンゲールを誘導し期待正解率を改善しない」という近年の定理的整理 [26] が少なくとも MATH-500 というベンチマークでは成り立たないことを示す反例である。この反転の機構として本論文は「検証可能な問題では他者の解の正誤を自己検算でき、信念更新が訂正方向へ偏る」という**検証可能性仮説**を提示し、MATH-500 の集約損失がほぼゼロである観察（表 4.11）はこれと整合する。ただし §4.6.6 のカテゴリ別分析が示す

とおり、この仮説は MMLU-Pro 内部の定量系カテゴリでは再現しなかった (math カテゴリではむしろ  $-9.3\text{pt}$  の悪化)。したがって本研究のデータから直接支持されるのは「効果がベンチマーク単位で反転する」ことまでであり、反転を規定する要因が問題内容の検証可能性なのか、出題形式 (選択肢の有無)・難易度分布・出力長などベンチマーク構成の複合なのかの分離は今後の課題である。

## 5.2 損失分解が導いた処方とその効果

実験 1 の診断 (§4.6.2) はチームの誤差を個体能力損失と集約損失に分解し、それぞれに対応する処方を実験 2 で検証した。

**能力毀損の機構と修復。** ペルソナ SFT がベースモデルの思考連鎖を半分以下 (中央値  $2,423$  字  $\rightarrow 1,188$  字) に圧縮していたという生成ログの観察は、毀損の主因が「短い応答スタイルの刷り込みによる長い導出能力の選択的破壊」であることを示す。これは SFT データとモデル分布のギャップが忘却を生むという近年の知見と整合する。処方としてベースモデル自身が生成した検証済みの長い思考連鎖 (平均  $6,503$  字) を約 38% 混合して再学習したところ、solo 精度は 3 ベンチマークすべてで基準を満たし、一部はベース単体を上回った (G1)。再学習チームは旧チームを同一測定環境で MMLU-Pro  $+3.7\text{pt}$ ・MATH-500  $+6.1\text{pt}$  上回った。ただし本研究はペルソナ間の行動多様性の直接測定 (回答不一致率の推移など) を最終評価では実施していないため、「多様性を保ったまま能力を回復した」とまでは主張できない——ここで言えるのはチームとしての性能が回復したことである。なお再学習は、リプレイデータの追加と同時に rank ( $32 \rightarrow 16$ )・学習率・エポック数・系列長 ( $1,024 \rightarrow 8,192$ ) も変更しており、回復のどこまでがリプレイ自体の寄与かは分離できていない (交絡; §5.5)。

**集約損失と検証型集約。** SuperGPQA では 3 体のうち少なくとも 1 体が正解している問題が 51.7% あるにもかかわらず、多数決+議論は 38.7% しか回収していなかった。logprob に基づく重み付き投票は  $+0.7\text{pt}$  の改善に留まり、比較選択型の裁定 (GenSelect 型) は上積みを示さなかった (G2)。集約損失の大部分は依然として未回収であり、「正解が少数派である問題」の回収は 4B 級では未解決の課題として残る。なお実験 2 で solo 能力が修復された結果、議論後に票が割れる問題自体が減少したため、集約改善の寄与余地が実験 1 の見積もりより縮小した点には注意が必要である。

**条件付き更新と匿名化.**「自己の推論に具体的な誤りを特定できた場合のみ回答変更を許す」条件付き更新はパイロットで +1.0pt (非有意) と小さいが悪化のない効果を示し、発言の匿名化と併せて採用した. これらは追従 (sycophancy) による正解の破壊——実験 1 では 500 問中 26 問で正しい多数派が議論後に崩壊していた——への対処であり、議論の信念更新を訂正方向へ偏らせる介入として位置づけられる.

### 5.3 進化的最適化の再解釈: 選抜ではなく修復

本研究の当初の中心仮説は「チームレベル適応度 (厳密 Shapley 値) による選択圧が協調的な個体を選抜する」であった. 実験 1 の結果はこの仮説を支持しない. 進化の寄与は MATH-500 の +4.3pt (有意) のみで、選抜対象とした MMLU-Pro ではゼロだった. さらに機構分析 (§4.6.2) は当初の想定より根本的な問題を明らかにした. 進化前後の LoRA の  $\Delta W$  は Frobenius ノルム比 1.000 に加え **cosine 類似度 0.9997–1.0000 でほぼ同一**であり、突然変異 1 回あたり  $\cos = 0.9997$ , 交叉 1 回あたり  $\cos = 0.9998$  しか重みを動かしていなかった. すなわち本実験の進化は**重み空間の探索としてほとんど機能しておらず**, 6 世代を通じて初期個体の極近傍に閉じていた. 初稿では「ノルム保存の下での方向回転が損傷成分を打ち消した (修復機構)」と解釈したが, cosine 解析によりこの解釈は**棄却**される——方向は回転していなかった. MATH-500 の +4.3pt は, 固定された極小の重み摂動に対する生成過程の敏感な応答 (評価環境の違いだけで +6pt 級の系統差が生じるという §4.6.4 の観察と同種の感度) として説明するのが最も保守的であり, 重み空間における意味のある「修復」があったとは言えない.

この帰結を選抜ノイズ・sharing 無効の検証と合わせると, 本実験の進化ループは三重の機能不全を抱えていたことになる. (i) **探索の不全**: 進化演算子の実効摂動が極小で, 候補間に意味のある差が生成されていなかった. (ii) **多様性圧の不全**: fitness sharing は  $K = 2$  構成で選抜中立だった (§4.6.6). (iii) **選抜の不全**: 適応度 100 問の標準誤差  $\pm 4.9\text{pt}$  の下での毎世代最大値選抜は 1~2pt 差の真の優劣を判別できず (必要問題数の試算は 1 判断あたり約 2,600 問), 開発セット上の見かけの改善 (+12pt) は勝者の呪いとして説明される. 重要なのは, これらがいずれも**実装・設計パラメータの不備**であって, チームレベル適応度という枠組み自体の反証ではないことである. 本研究が実証的に示せたのは「本実装は枠組みの有効性を

検証できる状態になかった」までであり、枠組みの検証には変異幅の拡大・ $K \geq 3$  のサブ集団・識別力の高い適応度セット（IRT 型の問題厳選や逐次半減法）を備えた再実験、および solo 適応度・ランダム選抜との対照（アブレーション A1）が必要である。一方、能力回復という目的に対しては実験 2 のリプレイ再学習が確実に機能した（再学習チームは進化後チームをクラスタ解析で +2.7pt 上回る）ため、本研究では処方 of 検証を優先した。

## 5.4 Self-Consistency との比較の最終形

生成回数を揃えた Self-Consistency (SC@9) は本研究を通じて最強のベースラインであり続け、測定環境を統一した最終評価では、診断に基づく処方を尽くした再学習チームですら -3.5pt [-4.5, -2.6] (問題 ID クラスタ解析,  $p < 10^{-4}$ ) と有意に及ばなかった。「評価設計を厳密にすると MAD の優位は消える」という批判 [7] を、(i) 生成回数を揃えた比較（トークン実測では SC@9 の方が総トークンで多く、チーム側が計算量で優遇された比較ではない; §4.6.6）、(ii) 問題 ID クラスタリングを考慮した対応あり検定と多重比較補正、(iii) 能力毀損の回復と集約改善という対策の実施、(iv) 測定環境の統制、のすべてを満たした上で確認した結果であり、本研究で最も統制の効いた知見である。

敗因の構造は明快である。SC@9 の強さは「同一分布からの独立な 9 サンプルの多数決」がもたらす分散削減にあり、ベース単体 (1 サンプル) に対して +2.8pt ( $p < 10^{-4}$ ) を安定して稼ぐ。一方チーム議論は 6 生成をペルソナ 3 体 × 2 ラウンドに配分するため、独立サンプル数では 3 にすぎず、議論による情報交換がその差を埋める必要がある。実験 2 の集約改善後もこのギャップは埋まらなかった。例外は MATH-500 であり、チームと SC@9 の差は検出されず (-0.8pt,  $p = 0.35$ 。ただし 90% 信頼区間 [-2.13, +0.45] の下限が等価マージン -2pt をわずかに超えるため同等性は未確定)、ベース単体には +3.4pt ( $p = 0.010$ ) と有意に優る。MATH-500 では議論の 1 ラウンドが誤答の訂正として機能し、少ないサンプル数をほぼ補償したことを示す。

なお実験 2 の途中経過（測定環境の統制前）では「チームが SC@9 を MMLU-Pro で +5.5pt 上回る」という結果が一時得られたが、これは評価イメージ間の系統差 (§4.6.4) の産物であった。系統差はベースモデルの素の生成に選択的に現れ LoRA 適用時にはほぼ現れないため、ベース系条件だけが過小評価され、チーム側が見

かけ上優位になるという質の悪いバイアスを生む。マルチエージェント議論の評価においてベースライン測定の環境同一性がいかに重要かを示す事例である。

## 5.5 本研究の限界

- **規模の限界:** 3 エージェント・単一モデル系列 (Qwen3-4B)・3 ベンチマークでの結果であり、より大きなモデルや異種モデル混成チームへの一般化は未検証である。特に「能力毀損」はベースモデルの事後学習の質に依存するため、モデル系列が変われば定量関係は変わりうる。
- **実験 1 と実験 2 の数値の非互換:** 評価イメージ間の系統差 (§4.6.4) により、実験 1 (旧環境) と実験 2 (新環境) の絶対値は直接比較できない。実験 1 の内部比較 (領域依存性・損失分解) と実験 2 の内部比較 (処方の効果・対 SC@9) はそれぞれ同一環境内の対応あり比較として有効だが、例えば「実験 1 の素の議論と実験 2 の再学習チーム」のような環境跨ぎの比較は本論文では行っていない。
- **シード数の非対称:** 最終評価は SC@9 と再学習チームが 6 シード、ベース単体と旧チームが 3 シードであり、後者を含む検定は検出力がやや低い。
- **進化ループの機能不全:** 実験 1 の進化は、(i) 進化演算子の実効摂動が極小 ( $\Delta W$  の cosine 類似度 0.9997 以上)、(ii) fitness sharing が  $K = 2$  で選抜中立、(iii) 適応度測定の標準誤差  $\pm 4.9\text{pt}$  に対し候補間差が小さい、という三重の機能不全を抱えていた (§5.3)。したがって本研究は「チームレベル適応度による進化」の有効性を支持も反証もできていない。変異幅の拡大・ $K \geq 3$ ・識別力厳選と逐次半減法を備えた再実験 (設計は研究設計書 v3 §3.4 として保存)、および solo 適応度・ランダム選抜との対照 (A1) が必要である。
- **進化ループの生成条件:** 進化ループは最大 512 トークン・top-p 0.9 の旧生成設定で実行されており、最終評価 (8,192 トークン・top-p 0.8) と生成条件が異なる。ループ内部の比較は全個体で条件が揃っているため公正だが、進化時と評価時の挙動差は残る。
- **未実施のアブレーション:** solo 適応度進化 (A1) 等は計算資源の制約から未実施であり、チームレベル適応度の寄与の直接分離は今後の課題である。A2

(sharing 無効化) は  $K = 2$  構成では自明に無差となるため、そもそも本構成では検証不能であった。

- **リプレイ再学習の交絡:** 実験 2 の再学習はリプレイデータの追加と同時に rank・学習率・エポック数・系列長も変更しており、能力回復のどこまでがリプレイ自体の寄与かは分離できない。「思考連鎖の圧縮が能力毀損の原因」という機構の説明も、圧縮と精度低下の相関および圧縮解消と精度回復の同時観察に基づく仮説であり、因果の単離実験（リプレイのみを変えた対照）は行っていない。
- **検証可能性仮説の適用限界:** 議論効果の反転を「問題の検証可能性」で説明する解釈は、ベンチマーク間の観察とは整合するが MMLU-Pro 内部のカテゴリ別分析では再現しなかった (§4.6.6)。本研究のデータが直接支持するのは「ベンチマーク依存の反転」までである。
- **評価領域:** 全ベンチマークが英語の選択式・短答式であり、生成型タスクや日本語タスクへの外的妥当性は限定的である。

## 第6章 結論

### 6.1 まとめ

本研究は、4B 級小型言語モデルに LoRA でペルソナを焼き込んだ 3 体のエージェント集団を構成し、議論によるチーム推論とその進化的最適化を、計算量を揃えた Self-Consistency という厳しい基準に対して検証した。得られた知見は以下の 4 点に要約される。

第一に、議論の効果はベンチマーク依存であり、「多様性の利得」と「ペルソナ注入による能力毀損」の 2 軸のトレードオフとして整理できる。素の議論は数学 (MATH-500, +4.2pt) と高難度科学 (SuperGPQA, +3.1pt) で有意に有効だが知識推論 (MMLU-Pro, -4.1pt) で有意に有害であり、重みペルソナチームはその逆の符号を示した。この反転は「議論は多数決に勝てない」とする近年の理論的整理と「小型モデルでも議論が効く」とする報告の併存を説明しうる。ただし反転を「問題の検証可能性」に帰する解釈は仮説にとどまる——MMLU-Pro 内部のカテゴリ別分析 (§4.6.6) では定量系カテゴリでも議論は有効化せず、反転の規定要因がベンチマーク構成 (形式・難易度・選択肢の有無) の複合である可能性を排除できない。

第二に、チーム誤差は個体能力損失と集約損失に分解でき、それぞれに実効的な処方が存在する。ペルソナ SFT は短い応答スタイルの刷り込みによって思考連鎖を半減させ長い導出能力を選択的に破壊していたが、ベースモデル自身が生成した検証済み長 CoT のリプレイ混合 (約 38%) を含む再学習によりベース水準 (等価マージン  $\pm 2$ pt の同等性が成立) まで回復し、一部はベース単体を上回った (ただし再学習では rank・学習率等も同時に変更しており、リプレイ単独の寄与は分離できていない)。集約損失 (正解を持つ個体の答えをチームが採用できない損失, 最大 13pt) に対しては、logprob 重み付き投票・条件付き更新・発言匿名化が小幅の改善を与えたが、大部分は未回収の課題として残る。

第三に、チームレベル適応度による進化的最適化は、本実験の実装では機能す

る状態になかった。進化前後の  $\Delta W$  はノルム比 1.000 かつ cosine 類似度 0.9997–1.0000 でほぼ同一であり、進化演算子は重み空間をほとんど動かしていなかった（探索の不全）。fitness sharing は  $K = 2$  構成で選抜中立であり（多様性圧の不全）、適応度測定の標準誤差（100 問で  $\pm 4.9\text{pt}$ ）に起因する勝者の呪いが選抜を無情報化していた（選抜の不全）。開発セットでの見かけの改善（+12pt）は最終評価に汎化せず、MATH-500 で観測された +4.3pt も極小の重み摂動に対する生成過程の感度として説明するのが最も保守的である。したがって本研究は枠組み自体の有効性を支持も反証もしておらず、能力回復という目的にはリプレイ再学習が確実な処方であった。

第四に、診断に基づく処方（リプレイ再学習 × 条件付き議論 × 匿名化 × 重み付き投票）を実測ゲート方式で積み上げた最終チームは、測定環境を統一した最終評価において旧チームに +2.7pt（問題 ID クラスタ解析,  $p = 0.0003$ ）と有意に優り、ペルソナ SFT が生んだ能力毀損をベース単体との同等性（等価マージン  $\pm 2\text{pt}$ ）が成立する水準（MATH-500 では +3.4pt 有意優位）まで回復させた。しかし生成回数を揃えた SC@9 には  $-3.5\text{pt}$  ( $p < 10^{-4}$ ) と有意に及ばず、「対策を尽くしても 4B 級のチーム議論は同等の生成予算の多数サンプリングに勝てない」という統制された負の結果が本研究の主結論である。付随して、評価コンテナイメージ間の系統差（同一設定で +6pt 級、ベース素生成に選択的に作用しチーム側を見かけ上優位にするバイアス）を検出・統制した過程は、小型 LLM 評価の再現性に対する方法論的警鐘である。

## 6.2 今後の課題

- **サンプリングと議論のハイブリッド**: 本研究のチームは 1 問あたり 6 生成と SC@9 より少ない計算量で比較したが、各エージェントがまず Self-Consistency@3 で自己集約してから議論する構成（3 体 × 3 サンプル = 9 生成）は SC@9 と計算量が完全に一致し、独立サンプルの分散削減と議論の誤り訂正を同時に得られる可能性がある。本研究の実測（チーム化ゲインと集約損失の分解値）に基づけば、これが 4B 級で SC@9 に到達しうる残された最有力の設計である。
- **集約損失の本格的な回収**: oracle 上限との差は依然大きい。検証器の学習（RLVR による集約器訓練）や、正解が少数派の問題を対象とした再帰的自

己集約の導入が有望である。

- **選抜として機能する進化の再検証:** 識別力の高い問題の厳選（IRT ベースの縮約評価）と逐次半減法により選抜ノイズを抑えた上で，チームレベル適応度が誤り相関の低い個体を選抜できるかを検証すること．本研究で保存した設計（研究設計書 v3 §3.4）が出発点となる．
- **エージェント数と役割設計の拡張:**  $n > 3$  への拡張（Shapley 値の近似計算），および「性格」ではなく「推論戦略」（順方向導出・逆方向検証・具体例代入）としてのペルソナ設計の検証．
- **ペルソナ注入方式の比較:** 重み SFT・プロンプト・activation steering の3方式を能力毀損と多様性利得の2軸上で直接比較し，領域に応じた注入方式の選択則を確立すること．
- **異種モデル混成と大規模化:** 異なるベースモデルの混成チームや，より大きなモデル規模での2軸トレードオフの定量関係の検証．

# 謝辞

本研究が順調に展開できたのは、指導教員の余俊助教から提供いただいた実験環境と貴重な指導、また、研究室全員からはいろいろな貴重なご意見をいただいた。心から感謝します。

## 参考文献

- [1] Junyou Li et al. More agents is all you need. *Transactions on Machine Learning Research*, 2024. arXiv:2402.05120.
- [2] Huan-ang Gao et al. A survey of self-evolving agents: What, when, how, and where to evolve on the path to artificial super intelligence. *Transactions on Machine Learning Research*, 2026. arXiv:2507.21046.
- [3] Jinyuan Fang et al. A comprehensive survey of self-evolving AI agents: A new paradigm bridging foundation models and lifelong agentic systems. arXiv:2508.07407, 2025.
- [4] Edward J. Hu et al. LoRA: Low-rank adaptation of large language models. arXiv:2106.09685 (ICLR 2022), 2021.
- [5] Yilun Du, Shuang Li, Antonio Torralba, Joshua B. Tenenbaum, and Igor Mordatch. Improving factuality and reasoning in language models through multiagent debate. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2305.14325.
- [6] Tian Liang et al. Encouraging divergent thinking in large language models through multi-agent debate. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2024. arXiv:2305.19118.
- [7] Andries Smit, Paul Duckworth, Nathan Grinsztajn, Thomas D. Barrett, and Arnu Pretorius. Should we be going MAD? A look at multi-agent debate strategies for LLMs. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2311.17371.
- [8] Xuezhi Wang et al. Self-consistency improves chain of thought reasoning in language models. In *Proceedings of the 11th International Conference on Learning Representations (ICLR)*, 2023. arXiv:2203.11171.
- [9] Andrea Wynn, Harsh Satija, and Gillian Hadfield. Talk isn’t always cheap: Understanding failure modes in multi-agent debate. arXiv:2509.05396, 2025. ICML 2025 MAS Workshop.
- [10] Blaž Bertalanč and Carolina Fortuna. The cost of consensus: Isolated self-correction prevails over unguided homogeneous multi-agent debate. arXiv:2605.00914, 2026. ACM Conference on AI and Agentic Systems.
- [11] Hangfan Zhang, Zhiyao Cui, Jianhao Chen, Xinrun Wang, Qiaosheng Zhang, Zhen Wang, Dinghao Wu, and Shuyue Hu. Stop overvaluing multi-agent debate — we must rethink evaluation and embrace model heterogeneity. arXiv:2502.08788, 2025.

- [12] Chanwoo Park, Seungju Han, Xingzhi Guo, Asuman Ozdaglar, Kaiqing Zhang, and Joo-Kyung Kim. MAPoRL: Multi-agent post-co-training for collaborative large language models with reinforcement learning. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2025. arXiv:2502.18439.
- [13] Yiqun Zhang, Peng Ye, Xiaocui Yang, Shi Feng, Shufei Zhang, Lei Bai, Wanli Ouyang, and Shuyue Hu. Nature-inspired population-based evolution of large language models. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 44187–44205, 2026. DOI: 10.18653/v1/2026.acl-long.2044, arXiv:2503.01155.
- [14] Roger Creus Castanyer, Geoffrey Bradway, Lorenz Wolf, Maxwell Lin, Augustine N. Mavor-Parker, and Matthew James Sargent. PopuLoRA: Co-evolving LLM populations for reasoning self-play. arXiv:2605.16727, 2026.
- [15] Anders Krogh and Jesper Vedelsby. Neural network ensembles, cross validation, and active learning. In *Advances in Neural Information Processing Systems 7 (NeurIPS)*, 1995.
- [16] Jean-Baptiste Mouret and Jeff Clune. Illuminating search spaces by mapping elites. arXiv:1504.04909, 2015.
- [17] Danny Wood, Tingting Mu, Andrew Webb, Henry Reeve, Mikel Luján, and Gavin Brown. A unified theory of diversity in ensemble learning. *Journal of Machine Learning Research*, 24, 2023. arXiv:2301.03962.
- [18] Qwen Team. Qwen3 technical report. arXiv:2505.09388, 2025.
- [19] Mitchell A. Potter and Kenneth A. De Jong. A cooperative coevolutionary approach to function optimization. In *Parallel Problem Solving from Nature (PPSN III)*. Springer, 1994.
- [20] Lloyd S. Shapley. A value for  $n$ -person games. In *Contributions to the Theory of Games II*. Princeton University Press, 1953.
- [21] Amirata Ghorbani and James Zou. Data Shapley: Equitable valuation of data for machine learning. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019. arXiv:1904.02868.
- [22] Benedek Rozemberczki et al. The Shapley value in machine learning. In *Proceedings of the 31st International Joint Conference on Artificial Intelligence (IJCAI), Survey Track*, 2022.
- [23] David E. Goldberg and Jon Richardson. Genetic algorithms with sharing for multimodal function optimization. In *Proceedings of the 2nd International Conference on Genetic Algorithms (ICGA)*, 1987.
- [24] George Stoica, Pratik Ramesh, Boglarka Ecsedi, Leshem Choshen, and Judy Hoffman. Model merging with SVD to tie the Knots. In *Proceedings of the 13th International Conference on Learning Representations (ICLR)*, 2025. arXiv:2410.19735 (KnOTS).
- [25] Iliya Mirzaei. Sample more, reflect less: Self-refine and reflexion lose to repeated sampling at equal token cost, from 1.5B to 7B. arXiv:2607.28576, 2026.

- [26] Hyeong Kyu Choi, Xiaojin Zhu, and Sharon Li. Debate or vote: Which yields better decisions in multi-agent large language models? In *Advances in Neural Information Processing Systems 38 (NeurIPS)*, 2025. arXiv:2508.17536, NeurIPS 2025 Spotlight.
- [27] Lars Benedikt Kaesberg, Jonas Becker, Jan Philip Wahle, Terry Ruas, and Bela Gipp. Voting or consensus? Decision-Making in multi-agent debate. In *Findings of the Association for Computational Linguistics: ACL 2025*, 2025. arXiv:2502.19130.
- [28] Quim Motger, Marc Oriol, Jordi Marco, and Xavier Franch. Multi-agent debate strategies: Survey, taxonomy, and challenges. arXiv:2607.26212, 2026.
- [29] Jintian Zhang, Xin Xu, Ningyu Zhang, Ruibo Liu, Bryan Hooi, and Shumin Deng. Exploring collaboration mechanisms for LLM agents: A social psychology view. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024. arXiv:2310.02124.
- [30] Haolun Wu, Zhenkun Li, and Lingyao Li. Can LLM agents really debate? A controlled study of multi-agent debate in logical reasoning. arXiv:2511.07784, 2025.
- [31] Maya Okawa. Emergence of biased consensus in multi-agent LLM debates. In *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, 2026. arXiv:2608.02827.
- [32] Aneesh Pappu, Batu El, Hancheng Cao, Carmelo di Nolfo, Yanchao Sun, Meng Cao, and James Zou. Multi-agent teams hold experts back. In *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, 2026. arXiv:2602.01011.
- [33] Yexiang Liu, Jie Cao, Zekun Li, Ran He, and Tieniu Tan. Breaking mental set to improve reasoning through diverse multi-agent debate. In *Proceedings of the 13th International Conference on Learning Representations (ICLR)*, 2025.
- [34] Justin Chih-Yao Chen, Swarnadeep Saha, and Mohit Bansal. ReConcile: Round-table conference improves reasoning via consensus among diverse LLMs. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2024. arXiv:2309.13007.
- [35] Xiaochen Zhu, Caiqi Zhang, Yizhou Chi, Tom Stafford, Nigel Collier, and Andreas Vlachos. Demystifying multi-agent debate: The role of confidence and diversity. arXiv:2601.19921, 2026.
- [36] Wenzhe Li, Yong Lin, Mengzhou Xia, and Chi Jin. Rethinking mixture-of-agents: Is mixing different large language models beneficial? arXiv:2502.00674, 2025.
- [37] Shubham Toshniwal, Ivan Sorokin, Aleksander Ficek, Ivan Moshkov, and Igor Gitman. GenSelect: A generative approach to best-of-N. arXiv:2507.17797, 2025. 2nd AI for Math Workshop at ICML 2025.
- [38] Siddarth Venkatraman, Vineet Jain, Sarthak Mittal, Vedant Shah, Johan Obando-Ceron, Yoshua Bengio, Brian R. Bartoldson, Bhavya Kailkhura, Guillaume Lajoie, Glen Berseth, Nikolay Malkin, and Moksh Jain. Recursive self-aggregation unlocks deep thinking in large language models. arXiv:2509.26626, 2025.

- [39] Guiv Farmanfarmaian. Selection, recombination, or a fresh solve? A candidate-free control for single-pass test-time aggregation. *arXiv:2608.18379*, 2026. COLM 2026 Workshop on Efficient Reasoning.
- [40] Carolina Fortuna and Blaž Bertalanč. Multi-agent scaling across disjunctive and compensatory tasks. *arXiv:2609.31563*, 2026.
- [41] Mingqian Zheng, Jiaxin Pei, Lajanugen Logeswaran, Moontae Lee, and David Jurgens. When “a helpful assistant” is not really helpful: Personas in system prompts do not improve performances of large language models. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, 2024. *arXiv:2311.10054*.
- [42] Junseok Kim, Nakyeong Yang, and Kyomin Jung. Persona is a double-edged sword: Mitigating the negative impact of role-playing prompts in zero-shot reasoning tasks. *arXiv:2408.08631*, 2024.
- [43] Zizhao Hu, Mohammad Rostami, and Jesse Thomason. Expert personas improve LLM alignment but damage accuracy: Bootstrapping intent-based persona routing with PRISM. *arXiv:2603.18507*, 2026.
- [44] Zhenhailong Wang, Shaoguang Mao, Wenshan Wu, Tao Ge, Furu Wei, and Heng Ji. Unleashing the emergent cognitive synergy in large language models: A task-solving agent through multi-persona self-collaboration. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, 2024. *arXiv:2307.05300*.
- [45] Aryan Keluskar, Amrita Bhattacharjee, and Huan Liu. When does personality composition matter for multi-agent LLM teams? In *Proceedings of the Conference on Language Modeling (COLM)*, 2026. *arXiv:2606.27443*.
- [46] Luke Baines et al. Persona cartography: Charting language model personality traits in weight space. *arXiv:2607.07916*, 2026.
- [47] R. Meredith Belbin. *Management Teams: Why They Succeed or Fail*. Heinemann, 1981.
- [48] R. Meredith Belbin. *Team Roles at Work*. Butterworth-Heinemann, 1993.
- [49] Adrian Furnham, Howard Steele, and David Pendleton. A psychometric assessment of the Belbin team-role self-perception inventory. *Journal of Occupational and Organizational Psychology*, 66(3):245–257, 1993. DOI: 10.1111/j.2044-8325.1993.tb00535.x.
- [50] Barbara Senior. Team roles and team performance: Is there ‘really’ a link? *Journal of Occupational and Organizational Psychology*, 70(3):241–258, 1997. DOI: 10.1111/j.2044-8325.1997.tb00646.x.
- [51] Aitor Aritzeta, Stephen Swailes, and Barbara Senior. Belbin’s team role model: Development, validity and applications for team building. *Journal of Management Studies*, 44(1):96–118, 2007. DOI: 10.1111/j.1467-6486.2007.00666.x.
- [52] Edward de Bono. *Six Thinking Hats*. Little, Brown, 1985.
- [53] Lu Hong and Scott E. Page. Groups of diverse problem solvers can outperform groups of high-ability problem solvers. *Proceedings of the National Academy of Sciences*, 101(46):16385–16389, 2004. DOI: 10.1073/pnas.0403723101.

- [54] Abigail Thompson. Does diversity trump ability? An example of the misuse of mathematics in the social sciences. *Notices of the American Mathematical Society*, 61(9):1024–1030, 2014.
- [55] Daniel Kuehn. Diversity, ability, and democracy: A note on Thompson’s challenge to Hong and Page. *Critical Review*, 29(1):72–87, 2017. DOI: 10.1080/08913811.2017.1288455.
- [56] Miao Zhang, Junsik Kim, Siyuan Xiang, Jian Gao, and Cheng Cao. Dynamic role assignment for multi-agent debate. arXiv:2601.17152, 2026.
- [57] Zijun Liu, Yanzhe Zhang, Peng Li, Yang Liu, and Diyi Yang. A dynamic LLM-powered agent network for task-oriented agent collaboration. In *Proceedings of the 1st Conference on Language Modeling (COLM)*, 2024. arXiv:2310.02170 (DyLAN).
- [58] Siyu Yuan, Kaitao Song, Jiangjie Chen, Xu Tan, Dongsheng Li, and Deqing Yang. EvoAgent: Towards automatic multi-agent generation via evolutionary algorithms. In *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics (NAACL)*, 2025. arXiv:2406.14228.
- [59] Han Zhou, Xingchen Wan, Ruoxi Sun, Hamid Palangi, Shariq Iqbal, Ivan Vulić, Anna Korhonen, and Serkan Ö. Arik. Multi-agent design: Optimizing agents with better prompts and topologies. In *Proceedings of the 14th International Conference on Learning Representations (ICLR)*, 2026. arXiv:2502.02533.
- [60] Yuntong Hu, Yuting Zhang, Matthew Trager, Yi Zhang, Shuo Yang, Wei Xia, and Stefano Soatto. EvoMAS: Evolutionary generation of multi-agent systems. In *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, 2026. arXiv:2602.06511.
- [61] Huaixiu Steven Zheng, Swaroop Mishra, Xinyun Chen, Heng-Tze Cheng, Ed H. Chi, Quoc V. Le, and Denny Zhou. Take a step back: Evoking reasoning via abstraction in large language models. In *Proceedings of the 12th International Conference on Learning Representations (ICLR)*, 2024. arXiv:2310.06117.
- [62] Lei Wang, Wanyu Xu, Yihuai Lan, Zhiqiang Hu, Yunshi Lan, Roy Ka-Wei Lee, and Ee-Peng Lim. Plan-and-solve prompting: Improving zero-shot chain-of-thought reasoning by large language models. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (ACL)*, 2023. arXiv:2305.04091.
- [63] Denny Zhou, Nathanael Schärli, Le Hou, Jason Wei, Nathan Scales, Xuezhi Wang, Dale Schuurmans, Claire Cui, Olivier Bousquet, Quoc Le, and Ed Chi. Least-to-most prompting enables complex reasoning in large language models. In *Proceedings of the 11th International Conference on Learning Representations (ICLR)*, 2023. arXiv:2205.10625.
- [64] Yixuan Weng, Minjun Zhu, Fei Xia, Bin Li, Shizhu He, Shengping Liu, Bin Sun, Kang Liu, and Jun Zhao. Large language models are better reasoners with self-verification. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, 2023. arXiv:2212.09561.
- [65] Michihiro Yasunaga, Xinyun Chen, Yujia Li, Panupong Pasupat, Jure Leskovec, Percy Liang, Ed H. Chi, and Denny Zhou. Large language models as analogical reasoners. In *Proceedings of the 12th International Conference on Learning Representations (ICLR)*, 2024. arXiv:2310.01714.

- [66] Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah D. Goodman. STaR: Bootstrapping reasoning with reasoning. In *Advances in Neural Information Processing Systems 35 (NeurIPS)*, 2022. arXiv:2203.14465.
- [67] Zheng Yuan, Hongyi Yuan, Chengpeng Li, Guanting Dong, Keming Lu, Chuanqi Tan, Chang Zhou, and Jingren Zhou. Scaling relationship on learning mathematical reasoning with large language models. arXiv:2308.01825, 2023.
- [68] Vighnesh Subramaniam, Yilun Du, Joshua B. Tenenbaum, Antonio Torralba, Shuang Li, and Igor Mordatch. Multiagent finetuning: Self improvement with diverse reasoning chains. In *Proceedings of the 13th International Conference on Learning Representations (ICLR)*, 2025. arXiv:2501.05707.
- [69] Ankur Samanta, Akshayaa Magesh, Runzhe Wu, Ayush Jain, Youliang Yu, Daniel Jiang, Boris Vidolov, Paul Sajda, Yonathan Efroni, and Kaveh Hassani. Self-improvement of language models by post-training on multi-agent debate. arXiv:2509.15172, 2025.
- [70] John Gkountouras, Josip Jukić, and Ivan Titov. Consensus as privileged context for label-free self-distillation. arXiv:2607.13643, 2026.
- [71] Chenxi Liu, Yanshuo Chen, Ruibo Chen, Tianyi Xiong, Tong Zheng, and Heng Huang. Learning from self-debate: Preparing reasoning models for multi-agent debate. arXiv:2601.22297, 2026.
- [72] Martino M. L. Pulici, Cuong Xuan Chu, Evgeny Kharlamov, Zifeng Ding, Volker Tresp, and Yunpu Ma. MADA-RL: Multi-agent debate-aware reinforcement learning for parameter-efficient reasoning in compact models. arXiv:2607.18006, 2026.
- [73] Darrell Whitley, V. Scott Gordon, and Keith Mathias. Lamarckian evolution, the Baldwin effect and function optimization. In *Parallel Problem Solving from Nature (PPSN III)*, volume 866 of *Lecture Notes in Computer Science*, pages 5–15. Springer, 1994. DOI: 10.1007/3-540-58484-6\_245.
- [74] Max Jaderberg et al. Population based training of neural networks. arXiv:1711.09846, 2017.
- [75] Robert Boyd and Peter J. Richerson. *Culture and the Evolutionary Process*. University of Chicago Press, 1985.
- [76] Takuya Akiba, Makoto Shing, Yujin Tang, Qi Sun, and David Ha. Evolutionary optimization of model merging recipes. *Nature Machine Intelligence*, 2025. arXiv:2403.13187.
- [77] Chengsong Huang et al. LoraHub: Efficient cross-task generalization via dynamic LoRA composition. In *Proceedings of the 1st Conference on Language Modeling (COLM)*, 2024. arXiv:2307.13269.
- [78] Shangbin Feng et al. Model swarms: Collaborative search to adapt LLM experts via swarm intelligence. In *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, 2025. arXiv:2410.11163.
- [79] Dongxin Guo, Jikun Wu, and Siu Ming Yiu. EvoPref: Multi-objective evolutionary optimization discovers diverse LLM alignments beyond gradient descent. arXiv:2605.09777, 2026.

- [80] Xin Qiu, Yulu Gan, Conor F. Hayes, Qiyao Liang, Yinggan Xu, Roberto Dailey, Elliot Meyerson, Babak Hodjat, and Risto Miikkulainen. Evolution strategies at scale: LLM fine-tuning beyond reinforcement learning. In *Proceedings of the 43rd International Conference on Machine Learning (ICML)*, 2026. arXiv:2509.24372.
- [81] Shangbin Feng, Zifeng Wang, Palash Goyal, Yike Wang, Weijia Shi, Huang Xia, Hamid Palangi, Luke Zettlemoyer, Yulia Tsvetkov, Chen-Yu Lee, and Tomas Pfister. Heterogeneous swarms: Jointly optimizing model roles and weights for multi-LLM systems. In *Advances in Neural Information Processing Systems 38 (NeurIPS)*, 2025. arXiv:2502.04510.
- [82] Andrew Dai, Boris Meinardus, Ciaran Regan, Yingtao Tian, and Yujin Tang. Discovering novel LLM experts via task-capability coevolution. In *Proceedings of the 14th International Conference on Learning Representations (ICLR)*, 2026. arXiv:2604.14969.
- [83] So Kuroki, Taishi Nakamura, Takuya Akiba, and Yujin Tang. Agent skill acquisition for large language models via CycleQD. In *Proceedings of the 13th International Conference on Learning Representations (ICLR)*, 2025. arXiv:2410.14735.
- [84] Mitchell Wortsman et al. Model soups: Averaging weights of multiple fine-tuned models improves accuracy without increasing inference time. In *Proceedings of the 39th International Conference on Machine Learning (ICML)*, 2022. arXiv:2203.05482.
- [85] Gabriel Ilharco et al. Editing models with task arithmetic. In *Proceedings of the 11th International Conference on Learning Representations (ICLR)*, 2023. arXiv:2212.04089.
- [86] Prateek Yadav et al. TIES-Merging: Resolving interference when merging models. In *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. arXiv:2306.01708.
- [87] Le Yu et al. Language models are super mario: Absorbing abilities from homologous models as a free lunch. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2311.03099 (DARE).
- [88] Enneng Yang, Li Shen, Guibing Guo, Xingwei Wang, Xiaochun Cao, Jie Zhang, and Dacheng Tao. Model merging in LLMs, MLLMs, and beyond: Methods, theories, applications, and opportunities. *ACM Computing Surveys*, 2026. arXiv:2408.07666, DOI: 10.1145/3787849.
- [89] Zhan Zhuang, Xiequn Wang, Wei Li, Yulong Zhang, Qiushi Huang, Shuhao Chen, Xuehao Wang, Yanbin Wei, Yuhe Nie, Kede Ma, Yu Zhang, and Ying Wei. Come together, but not right now: A progressive strategy to boost low-rank adaptation. In *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, 2025. arXiv:2506.05713.
- [90] Alejandro R. Salamanca, Ahmet Üstün, Nicki Skafte Detlefsen, and Tim Dettmers. Seeded LoRA: Collaborative fine-tuning through seed initialization of adapters. In *ICML 2024 Workshop on Efficient Systems for Foundation Models (ES-FoMo II)*, 2024. OpenReview: U3UtvOYMiW.
- [91] John F. Banzhaf, III. Weighted voting doesn't work: A mathematical analysis. *Rutgers Law Review*, 19:317–343, 1965.
- [92] Jiachen T. Wang and Ruoxi Jia. Data Banzhaf: A robust data valuation framework for machine learning. In *Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2023. arXiv:2205.15466.

- [93] David H. Wolpert and Kagan Tumer. An introduction to collective intelligence. arXiv:cs/9908014, 1999.
- [94] Adrian K. Agogino and Kagan Tumer. Efficient evaluation functions for evolving coordination. *Evolutionary Computation*, 16(2):257–288, 2008.
- [95] Jakob Foerster et al. Counterfactual multi-agent policy gradients. In *Proceedings of the 32nd AAAI Conference on Artificial Intelligence*, 2018. arXiv:1705.08926 (COMA).
- [96] Catherine Rodriguez and James Ghawaly, Jr. Co-evolved spiking neural network ensembles via marginal contribution fitness. arXiv:2606.13985, 2026. ACM International Conference on Neuromorphic Systems (ICONS) 2026.
- [97] R. Paul Wiegand, William C. Liles, and Kenneth A. De Jong. An empirical analysis of collaboration methods in cooperative coevolutionary algorithms. In *Proceedings of the Genetic and Evolutionary Computation Conference (GECCO)*, pages 1235–1242, 2001.
- [98] Liviu Panait, Sean Luke, and R. Paul Wiegand. Biasing coevolutionary search for optimal multiagent behaviors. *IEEE Transactions on Evolutionary Computation*, 10(6):629–645, 2006.
- [99] Yanming Li et al. Who deserves the reward? SHARP: Shapley credit-based optimization for multi-agent system. arXiv:2602.08335, 2026.
- [100] Yanjun Chen, Yirong Sun, Hanlin Wang, Jinghan Wang, Xinming Zhang, Xiaoyu Shen, Wenjie Li, and Wei Zhang. The trace is the state: Exact credit assignment for LLM agent teams. arXiv:2603.06859, 2026.
- [101] Mingyu Lu, Yushan Huang, Chris Lin, and Su-In Lee. Agents that matter: Optimizing multi-agent LLMs via removal-based attribution. arXiv:2605.27621v1, 2026. Later versions are titled “Agents that Matter: How Subtle Choices Shape Agent Attribution in Multi-Agent Systems”.
- [102] Yichi Zhang, Kevin Lu, Yuang Zhang, Jie Gao, Lirong Xia, and Fang-Yi Yu. Mixture of complementary agents for robust LLM ensemble. arXiv:2605.24048, 2026.
- [103] Rich Caruana, Alexandru Niculescu-Mizil, Geoff Crew, and Alex Ksikes. Ensemble selection from libraries of models. In *Proceedings of the 21st International Conference on Machine Learning (ICML)*, 2004.
- [104] Donghwan Kim. Are diversity metrics measuring diversity? A capability-controlled audit of majority-vote gain in LLM ensembles. arXiv:2607.20768, 2026.
- [105] Evan Miller. Adding error bars to evals: A statistical approach to language model evaluations. arXiv:2411.00640, 2024.
- [106] Rotem Dror, Gili Baumer, Segev Shlomov, and Roi Reichart. The hitchhiker’s guide to testing statistical significance in natural language processing. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2018.
- [107] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 1979.
- [108] Sida Wang. Measuring all the noises of LLM evals. arXiv:2512.21326, 2025.

- [109] Yaochu Jin and Jürgen Branke. Evolutionary optimization in uncertain environments—a survey. *IEEE Transactions on Evolutionary Computation*, 9(3):303–317, 2005.
- [110] Pratyusha Rakshit, Amit Konar, and Swagatam Das. Noisy evolutionary optimization algorithms – a comprehensive survey. *Swarm and Evolutionary Computation*, 33:18–45, 2017.
- [111] Yang Xu, Jiefu Zhang, Haixiang Sun, Zihan Zhou, Tianyu Cao, and Vaneet Aggarwal. Towards reliable LLM evaluation: Correcting the winner’s curse in adaptive benchmarking. arXiv:2605.05973, 2026.
- [112] Felipe Maia Polo et al. tinyBenchmarks: Evaluating LLMs with fewer examples. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2402.14992.
- [113] Liam Cooper, Shinnung Jeong, Hyeran Jeon, Jeffrey Young, and Hyesoon Kim. Accelerating the mitigation of LLM inference nondeterminism across GPU architectures. arXiv:2609.25624, 2026.
- [114] Nada Zine, Tristan Coignion, Vincenzo Stoico, Clément Quinton, Ivano Malavolta, Romain Rouvoy, and Patricia Lago. Attention to detail: Evaluating energy, performance, and accuracy trade-offs across vLLM configurations. arXiv:2607.09172, 2026.
- [115] Hynek Kydlíček. Math-Verify: Math verification library. <https://github.com/huggingface/Math-Verify>, 2025. Version 0.8.0.
- [116] Qian Zhang, Yan Zheng, Jinyi Liu, Hebin Liang, and Lanjun Wang. Key decision-makers in multi-agent debates: Who holds the power? arXiv:2511.11040, 2025.
- [117] Joel Lehman and Kenneth O. Stanley. Abandoning objectives: Evolution through the search for novelty alone. *Evolutionary Computation*, 19(2), 2011.
- [118] Kalyanmoy Deb, Amrit Pratap, Sameer Agarwal, and T. Meyarivan. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6(2), 2002.
- [119] Nathan Halko, Per-Gunnar Martinsson, and Joel A. Tropp. Finding structure with randomness: Probabilistic algorithms for constructing approximate matrix decompositions. *SIAM Review*, 53(2), 2011. arXiv:0909.4061.
- [120] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. arXiv:2305.14314.
- [121] Woosuk Kwon et al. Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th ACM Symposium on Operating Systems Principles (SOSP)*, 2023. arXiv:2309.06180 (vLLM).
- [122] Yubo Wang et al. MMLU-Pro: A more robust and challenging multi-task language understanding benchmark. In *Advances in Neural Information Processing Systems 37 (NeurIPS), Datasets and Benchmarks Track*, 2024. arXiv:2406.01574.
- [123] Hunter Lightman et al. Let’s verify step by step. arXiv:2305.20050 (ICLR 2024), 2023.

- [124] Dan Hendrycks et al. Measuring mathematical problem solving with the MATH dataset. In *Advances in Neural Information Processing Systems 34 (NeurIPS), Datasets and Benchmarks Track*, 2021. arXiv:2103.03874.
- [125] M-A-P Team, Xinrun Du, et al. SuperGPQA: Scaling LLM evaluation across 285 graduate disciplines. arXiv:2502.14739, 2025.
- [126] Karl Cobbe et al. Training verifiers to solve math word problems. arXiv:2110.14168, 2021.
- [127] David Rein et al. GPQA: A graduate-level google-proof Q&A benchmark. arXiv:2311.12022 (COLM 2024), 2023.