

令和〇年度 修士論文

マルチエージェント議論における
チームレベル適応度を用いた
LoRA エージェント集団の進化的最適化

Evolutionary Optimization of LoRA Agent Populations
with Team-Level Fitness in Multi-Agent Debate

2026 年 7 月 10 日

指導教員 余俊 助教

新潟大学 自然科学研究科
電気情報工学専攻 情報社会デザイン科学コース

学生番号 F25C142E

舩田 岳

Gaku Masuda

概要

大規模言語モデル (LLM) の複数体を議論させるマルチエージェント推論は、単一モデルの限界を超える手段として注目されるが、小型モデルでは「計算量を揃えた多数決 (Self-Consistency) に勝てない」という強い批判がある。本研究は、4B 級モデル (Qwen3-4B-Instruct-2507) に LoRA で異なるペルソナを焼き込んだ 3 体のエージェント集団を構成し、(1) 議論によるチーム推論が生成回数を揃えた Self-Consistency@9 (SC@9) を上回れるか、(2) チームレベル適応度 (厳密 Shapley 値 $\times$ fitness sharing) による重み空間の進化的最適化が寄与するかを、3 ベンチマーク (MMLU-Pro $\cdot$ MATH-500 $\cdot$ SuperGPQA) $\times$ 3 シードの対応あり検定 (問題 ID クラスタリングを考慮した置換検定 $\cdot$ ブートストラップ + Holm 補正) で検証した。

実験 1 (主実験) の結果、議論の効果はベンチマーク依存に反転することが判明した。素の議論は数学 (+4.2pt) と高難度科学 (+3.1pt) で有意に有効だが MMLU-Pro では有意に有害 (-4.1pt) であり、重みペルソナチームは逆に MMLU-Pro のみで有効 (対ベース +4.5pt) だった。この反転は「多様性の利得」と「ペルソナ注入による能力毀損」の 2 軸トレードオフとして整理できる (ただし反転を問題の検証可能性に帰する解釈はベンチマーク内のカテゴリ別分析では支持されず、仮説にとどまる)。診断分析により、(i) ペルソナ SFT が思考連鎖を半減させ長い導出能力を選択的に破壊すること、(ii) 3 体の誰かが正解している問題の最大 13% 分を多数決集約が取りこぼすこと、(iii) 進化は適応度測定ノイズ (100 問で ± 4.9 pt) 下の勝者の呪いにより選抜として機能しなかったうえ、進化前後の ΔW が cosine 類似度 0.9997 以上とほぼ同一——すなわち進化演算子が重み空間をほとんど動かしていなかったことを明らかにした。

実験 2 では診断に基づく処方——ベースモデル自己生成の検証済み長 CoT リプレイ混合 (38%) による再学習、自己誤り特定時のみ回答変更を許す条件付き議論、発言匿名化、logprob 重み付き投票——を、事前定義した合格基準を持つ実測ゲート方式で検証した。この過程で評価コンテナイメージ間の系統差 (同一問題 $\cdot$ 同一設定で +6pt 級、ベースモデルの素の生成に選択的に作用) を検出したため、主要 4 条件を同一環境で全面再測定して統制した。最終評価において、処方はペルソナ SFT が生んだ能力毀損をベース単体との同等性 (等価マージン ± 2 pt) が成立する水準まで回復させ (対旧チーム +2.7pt, $p = 0.0003$; MATH-500 では対ベース +3.4pt 有意優位)、一方で SC@9 には -3.5pt ($p < 10^{-4}$) と有意に及ばなかった。

本研究の貢献は、(a) 小型 LLM 議論チームの成否を 2 軸トレードオフと損失分解で説明する診断枠組み、(b) 進化ループの機能不全（探索・多様性圧・選抜の三重の不全）の実測による特定と選抜ノイズの定量化、(c) 能力毀損を回復させる処方の実証と、それを尽くしてもなお生成回数を揃えた多数サンプリングに及ばないという統制された負の結果、(d) 評価環境の系統差がベースライン側を選択的に過小評価しチーム手法を見かけ上優位にするバイアスの発見、である。数学（MATH-500）では議論チームがベース単体を有意に上回り続けており、マルチエージェント議論の価値が残る条件を実測に基づいて画定した。

目次

第1章 序論	9
1.1 研究背景	9
1.1.1 単一モデルの拡大から小型モデル集団の協調へ	9
1.1.2 マルチエージェント議論の登場とその限界	10
1.2 研究課題	10
1.3 提案手法の要点と本研究の貢献	11
1.4 本論文の構成	13
第2章 関連研究	14
2.1 マルチエージェント議論	14
2.1.1 原典と初期の成果	14
2.1.2 批判研究：MAD は本当に有効か	15
2.1.3 成功条件の知見と本研究への含意	15
2.2 モデルマージと LoRA 合成の理論	16
2.3 進化的アプローチによるモデル最適化	17
2.4 協調の定量化と適応度設計の理論	19
2.4.1 Shapley 値による貢献配分	19
2.4.2 協調的共進化と集団ベース訓練	20
2.4.3 多様性の扱い：加算ではなく分離・ペナルティ	20
2.4.4 評価方法論	21
2.5 本研究の位置づけ	21
第3章 提案手法	23
3.1 問題定式化	23
3.1.1 ベースモデルと LoRA 個体	23
3.1.2 役割・エージェント・チーム	24
3.1.3 議論プロトコルと特性関数	24

3.2	議論プロトコル	24
3.3	適応度関数	26
3.3.1	特性関数と厳密 Shapley 値	26
3.3.2	Fitness sharing と行動距離	27
3.3.3	多様性を加算しない設計判断	28
3.4	進化アルゴリズム	29
3.4.1	協調的共進化の構造	29
3.4.2	選抜とエリート保存	29
3.4.3	交叉: ΔW 空間ブレンドとランダム化 SVD 再分解	30
3.4.4	ガウス突然変異	31
3.4.5	世代ループ全体	31
3.5	計算量の分析	31
第 4 章	評価実験	34
4.1	実装	34
4.1.1	ベースモデルと QLoRA 学習	34
4.1.2	vLLM Multi-LoRA サービング	35
4.1.3	Vertex AI Spot 構成とプリエンプション耐性	36
4.2	ベンチマークと評価プロトコル	36
4.2.1	ベンチマーク選定	36
4.2.2	生成型評価と回答抽出	37
4.2.3	進化ループ内の適応度セット	37
4.3	比較条件	38
4.4	統計設計	38
4.5	ハイパーパラメータ	41
4.6	実験結果	43
4.6.1	実験 1: 主実験の結果	44
4.6.2	実験 1 の診断: 損失分解	45
4.6.3	実験 2: 処方の検証 (ゲート方式)	46
4.6.4	測定環境の系統差の発見と統制	47
4.6.5	実験 2: 最終評価 (同一測定環境)	48
4.6.6	追加分析: sharing の事後検証・カテゴリ別効果・計算量の実測	49

第 5 章 考察	51
5.1 実験結果の解釈: 議論の効果は 2 軸のトレードオフで決まる	51
5.2 損失分解が導いた処方とその効果	52
5.3 進化的最適化の再解釈: 選抜ではなく修復	53
5.4 Self-Consistency との比較の最終形	54
5.5 本研究の限界	55
第 6 章 結論	57
6.1 まとめ	57
6.2 今後の課題	58
謝辞	60
参考文献	61

第1章 序論

1.1 研究背景

1.1.1 単一モデルの拡大から小型モデル集団の協調へ

大規模言語モデル（LLM）の性能は、パラメータ数・データ量・計算量の拡大によって向上してきた。しかし、モデル規模の拡大は学習・推論コストの急激な増大を伴い、単一モデルの能力を際限なく引き上げるアプローチには経済的・工学的な制約が存在する。この制約を背景として、近年、「個の拡大」に代わる方向性として「集団の協調」への関心が高まっている。すなわち、単一の巨大モデルにすべての能力を担わせるのではなく、複数のモデル（あるいは複数のインスタンス）を相互作用させ、その集合としての振る舞いから単体を超える性能を引き出すという考え方である。実際、複数のサンプル生成と多数決という最も素朴な協調形態であっても、エージェント数の増加に伴い性能が単調に向上するスケール特性が報告されている [1]。また、配備済みモデルの重みやプロンプト、エージェント構成そのものを実行後に継続的に改善していく「自己進化エージェント」という枠組みが体系化されつつあり、モデルを静的な成果物ではなく進化し続ける集団として扱う視点が整理されている [2, 3]。

この潮流は、小型モデルにとって特に重要な意味を持つ。数十億パラメータ級（以下、4B 級と表記する）の小型モデルは、単体では最先端の巨大モデルに及ばないものの、ローカル環境や安価な計算資源上で複数個を同時に運用できるため、「複数の特化した小型モデルの協調」によって単体性能の限界を補うという設計が現実的な選択肢となる。さらに、パラメータ効率的微調整手法である LoRA（Low-Rank Adaptation）[4] を用いれば、単一のベースモデルの上に複数の軽量アダプタを載せ替えるだけで多様な「人格（ペルソナ）」や役割を持つエージェント群を構成でき、メモリコストを抑えたまま集団を形成できる。本研究はこの構図、すなわち「共有ベースモデル＋役割別 LoRA アダプタ群」による小型モデル協調を対象とする。

1.1.2 マルチエージェント議論の登場とその限界

複数の LLM エージェントを協調させる代表的なプロトコルが、マルチエージェント議論 (Multi-Agent Debate; MAD) である。Du ら [5] は、複数の LLM インスタンスが互いの回答を参照しながら複数ラウンドにわたり回答を更新し、最終的に合意された回答を採用する手続きにより、3 エージェント × 2 ラウンドの構成で GSM8K の精度を 77 から 85 へ、MMLU を 63.9 から 71.1 へ改善できることを示した。また Liang ら [6] は、単一モデルの自己反省が同一の思考に固執する「思考の退化 (Degeneration-of-Thought)」に陥ることを指摘し、異なる視点を持つエージェント間の対立的議論がその回避に有効であることを示した。

しかし、その後の検証研究は MAD の効果に重大な留保を付けている。Smit ら [7] は、MAD が Self-Consistency[8] などの単純なアンサンブル手法に対して計算量を揃えた比較では安定して勝てないことを示した。さらに、議論の中で他者の回答に同調して正答を誤答へ書き換えてしまう追従性 (sycophancy) による誤りの伝染 [9]、同一モデルの複製からなる同質なエージェント集団では議論が非効率かつ不安定になるという報告 [10] が続いている。Zhang ら [11] は既存 MAD 研究の評価上の不備を系統的に指摘したうえで、MAD を機能させる鍵はエージェント間の異質性の活用にあると論じた。すなわち、MAD の成否は「議論に参加するエージェント集団の質と多様性」に強く依存するにもかかわらず、既存研究の多くはエージェント側を固定し、プロトコル (ラウンド数・集約方式・プロンプト) の工夫のみで改善を図ってきたのである。

1.2 研究課題

以上の背景から、本研究は次の三つの課題を出発点とする。

(a) 既存の MAD 研究はエージェントを固定し、協調の質そのものを最適化していない。MAD の性能はエージェント集団の構成に依存するにもかかわらず、既存研究の主流は与えられたモデルを所与として議論プロトコルを調整するものであった。議論への貢献度を報酬としてモデル自体を訓練する試みは MAPoRL[12] などの強化学習ベースの研究に限られ、「議論チームへの貢献」を選択圧としてエージェント集団 (の重み) を世代交替的に進化させる研究は、著者の知る限り報告されていない。

(b) 既存の LoRA 集団進化は個体性能のみを適応度とする．LoRA アダプタの重みを遺伝子とみなし，交叉・突然変異・選択によって集団を進化させる研究系統が近年急速に発展している（GENOME[13]，PopuLoRA[14] など）．しかしこれらの適応度は個体単独のタスク性能（あるいは敵対的 self-play の勝敗）であり，「チームの一員としてどれだけ協調に寄与するか」を測る適応度は用いられていない．個体として優秀なエージェントの集合が優れたチームになるとは限らない，というアンサンブル学習の古典的知見 [15] に照らせば，これは本質的な欠落である．

(c) 多様性を適応度に加算する素朴な設計には理論的問題がある．チームの多様性が重要であるならば，「性能 $+\lambda \times$ 多様性」の形で適応度に多様性項を加算すればよいと考えたくなる．しかし，品質多様性（Quality-Diversity）研究は多様性を目的関数に混ぜるのではなくアーカイブ構造で分離して保持すべきことを示しており（MAP-Elites[16]），アンサンブル多様性の統一理論もまた，多様性が bias・variance と並ぶトレードオフ管理の対象であって無条件に加算してよい量ではないことを示している [17]．したがって，協調と多様性を扱う適応度設計には，加重和に代わる理論的に正当化された構成が必要である．

1.3 提案手法の要点と本研究の貢献

本研究は，上記の課題に対し，マルチエージェント議論のチームレベル適応度——厳密 Shapley 値によって測られる協調寄与——を選択圧として，ペルソナ LoRA 集団を進化的に最適化する枠組みを提案する．対象は Qwen3-4B-Instruct[18] を共有ベースモデルとする 3 役割（批判的検証者・実務的意思決定者・発散的探索者）の LoRA エージェント集団であり，協調的共進化 [19] の枠組みに従って役割別サブ集団を維持しながら，世代ごとに (i) 各候補 LoRA を代表チームに組み込んだ議論評価，(ii) Shapley 値に基づく貢献度の算出，(iii) ΔW 空間での交叉と突然変異による次世代生成，を繰り返す．

適応度の中核には協力ゲーム理論の Shapley 値 [20] を採用する．Shapley 値は効率性・対称性・null player・線形性の公理を一意に満たす貢献配分であり [21]，一般には連合数が指数的に増えるため近似を要するが [22]，本研究の 3 エージェント構成では全 7 連合の議論評価によって近似なしの厳密計算が可能である．また，課題 (c) を踏まえ，多様性は適応度への加算項とせず，fitness sharing[23] による乗法ペナルティ——回答不一致率で測った行動距離に基づき，同一ニッチに密集した

個体の適応度を割り引く——として組み込む。

本研究の貢献は以下の4点である。

1. **厳密 Shapley 値による協調寄与を LoRA 集団進化の適応度に組み込む初の定式化.** 議論チームへの限界貢献を、3 エージェント構成において全連合の実測から近似なしに計算可能な Shapley 値として定式化し、これを選択圧とする進化的最適化の枠組みを提示する。Shapley 値は個体単独の性能（単独連合の価値）を内包するため、性能項と協調項の恣意的な加重和を必要としない点で、既存の適応度設計と理論的に区別される。
2. **協調的共進化の枠組みによる MAD チーム最適化手法の提案.** Potter と De Jong[19] の役割別サブ集団と協力者評価の考え方を LLM エージェント集団に移植し、役割内の ΔW 空間交叉（LoRA 因子の素朴な補間が持つ交差項問題を回避するため、 $\Delta W = BA$ を明示的に構成して補間し SVD で低ランクに再分解する方式；Stoica ら [24] の知見に基づく）と fitness sharing を組み合わせた世代交代アルゴリズムを設計する。ただし fitness sharing はサブ集団サイズ $K = 2$ の本実験構成では選抜に作用しないことが事後検証で判明しており（§3.3.2, §4.6.6）、実際に働いた選択圧は Shapley 値のみである。
3. **4B 級小型モデルにおける「議論が機能する条件」の実証分析と損失分解による診断枠組み.** 7～8B 級の同質エージェントによる素の議論は非効率・不安定であり [10]、評価設計の不備を正すと MAD の優位が消えるという批判 [11] も踏まえると、4B 級では素の議論は機能しない可能性が高い。本研究は、生成回数を揃えた Self-Consistency ベースラインおよびプロンプトのみのペルソナ付与との統制比較によって議論チームの成否を3ベンチマークで測定し、その効果が「多様性の利得」と「ペルソナ注入による能力毀損」の2軸トレードオフとしてベンチマーク依存に反転することを示す（この反転を「検証可能性」で統一的に説明する解釈は、ベンチマーク内のカテゴリ別分析では支持されず、仮説の域を出ない；§4.6.6）。さらにチーム誤差を個体能力損失と集約損失に分解する診断（oracle 上限分析）を提案する。
4. **診断に基づく処方の実測ゲート検証と、統制された負の結果.** 上記の診断が特定した損失（思考連鎖の圧縮による能力毀損・正解が少数派の問題での集約失敗・適応度測定ノイズによる選抜の無情報化）のそれぞれに対し、能力保持リプレイ再学習・検証型集約・議論プロトコル改良という処方を設計し、事

前定義した合格基準を持つゲート方式で検証する。処方は旧チームを +2.7pt (問題 ID クラスタ解析, $p = 0.0003$) 有意に改善し, ベース単体との同等性 (等価マージン $\pm 2\text{pt}$) を回復させたが, 生成回数を揃えた Self-Consistency には -3.5pt ($p < 10^{-4}$) と有意に及ばなかった。この過程で評価環境の系統差 (同一設定・同一問題でイメージ差のみにより +6pt 級) を検出・統制しており, 負の結果の確定と評価再現性の警鐘を含めて報告する。

1.4 本論文の構成

本論文の構成は以下の通りである。第2章では, マルチエージェント議論, モデルマージと LoRA 合成の理論, 進化的モデル最適化, 協調の定量化と適応度設計の理論という4つの研究系統を整理し, 本研究の位置づけを明確化する。第3章では, 提案手法——Shapley 値に基づくチームレベル適応度, fitness sharing, ΔW 空間交叉を含む協調的共進化アルゴリズム, および議論プロトコル——を定式化する。第4章では, ベンチマーク・比較条件・統計的検定を含む実験設計を述べ, 実験結果を報告する。第5章では実験結果に対する考察と本研究の限界を論じ, 第6章で結論と今後の展望を述べる。

第2章 関連研究

本章では、本研究に関連する研究を4つの系統——(1) マルチエージェント議論, (2) モデルマージと LoRA 合成の理論, (3) 進化的アプローチによるモデル最適化, (4) 協調の定量化と適応度設計の理論——に整理し、最後に本研究の位置づけを述べる。

2.1 マルチエージェント議論

2.1.1 原典と初期の成果

マルチエージェント議論 (Multi-Agent Debate; MAD) の原典とされるのが Du ら [5] の研究である。複数の LLM インスタンスがまず独立に回答を生成し、続くラウンドで他エージェントの回答を参照しながら自身の回答を批判的に更新する、という単純な手続きにより、3 エージェント × 2 ラウンドの構成で GSM8K を 77 から 85 へ、MMLU を 63.9 から 71.1 へ改善できることが示された。同研究では、他者回答を要約して提示することが有効である一方、単一エージェントの自己反省のみでは改善が得られないことも報告されており、「他者からの異なる情報」が改善の源泉であることが示唆されている。並行して Liang ら [6] は、単一モデルの自己反省が自身の初期解に固執する「思考の退化 (Degeneration-of-Thought; DoT)」を指摘し、異なる立場を割り当てられたエージェント間の対立的議論が DoT の回避に必要であると論じた。この知見は、議論に参加するエージェントに明示的な視点の多様性——本研究の文脈ではペルソナの多様性——を与えるべきであるという本研究の設計動機の直接の源流である。

議論を実行時のプロトコルとしてだけでなく訓練信号の源として使う方向も発展した。Subramaniam ら [25] は、議論の軌跡から生成役と批評役を分化させて自己教師あり微調整 (SFT) を行う Multiagent Finetuning を提案し、Phi-3 の MATH 精度を 5 反復で 58.8 から 66.0 へ改善するとともに、エージェント間の多様性の維持が反復改善の持続と相関することを示した。また MACA[26] は議論トレースか

らの選好学習により小型モデルの GSM8K を +27.6% 改善した。さらに Park ら [12] の MAPoRL は、議論における協調品質を報酬としてマルチエージェント強化学習で複数モデルを共訓練する枠組みを提案しており、「協調の質を最適化信号にする」という点で本研究に最も思想が近い。ただし MAPoRL は勾配ベースの RL であり、重み空間の集団に対する世代交代型の進化ではない（この対比は 2.5 節で詳述する）。

このほか、複数モデルの出力を階層的に統合する Mixture-of-Agents[27] に対して、Li ら [28] は単一の強いモデルの複数サンプルを統合する Self-MoA が異種混合を上回る場合が多いことを示し、混合が有効なのは構成モデルの品質が拮抗している場合に限られると分析した。品質と多様性はトレードオフの関係にあり、多様性は品質を犠牲にしない範囲でのみ価値を持つ——この知見は、品質（貢献度）と多様性を単一の適応度に統合する本研究の設計課題を先取りしている。

2.1.2 批判研究：MAD は本当に有効か

MAD の初期の成功報告に対しては、その後、系統的な批判が積み重ねられている。第一に、Smit ら [7] は複数の MAD 戦略を計算量を統制して比較し、MAD が Self-Consistency（複数サンプルの多数決）[8] 等の単純な手法に安定して勝てないことを示した。これは MAD の効果検証において計算量を揃えたベースラインが不可欠であることを意味する。第二に、Zhang ら [11] は既存 MAD 研究の評価設計（ベースラインの弱さ、ハイパーパラメータの非統制等）を系統的に指摘し、公平な条件では MAD の優位が大きく縮小すること、そして今後の方向としてエージェント間の異質性の活用を提案した。第三に、議論という相互作用そのものの失敗様式も特定されている。他者への追従（sycophancy）により、当初正答を持っていたエージェントが誤答へ引きずられる「正 → 誤の伝染」が観察されており [9], 7~8B 級の同一モデルの複製からなる同質な MAD は非効率かつ不安定であることが報告されている [10]。

2.1.3 成功条件の知見と本研究への含意

批判研究と並行して、「どのような条件なら議論が機能するのか」を切り分ける研究も現れている。Choi ら [29] は MAD の利得の大半が最終的な多数決（投票）で説明でき、議論中の信念更新はマルチンゲールの（期待值的に情報を増やさな

い)であることを示した。Kaesberg ら [30] は集約方式を比較し、推論タスクでは合意形成よりも投票が優れ (+13.2%)、議論ラウンドの追加はむしろ逆効果であることを示した。さらに近年の分析は、初期回答の多様性と確信度に条件付けられた回答更新が MAD 成功の鍵であることを示している [31]。

これらを総合すると、次の緊張関係が浮かび上がる。議論の利得は「多様な初期回答の生成」と「正しい方向への選択的更新」から生じるが、同質で追従的な小型モデル集団はそのどちらも満たしにくい。7~8B 級ですら同質 MAD の不安定性が報告されている以上、本研究が対象とする 4B 級では、素の（無調整の）debate は機能しない可能性が高い。本研究はこの緊張関係を回避すべき前提ではなく検証対象として引き受ける。すなわち、(i) プロトコル面では文献の成功条件に忠実に従い（独立初期回答、最大 2 ラウンド、多数決集約）、(ii) エージェント面では重み空間に焼き込まれたペルソナ多様性とチームレベル選択圧によって「議論が機能するエージェント集団」を明示的に育成できるかを問う。

2.2 モデルマージと LoRA 合成の理論

本研究の進化アルゴリズムは LoRA 重みの交叉（ブレンド）を核とするため、重み合成がいつ・なぜ妥当なのかという理論的根拠を必要とする。

重み平均によるモデル合成の原点は Model Soups[32] である。同一の事前学習モデルから微調整された複数モデルの重みを単純平均するだけで精度と頑健性が向上することが示されたが、これは微調整解が損失地形上で線形に接続されている（linear mode connectivity）ことを前提とする。Ilharco ら [33] の Task Arithmetic は、微調整前後の重み差分 ΔW を「タスクベクトル」とみなし、その加減算によって能力を合成・除去できることを示し、 ΔW 空間での算術という枠組みを確立した。

一方で、素朴な線形和には劣化要因があることも明らかになっている。Yadav ら [34] の TIES-Merging は、タスクベクトル間のパラメータ符号の衝突（干渉）が線形和の性能劣化の主因であることを特定し、符号衝突を解決してからマージする手法を提案した。Yu ら [35] の DARE は、 ΔW の大部分をランダムに drop して残りを rescale してもタスク性能が保たれる冗長性を利用し、干渉を減らしてマージする。

LoRA に固有の問題を扱ったのが Stoica ら [24] の KnOTS である。同研究は、LoRA によって得られた ΔW はフルファインチューニングの場合よりもモデル間

の整合 (alignment) が低く、素朴な重み平均が顕著に劣化することを示し、複数の ΔW を SVD によって共通基底に整列させてからマージする手法を提案した。さらに、LoRA の低ランク因子 A, B を別々に補間する方式には**交差項問題**がある。すなわち、2つのアダプタ $(B_1A_1), (B_2A_2)$ の因子を係数 α で別々に補間すると、

$$((1-\alpha)B_1+\alpha B_2)((1-\alpha)A_1+\alpha A_2) = (1-\alpha)^2 B_1A_1 + \alpha^2 B_2A_2 + \alpha(1-\alpha)(B_1A_2+B_2A_1) \quad (2.1)$$

となり、意図した凸結合 $(1-\alpha)B_1A_1 + \alpha B_2A_2$ ではなく、意味を持たない交差項 B_1A_2, B_2A_1 が混入する。加えて $BA = (BR)(R^{-1}A)$ という再パラメータ化不変性のため、同一の ΔW を表す因子分解は無数に存在し、因子空間での補間は分解の取り方に依存してしまう。したがって、LoRA 集団の交叉演算子は因子空間ではなく ΔW 空間で定義し、必要に応じて SVD で低ランクに再分解するのが理論的に正当である。本研究の交叉演算子 (ΔW 空間ブレンド + SVD 再分解) はこの知見に直接依拠しており、因子別補間 (naive 方式) はアブレーション対象 (A3) として実装内に位置づける (実施状況は §4.3)。

なお、線形マージ以外の合成として、Prabhakar ら [36] は複数 LoRA をランク方向に連結する CAT (ランクの合計をとる連結) が線形マージを上回り、数学タスクで +43% の改善を得ることを報告している。モデルマージ全般の体系的整理は Yang ら [37] のサーベイに詳しい。

2.3 進化的アプローチによるモデル最適化

進化計算を LLM の重み・合成レシピの探索に適用する研究は、近年ひとつの系統を成しつつある。

先駆けとなったのは Akiba ら (Sakana AI) の進化的モデルマージである [38]。CMA-ES を用いて既存フルモデル群のマージレシピ (層別のマージ係数や推論経路) を探索し、日本語 LLM である EvoLLM-JP 7B が一部ベンチマークで 70B 級モデルを超える性能を達成した。ただしこれは既存モデルを素材とする「レシピの 1 点探索」であり、モデル集団自体の世代交代は行われず。LoraHub[39] も同様に、既存 LoRA 群の合成係数ベクトルを勾配フリー最適化で求める 1 点解の探索であり、かつ $A \cdot B$ 因子別の合成であるため前節の交差項問題を内包する。

集団ベースの探索へ進んだのが Model Swarms[40] である。複数の LoRA エキスパートを粒子とみなし、粒子群最適化 (PSO) によって重み空間を協調探索する

ことで、200 例程度の少数データから最大 +21%の適応改善を得た。ただし PSO は速度ベクトルによる連続的な移動であり、交叉・突然変異・世代交代という遺伝的操作を持たず、効用関数も個体単位である。

遺伝的アルゴリズムを LoRA 重みに全面的に適用したのが GENOME/GENOME+ である [13]。LoRA 重みを遺伝子とみなし、交叉・突然変異・選択・継承 (succession) からなる世代交代を最大 40 個体の集団で実行する。本研究にとって最近接の先行研究であるが、その適応度は**個体単独のタスク性能のみ**である。同系統の EvoPref[41] は 32 個体の LoRA を NSGA-II で 200 世代進化させ多様性アーカイブを併用するが、目的はアライメントであり評価は個体単位である。また PopuLoRA[14] は共有ベースモデル上の LoRA 集団を出題者対解答者の敵対的 self-play で共進化させ、同ランク制約下の交叉演算子を提案した。個体間の相互作用が適応度を決めるという点で本研究に近づいているが、その相互作用は敵対的であり、協調的な議論への寄与を測るものではない。実装基盤としては、進化的マージの汎用ライブラリ Mergenetic[42] が公開されている。

主要研究の対比を表 2.1 に示す。

表 2.1: 進化的モデル最適化の主要研究の対比

研究	進化の対象	探索方式	集団と世代交代	適応度の評価単位	個体間相互作用
進化的モデルマージ [38]	マージレシピ (層別係数・推論経路)	CMA-ES	なし (レシピ 1 点解)	マージ後モデル単体の性能	なし
LoraHub[39]	LoRA 合成係数ベクトル	勾配フリー最適化	なし (1 点解)	合成モデル単体の性能	なし
Model Swarms[40]	LoRA 重み (粒子)	PSO	集団あり・世代交代なし	個体単位の効用	探索情報の共有のみ
GENOME/GENOME+[13]	LoRA 重み (遺伝子)	GA (交叉・突然変異・選択)	集団あり・世代交代あり (最大 40 個体)	個体単独のタスク性能	なし
EvoPref[41]	LoRA 重み	NSGA-II (200 世代)	集団あり・世代交代あり (32 個体)	個体単位 (アライメント目的)	なし
PopuLoRA[14]	LoRA 重み	共進化 GA	集団あり・世代交代あり	対戦の勝敗	敵対的 self-play
本研究	LoRA 重み (役割別サブ集団)	協調的共進化 GA	集団あり・世代交代あり	チーム議論への厳密 Shapley 寄与	協調的議論

表 2.1 が示すとおり、系統の発展は「レシピの 1 点探索 → 集団による重み空間

探索 → 世代交代型の遺伝的進化 → 相互作用を伴う共進化」と進んできたが、協調的な相互作用（議論）のチームレベル評価を適応度とする世代交代型 LoRA 進化は空白のまま残されている。

2.4 協調の定量化と適応度設計の理論

前節の空白を埋めるには、「チームへの貢献」を原理的に定義し、それを進化の選択圧として健全に機能させる理論が必要である。本節では本研究の適応度設計が依拠する4つの理論的支柱を整理する。

2.4.1 Shapley 値による貢献配分

協力ゲーム理論の Shapley 値 [20] は、連合 (coalition) の価値関数 v が与えられたとき、各プレイヤーの貢献を全部分連合への限界貢献の加重平均として配分する。機械学習分野では Ghorbani と Zou [21] が訓練データの価値評価 (Data Shapley) に導入し、Shapley 値が効率性・対称性・null player・線形性の4公理を満たす一意の配分であることを配分原理としての根拠とした。Rozemberczki ら [22] のサーベイが整理するように、Shapley 値の計算は一般に 2^n 個の連合評価を要するため近似手法が発達してきたが、逆に言えば n が小さければ厳密計算が可能である。本研究は議論チームを3エージェントに設計することで、全7連合（空集合を除く）の議論を実測し近似誤差のない厳密 Shapley 値を得る。これは単純な leave-one-out (LOO) 近似が持つ欠陥——たとえば同一能力の複製が2個体いる場合、どちらを除いても価値が変わらないため両者に貢献0を割り当ててしまう——を原理的に回避する。

マルチエージェント強化学習における credit assignment の系譜も同じ問題意識を共有する。Wolpert と Tumer [43] の difference reward (Wonderful Life Utility) は「自分がいなかった場合」との反事実差分で個体の貢献を測る枠組みの源流であり、Foerster ら [44] の COMA は counterfactual baseline を用いた方策勾配としてこれを深層 MARL に実装した。Shapley 値はこれら反事実的貢献を全連合にわたって公理的に平均化したものと位置づけられる。

2.4.2 協調的共進化と集団ベース訓練

複数の部分要素が組み合わさって初めて全体の性能が決まる問題に対する進化計算の古典的解が、Potter と De Jong[19] の協調的共進化 (Cooperative Coevolution) である。問題を部分要素 (本研究では議論の役割) ごとのサブ集団に分割し、各個体を他サブ集団の代表 (協力者) と組み合わせて評価する。この「代表チーム文脈での個体評価」は、本研究において各候補 LoRA の Shapley 値を計算する際のチーム構成法 (候補 1 体 + 他役割の代表 2 体) の骨格そのものである。また、Jaderberg ら [45] の Population Based Training (PBT) は、訓練途中の集団に対する exploit (劣位個体の優位個体による置換) と explore (摂動) の交互適用が有効であることを示しており、本研究の世代ループ (役割内選抜と突然変異) の手続き的な根拠を与える。

2.4.3 多様性の扱い：加算ではなく分離・ペナルティ

進化計算において目的関数への単一目的化は欺瞞的 (deceptive) な探索を招きうる。Lehman と Stanley[46] の Novelty Search は、目的への直接最適化がかえって目的達成を妨げる場合があることを示し、行動の新規性そのものを探索圧とする発想を導入した。しかし「では多様性を適応度に加算すればよい」とは言えない。Mouret と Clune[16] の MAP-Elites は、多様性を適応度に混ぜるのではなく行動記述子で張られたアーカイブとして分離保持する品質多様性 (QD) の枠組みを確立し、多目的最適化の古典 NSGA-II[47] も、加重和方式が非凸 Pareto 前線を捉えられず重み係数の選択が恣意的になるという限界を明確にしている。アンサンブル学習の側からは、Krogh と Vedelsby[15] の ambiguity 分解——アンサンブル誤差 E は構成員の平均誤差 $\bar{E}$ から構成員間の不一致 $\bar{A}$ を引いた $E = \bar{E} - \bar{A}$ に分解される——が多様性の価値の数学的根拠を与える一方、Wood ら [17] の統一理論は、多様性が bias・variance と並ぶ誤差の第 3 次元であり、損失関数に依存してその効き方が変わるトレードオフ管理の対象であることを示し、多様性の無条件な加算に対する最も強い反証となっている。

これらを踏まえ、本研究は多様性を適応度への加算項とせず、Goldberg と Richardson による fitness sharing[23]——行動的に近接した個体同士で適応度を割り引く乗法ペナルティ——として組み込む。fitness sharing はニッチ形成による早期収束の防止という明確な役割を持ち、貢献度 (Shapley 値) の順序構造を加算項のよう

に恣意的な係数で歪めない。また Krogh と Vedelsby の分解は、進化の過程でチームの行動多様性（回答不一致プロファイル）がどう変化しチーム性能とどう関係するかを分析する枠組み（研究課題 (c) の多様性設計に対応）として用いる。

2.4.4 評価方法論

適応度と最終評価の設計には評価方法論の知見を用いる。tinyBenchmarks[48] は約 100 問のサブセットでフルベンチマークとの誤差が約 2% に収まることを示しており、進化ループ内の適応度セット（固定 100 問）の規模設定の根拠となる。最終評価の統計的検定は、SEM の併記・クラスタ標準誤差・複数回リサンプル・paired 分析・検出力分析を勧告する Miller[49] の指針と、NLP における有意性検定の使い分けを整理した Dror ら [50] に従う。

2.5 本研究の位置づけ

以上の 4 系統を俯瞰すると、既存研究は「協調プロトコルの改善（2.1 節）」「重み合成の演算子（2.2 節）」「重み集団の進化（2.3 節）」「貢献と多様性の理論（2.4 節）」をそれぞれ発展させてきたが、それらの交点——**議論のチームレベル適応度を選択圧とする LoRA 重み集団の世代交代型進化**——は未報告である。表 2.2 に、隣接する研究系統と本研究に欠けている要素を整理する。

本研究の位置づけは次の 3 点に要約される。

第一に、**最適化信号の新規性**である。表 2.2 の上段 2 系統（GENOME・PopuLoRA）は重み集団の進化という「器」を持つが信号が個体的・敵対的であり、中段 2 系統（MAPoRL・EvoMAS 等）は協調・チームという「信号」を持つが対象が勾配更新やプロンプトである。本研究は、公理的に正当化された貢献配分である厳密 Shapley 値（2.4.1 項）を LoRA 重み集団の世代交代進化の適応度に導入することで、この器と信号を初めて接続する。GENOME 型の個体性能適応度はアブレーション（A1）として設計・実装したが、計算資源の制約から本実験では未実施である（第 5 章）。新規性の主張は定式化の水準に留まる点に注意されたい。

第二に、**理論的整合性を持つ演算子の選択**である。交叉は KnOTS の知見（2.2 節）に基づく ΔW 空間ブレンド + SVD 再分解とし、因子別補間の交差項問題を回避する。多様性は QD とアンサンブル統一理論の批判（2.4.3 項）を踏まえ、加算項ではなく fitness sharing の乗法ペナルティとして扱う。議論プロトコルは批判研

表 2.2: 隣接研究系統と本研究の位置づけ

系統	代表研究	最適化の対象	最適化の信号	本研究との差分（欠けている要素）
LoRA 集団＋進化演算	GENOME[13], EvoPref[41]	LoRA 重み集団	個体タスク性能	適応度が個体性能のみで，協調寄与を測らない
LoRA 集団＋相互作用共進化	PopuLoRA[14]	LoRA 重み集団	敵対的 self-play の勝敗	相互作用が敵対的であり，協調議論でない
議論品質を最適化信号に	MAPoRL[12]	モデル重み（勾配更新）	議論の協調品質報酬	RLであり，集団の世代交代型進化でない
チーム適応度で MAS を進化	EvoMAS[51], Evolve as a Team[52]	プロンプト・エージェント構成	チーム性能	進化対象が重みでなくプロンプト／構成
LoRA 重み空間の協調探索	Model Swarms[40]	LoRA 重み集団	個体効用	PSO であり交叉・突然変異・世代交代がない
議論由来データで SFT	Multiagent Finetuning[25]	モデル重み（勾配更新）	議論トレースの模倣	勾配による模倣であり，選択圧でない
本研究	—	役割別 LoRA 重み集団	議論チームへの厳密 Shapley 寄与 × fitness sharing	—

究が特定した成功条件（2.1.3 項：独立初期回答・少数ラウンド・多数決集約）に準拠する。

第三に，否定的知見も成果となる問題設定である．4B 級の同質エージェントによる素の議論は機能しない可能性が高いという緊張関係（2.1.3 項）の下で，チームレベル選択圧が議論を機能させるならばそれは MAD を「エージェント集団の育成問題」として捉え直す証拠となり，機能しないならば適応度別・世代別の性能と行動多様性の軌跡から小型モデル議論の成立条件を統計的に特定できる．いずれの帰結でも，計算量を統制した Self-Consistency ベースライン（Smit ら [7] の要請）と paired 検定（Miller[49] の指針）に基づく厳密な比較の上で結論が導かれる点が，評価不備が指摘されてきた MAD 研究 [11] に対する方法論的な貢献となる．

なお，本領域は 2025～2026 年にかけて発展が速く，PopuLoRA のような近接研究が継続的に出現している．本表は執筆時点（2026 年 7 月）の再検索に基づく．

第3章 提案手法

本章では、マルチエージェント議論 (Multi-Agent Debate; MAD) のチームレベル適応度を選択圧としてペルソナ LoRA 集団を進化させる提案手法を定式化する。まず 3.1 節で問題を形式的に定義し、3.2 節で議論プロトコル、3.3 節で適応度関数、3.4 節で進化アルゴリズムを述べ、3.5 節で計算量を分析する。本章の記述はすべて公開実装 (`src/evalx/debate.py`, `src/evalx/shapley.py`, `src/evolve/loop.py`, `src/models/lora_ops.py`) と一対一に対応する。

3.1 問題定式化

3.1.1 ベースモデルと LoRA 個体

凍結されたベースモデル $\mathcal{M}_{\theta_0}$ (本研究では Qwen3-4B-Instruct-2507[18]) を共有し、その上に付加する LoRA (Low-Rank Adaptation) [4] アダプタを進化の対象となる「個体」とする。LoRA は対象モジュール $m \in \mathcal{L}$ (本実装では各 Transformer 層の q, k, v, o 射影および gate, up, down 射影) の重み $W_0^{(m)} \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ に対し、低ランク行列対 $B^{(m)} \in \mathbb{R}^{d_{\text{out}} \times r}$, $A^{(m)} \in \mathbb{R}^{r \times d_{\text{in}}}$ による更新

$$W^{(m)} = W_0^{(m)} + \gamma B^{(m)} A^{(m)}, \quad \gamma = \frac{\alpha_{\text{LoRA}}}{r} \quad (3.1)$$

を与える ($r = 32$, $\alpha_{\text{LoRA}} = 2r$, したがって $\gamma = 2$ で全個体共通・固定)。個体 x は行列対の集合 $x = \{(A^{(m)}, B^{(m)})\}_{m \in \mathcal{L}}$ として定義され、その実効的な表現型は各モジュールの更新行列 (タスクベクトル [33])

$$\Delta W^{(m)}(x) = B^{(m)} A^{(m)} \quad (3.2)$$

の集合である。全個体は同一のベースモデル・同一の rank・同一の対象モジュール集合を共有するため、後述の交叉演算が層ごとに well-defined になる。

3.1.2 役割・エージェント・チーム

役割集合を $\mathcal{R} = \{\text{critic}, \text{pragmatist}, \text{explorer}\}$ (批判的検証者・実務的意思決定者・発散的探索者) とし, 各役割 r に固有のペルソナプロンプト π_r (システムプロンプトとして与える短い役割記述) を割り当てる. エージェントは個体と役割プロンプトの組 $a = (x, \pi_r)$ である. 役割ごとのペルソナは, 初期化時に役割別 SFT データで重み空間にも焼き込まれる (第 4 章).

世代 t における役割 r のサブ集団を $P_r^{(t)} = \{c_{r,1}^{(t)}, \dots, c_{r,K}^{(t)}\}$ (本実装では $K = 2$), その代表個体を $\rho_r^{(t)} \in P_r^{(t)}$ と書く. 候補個体 $c \in P_r^{(t)}$ の評価は, 他役割の代表と組んだ代表チーム文脈

$$T(c) = \{c\} \cup \{\rho_{r'}^{(t)} \mid r' \in \mathcal{R}, r' \neq r\} \quad (3.3)$$

で行う. これは協調的共進化 (Cooperative Coevolution) [19] における「協力者 (collaborator) を固定した部分解評価」に相当する.

3.1.3 議論プロトコルと特性関数

質問 q と正解 y^* の組からなる固定の適応度セットを $D_{\text{fit}} = \{(q_j, y_j^*)\}_{j=1}^{N_{\text{fit}}}$ ($N_{\text{fit}} = 100$) とする. エージェント集合 (連合) S に対し, 3.2 節の議論プロトコルを R ラウンド実行して多数決回答を返す演算子を $\mathcal{D}_R(S, q)$ と書く ($|S| = 1$ のときは単独の Chain-of-Thought 回答). 連合 S の**特性関数** (characteristic function) を適応度セット上の精度

$$v(S) = \frac{1}{N_{\text{fit}}} \sum_{j=1}^{N_{\text{fit}}} \mathbf{1} [\mathcal{D}_R(S, q_j) = y_j^*], \quad v(\emptyset) = 0 \quad (3.4)$$

と定義する. 定義より $v(\{i\})$ は個体 i の solo 精度に一致する. 以上の記号を表 3.1 にまとめる.

3.2 議論プロトコル

議論プロトコルは Du らの MAD 原型 [5] に準拠し, 近年の系統的検証 [29, 30, 31] の知見に基づいて簡素化した以下の構造を採る.

ラウンド構造. 各問題 q に対し:

表 3.1: 記号表

記号	意味
$\mathcal{M}_{\theta_0}$	凍結ベースモデル (Qwen3-4B-Instruct-2507)
$x = \{(A^{(m)}, B^{(m)})\}$	LoRA 個体 (rank $r = 32$, $\gamma = 2$)
$\Delta W^{(m)}(x) = B^{(m)} A^{(m)}$	モジュール m の実効更新行列
$\mathcal{R}, \pi_r$	役割集合 (3 役割), 役割別ペルソナプロンプト
$P_r^{(t)}, K$	世代 t ・役割 r のサブ集団, その規模 ($K = 2$)
$\rho_r^{(t)}$	役割 r の代表個体 (前世代の役割内最良)
$T(c)$	候補 c の代表チーム文脈 (3 エージェント)
$D_{\text{fit}}, N_{\text{fit}}$	適応度セット, その問題数 (100)
$\mathcal{D}_R(S, q)$	連合 S による R ラウンド議論の多数決回答
$v(S)$	特性関数 (連合 S の適応度セット精度, $v(\emptyset) = 0$)
ϕ_c	候補 c の厳密 Shapley 値
$d(c, c')$	行動距離 (solo 予測の不一致率)
σ_{share}	fitness sharing の niche 半径 (0.3)
$F(c)$	最終適応度 $\phi_c \cdot s(c)$
G, R	世代数 (6), 議論ラウンド数 (1)

- **round 0 (独立回答)**: 各エージェント $a_i = (x_i, \pi_{r_i})$ は, システムプロンプト (ペルソナ π_{r_i} + 回答形式指示) と質問のみを入力として独立に段階的推論と回答を生成する. 初期回答の多様性が MAD 成功の主要条件であるとの報告 [31] に従い, 独立生成を厳格に保つ.
- **round 1... R (批判的更新)**: 各エージェントに, **他エージェントの直前ラウンドの発話全文**を提示し, 「他者の推論の誤りを指摘した上で, 自身の解答を更新 (または維持) せよ」と指示して回答を再生成する. 自己の過去発話は再提示せず, 各ラウンドは対話履歴を持たない独立の単一ターン呼び出しとして実装する. ラウンド数はラウンド追加が逆効果になるとの報告 [30] に基づき $R \in \{1, 2\}$, 既定 $R = 1$ とする.

各生成には温度 $\tau = 0.7 \cdot \text{top-p } 0.9$ のサンプリングを用い, 乱数シードはエージェント添字 i とラウンド添字 ρ に応じて $\text{seed}' = \text{seed} \cdot 10^4 + 100i + \rho$ と系統的にずらす. これにより同一重み・同一プロンプトの構成 (第 4 章の温度サンプリング対照条件) でも初期回答の多様性が確保され, かつ全実行が再現可能になる.

回答抽出と集約. 各エージェントの最終ラウンド発話から, 厳密な書式指示 ANSWER: <値>に対する正規表現で最終回答を抽出する (抽出不能な発話は無効

票とする)。集約は**最終ラウンド回答の多数決**であり、同数の場合は候補を辞書順に整列した上でシード付き乱数により一様を選ぶ。

judge（審判）エージェントによる集約を採用しない根拠は二つある。第一に、MAD の性能利得の大半は議論そのものではなく多数決集約で説明されるという分析 [29]、および推論タスクでは合意形成プロトコルより投票が一貫して優れるという比較実験 [30] があり、集約規則としての多数決の優位が示されている。第二に、議論の最終決定を担うエージェントの判定能力がチーム性能を左右する（意思決定者がボトルネックとなる）ことが報告されており [53]、本研究のように 4B 級の小型モデルのみでチームを構成する設定では特に深刻である。また、言語化された確信度（confidence）は過信バイアスを持つため主集約には用いない。

なお $|S| = 2$ の連合では多数決が常に同数となり得るため、実効的には「一致すればその回答、不一致ならシード付き乱数で一方を選択」という規則になる。これは Shapley 値算出（3.3 節）に必要な中間連合の評価としてプロトコルの一貫性を優先した設計である。

3.3 適応度関数

3.3.1 特性関数と厳密 Shapley 値

候補 c （役割 r ）の適応度の中核は、代表チーム文脈 $T(c) = \{c, \rho_1, \rho_2\}$ （ ρ_1, ρ_2 は他 2 役割の代表）上の**厳密 Shapley 値** [20] である：

$$\phi_c = \sum_{S \subseteq T(c) \setminus \{c\}} \frac{|S|!(n - |S| - 1)!}{n!} (v(S \cup \{c\}) - v(S)), \quad n = 3. \quad (3.5)$$

$n = 3$ を展開すると、係数は $|S| = 0, 1, 2$ に対しそれぞれ $\frac{1}{3}, \frac{1}{6}, \frac{1}{3}$ であり、

$$\begin{aligned} \phi_c = & \frac{1}{3}v(\{c\}) + \frac{1}{6}[v(\{c, \rho_1\}) - v(\{\rho_1\})] + \frac{1}{6}[v(\{c, \rho_2\}) - v(\{\rho_2\})] \\ & + \frac{1}{3}[v(T(c)) - v(\{\rho_1, \rho_2\})] \end{aligned} \quad (3.6)$$

となる。必要な特性関数値は 3 エージェントの全非空連合 $2^3 - 1 = 7$ 個であり、本研究ではこれを**すべて実測**する。すなわち Monte Carlo 近似や Leave-One-Out (LOO) 近似 [22] を一切用いず、公理的に一意的な貢献配分を厳密に得る。エージェント数を 3 に限定した設計判断は、(i) Du らの標準構成であり奇数のため多数決

が機能しやすいこと, (ii) 2^n に指数増加する連合評価が $n = 3$ でのみ実測可能な規模に収まること, の二点による.

Shapley 値を採る理論的根拠は, 効率性 ($\sum_i \phi_i = v(N) - v(\emptyset)$)・対称性・null player・線形性の 4 公理を同時に満たす唯一の配分規則である点にある [20, 21]. 特に LOO 型の寄与度 $v(N) - v(N \setminus \{c\})$ は, 行動が同型な個体 (複製) が連合に共存すると双方に寄与 0 を割り当てるという既知の欠陥を持つ [21]. 進化計算では集団内に類似個体が発生しやすいため, この欠陥は選択圧を系統的に歪める. Shapley 値はすべての部分連合にわたる限界貢献の加重平均であるため複製に対しても頑健である.

また, 式 (3.6) の第 1 項が示すとおりの ϕ_c は $v(\{c\})$ (solo 精度) を重み $\frac{1}{3}$ で内包する. したがって個体タスク性能を別項として適応度に加算する必要はなく, 「個体性能 + 協調寄与」が単一のスカラーに公理的に統合される. これが個体性能のみを適応度とする先行研究 (GENOME[13]) との本質的な差分であり, この差分はアブレーション A1 (適応度を $v(\{c\})$ に置換) として直接検証可能な設計とした (実施状況は §4.3).

3.3.2 Fitness sharing と行動距離

Shapley 値のみを選択圧とすると, 役割内の個体が同一の行動様式に収束し, 進化の探索が早期に停滞する恐れがある. そこで Goldberg と Richardson の fitness sharing[23] による乗法ペナルティを導入する. 同役割サブ集団内の個体間の**行動距離**を, 適応度セット上の solo 予測の不一致率

$$d(c, c') = \frac{1}{|D_{\text{fit}}|} \sum_j \mathbf{1}[\hat{y}_j(c) \neq \hat{y}_j(c')] \quad (3.7)$$

($\hat{y}_j(\cdot)$ は問題 j に対する solo 抽出回答) と定義し, sharing 係数を

$$s(c) = \frac{1}{1 + \sum_{c' \in P_r^{(t)} \setminus \{c\}} \max\left(0, 1 - \frac{d(c, c')}{\sigma_{\text{share}}}\right)}, \quad \sigma_{\text{share}} = 0.3 \quad (3.8)$$

とする. 分母は c の属する niche の実効個体数 (niche count) であり, 行動距離が σ_{share} 未満の同役割個体が近くに多いほど適応度が割り引かれる. 最終的な適応度は

$$F(c) = \phi_c \cdot s(c) \quad (3.9)$$

である．行動距離の計算に必要な solo 予測は Shapley 値算出時の単独連合評価 ($v(\{c\})$ の実測) の副産物として得られるため，追加の推論コストは発生しない．重み空間のパラメータ距離ではなく行動空間の距離を用いるのは，LoRA の再パラメータ化不変性 (3.4.3 項) によりパラメータ距離が表現型の差を反映しないためである．

重要な注意 (実装構成による選抜中立性)： 本実験の役割内サブ集団は $K = 2$ である (§3.4)．このとき式 (3.8) の和は相手 1 個体との距離のみからなり， $d(a, b) = d(b, a)$ の対称性から **2 個体の sharing 係数は常に同値**になる．乗法ペナルティは正の定数倍として順位を保存するため，役割内選抜 ($\arg \max_c F(c)$) は Shapley 値のみの選抜と完全に一致する．すなわち **fitness sharing は $K = 2$ の本構成では選抜に作用しない**．この帰結は執筆後の検証で判明したものであり，実際の進化ログにおける事後検証 (全 18 ケースで係数が役割内同値・選抜順位不変) を §4.6.6 に示す．sharing を設計意図どおり機能させるには $K \geq 3$ が必要であり，本章の記述は「導入した設計」として残すが，実験結果の解釈において sharing の効果を主張することはできない．

3.3.3 多様性を加算しない設計判断

多様性の扱いとして「適応度 = 性能 + λ · 多様性」という加重和がしばしば用いられるが，本研究はこれを採用しない．根拠は二系統ある．第一に，Quality-Diversity 文献の中核である MAP-Elites[16] は，多様性を目的関数に加算するのではなく行動記述子による niche 分離 (アーカイブ) として性能最適化から構造的に分離すべきであると論じており，Novelty Search[46] 以来の知見として，加重和は探索の欺瞞性 (deception) を単に係数 λ の調整問題にすり替えるに過ぎない．第二に，アンサンブル学習の統一理論 [17] は，多様性が bias · variance と並ぶ第三の項として汎化誤差分解に現れる**トレードオフの管理対象**であり，無条件に最大化・加算すべき量ではないことを数学的に示した．加重和はさらに，目的間のスケール不整合と係数の恣意性，非凸 Pareto 前線を表現できないという多目的最適化上の既知の限界 [47] も抱える．

そこで本研究は，(i) 選択圧そのものはチーム貢献 ϕ_c に一元化し，(ii) 多様性は fitness sharing の**乗法ペナルティ**として「同一 niche への密集」を抑制する形でのみ作用させる，という分離設計を採用．乗法形式は性能と多様性の単位の混合を避け， ϕ_c の順位構造を niche 内でのみ再調整する．ただし前項末尾に述べたとお

り、この設計は $K = 2$ の本実験構成では選抜中立であり（アブレーション A2 の sharing 無効化も同構成では自明に無差になる）、多様性維持機構としての実効性の検証は $K \geq 3$ での再実験に委ねられる。

3.4 進化アルゴリズム

3.4.1 協調的共進化の構造

全体構造は Potter と De Jong の協調的共進化 [19] に従い、3 役割それぞれに独立のサブ集団 $P_r^{(t)}$ （各 $K = 2$ 個体、計 6 LoRA）を保持する。各候補の評価は 3.1.2 項の代表チーム文脈で行う。すなわち候補 c は「他役割の現代表 $\rho_{r'}$ と組んだときにチームへどれだけ貢献するか」で測られ、役割間の相互適応がチームレベルの選択圧として実現される。代表を固定する評価方式は、Population Based Training[45] の exploit（良い個体の活用）に対応し、評価対象の組合せ爆発を防ぐ。

初期化（世代 0）．役割別 SFT データ（各 60 例）で QLoRA 学習した 3 個体を各役割の初期代表とし、さらに各個体に全テンソル対象のガウス突然変異（変異率 $\rho_{\text{mut}} = 1.0$ 、3.4.4 項と同一の相対ノイズ幅）を施した変異体を 1 個体ずつ加え、各役割 $K = 2$ の初期サブ集団を構成する。

3.4.2 選抜とエリート保存

世代 t において、役割 r の全候補の適応度 $F(c)$ を計算した後、役割内で最良の個体を次期代表に選ぶ:

$$\rho_r^{(t+1)} = \arg \max_{c \in P_r^{(t)}} F(c). \quad (3.10)$$

選ばれた代表は**エリート保存**により無変更のまま次世代サブ集団に残る。これは突然変異による劣化がチーム全体へ伝播することを防ぐための設計である。ただし候補の適応度は「他役割の**現代表**と組んだ文脈」で測られ、この評価文脈（他役割の代表と sharing の対象個体）は世代ごとに変わるため、エリート保存があっても代表系列の適応度の単調非減少は保証されない点に注意する（実測でも同一個体の測定チーム精度は世代間で $\pm 4 \sim 7$ pt 変動した; §4.6.2）。

3.4.3 交叉: ΔW 空間ブレンドとランダム化SVD再分解

交差項問題. LoRA 個体の交叉として最も素朴なのは, 行列 A, B を別々に線形補間する方式 (naive 方式) である:

$$A' = (1 - \alpha)A_1 + \alpha A_2, \quad B' = (1 - \alpha)B_1 + \alpha B_2. \quad (3.11)$$

しかしこのとき実効更新は

$$\Delta W_{\text{naive}} = B'A' = (1 - \alpha)^2 B_1 A_1 + \alpha^2 B_2 A_2 + \alpha(1 - \alpha)(B_1 A_2 + B_2 A_1) \quad (3.12)$$

となり, 意図した補間 $(1 - \alpha)\Delta W_1 + \alpha\Delta W_2$ とは一致しない. 両親の寄与が二乗係数で縮み ($\alpha = 0.5$ で各 0.25), さらに意味を持たない交差項 $B_1 A_2, B_2 A_1$ が混入する. 加えて LoRA 分解には再パラメータ化の自由度があり, 任意の正則行列 R に対して $BA = (BR)(R^{-1}A)$ が同一の ΔW を与えるため, A, B を別々に扱う演算は同一個体の等価な表現の間でも結果が変わってしまう. KnOTS[24] は, 独立に学習された LoRA 由来の ΔW は互いの整合 (alignment) が低く, この種の素朴なパラメータ空間マージが性能劣化の主因になることを示している.

提案する交叉 (ΔW 空間ブレンド + SVD 再分解). 本研究の主方式は, 補間を再パラメータ化不変な ΔW 空間で行う. 各モジュール m について:

1. 実効更新行列を補間する:

$$\Delta W'^{(m)} = (1 - \alpha) B_1^{(m)} A_1^{(m)} + \alpha B_2^{(m)} A_2^{(m)}, \quad \alpha \sim \mathcal{U}(0.3, 0.7). \quad (3.13)$$

2. $\Delta W'^{(m)}$ をランダム化SVD[54] (oversampling $q = \min(r + 8, \min(d_{\text{out}}, d_{\text{in}}))$, power iteration 4 回) で分解し, 上位 r 成分 $U_r \Sigma_r V_r^\top$ に切り詰めて子の LoRA 行列対を再構成する:

$$B'^{(m)} = U_r \Sigma_r^{1/2}, \quad A'^{(m)} = \Sigma_r^{1/2} V_r^\top. \quad (3.14)$$

これにより子の実効更新 $B'A' = U_r \Sigma_r V_r^\top$ は, 補間された $\Delta W'$ の Frobenius ノルム最良 rank- r 近似 (Eckart–Young の意味で, ランダム化SVDによる近似精度の範囲内) となり, 交差項の混入と再パラメータ化依存性の両方が排除される. 特異値の平方根を A, B に均等配分するのは, 両行列のスケールを揃え後続の突然変異ノイズ (テンソルの標準偏差に対する相対スケール) が偏らないようにするた

めである．親同士の rank と対象モジュール集合の一致は実行時に検証する．naive 方式は実装内に保持し，アブレーション A3 として比較可能な形にした．

交叉の親選択． 役割 r の子は，次期代表 $\rho_r^{(t+1)}$ を第一親，同役割サブ集団の残余個体のうち適応度最良のものを第二親として生成する（ $K = 2$ では残余は 1 個体）．混合比 α は世代・役割ごとに $\mathcal{U}(0.3, 0.7)$ から再抽出する．

3.4.4 ガウス突然変異

交叉で得た子アダプタの各テンソル W_k に対し，独立に確率 $\rho_{\text{mut}} = 0.3$ で加法的ガウスノイズを付加する：

$$W_k \leftarrow W_k + \varepsilon_k, \quad \varepsilon_k \sim \mathcal{N}(0, (\sigma_{\text{mut}} \cdot \text{std}(W_k))^2 I), \quad \sigma_{\text{mut}} = 0.02. \quad (3.15)$$

ノイズ幅を各テンソルの経験標準偏差 $\text{std}(W_k)$ に対する相対値とすることで，層・モジュールごとに大きく異なるパラメータスケールに自動適応する．突然変異はシード指定により完全に再現可能である．

3.4.5 世代ループ全体

以上を統合した手続きを Algorithm 1 に示す．世代数は $G = 6$ とする．次世代サブ集団は各役割とも「エリート代表 1 + 交叉・突然変異による子 1」の $K = 2$ 構成である．

全個体は vLLM の動的 LoRA ロード API により同一サーバへ世代ごとに登録され，進化は勾配計算を一切伴わない（重み操作は交叉・突然変異のみ）．世代ごとの評価ログ（各候補の ϕ_c ，solo 精度，チーム精度，全連合精度，sharing 距離，選抜結果）は JSON として逐次永続化され，Spot インスタンスのプリエンプション後も再開可能である．

3.5 計算量の分析

連合評価数． 本手法の支配的コストは LLM 推論による連合評価である．候補 1 個体あたり必要な連合は $2^3 - 1 = 7$ だが，代表チーム文脈の構造上，多くの連合が候補間で共有される．世代内の連合評価キャッシュを用いると，代表のみからなる連合（solo 3 + 対 3 + 3 体 1 の計 7 個）は全候補で共有され，代表でない候補（各

Algorithm 1 チームレベル Shapley 適応度による協調的共進化

Require: 役割別 SFT 済み LoRA $\{x_r\}_{r \in \mathcal{R}}$, 適応度セット D_{fit} , 世代数 G , ラウンド数

$R, \sigma_{\text{share}}, \rho_{\text{mut}}, \sigma_{\text{mut}}$

Ensure: 最終世代の代表チーム $\{\rho_r^{(G)}\}_{r \in \mathcal{R}}$

```
1: for  $r \in \mathcal{R}$  do
2:    $P_r \leftarrow \{x_r, \text{Mutate}(x_r; \rho=1.0, \sigma_{\text{mut}})\}$ ;  $\rho_r \leftarrow x_r$  { 世代 0 の初期化 }
3: end for
4: for  $t = 0, \dots, G - 1$  do
5:   連合評価キャッシュ  $C \leftarrow \emptyset$ 
6:   for  $r \in \mathcal{R}, c \in P_r$  do
7:      $T(c) \leftarrow \{c\} \cup \{\rho_{r'} \mid r' \neq r\}$  { 適応度評価 }
8:     for all  $S \subseteq T(c), S \neq \emptyset$  do
9:       if  $S \notin C$  then
10:         $C[S] \leftarrow v(S)$  { debate/solo を実測 }
11:       end if
12:     end for
13:      $\phi_c \leftarrow \text{Shapley}(c, \{C[S]\})$  { 式 (3.5) }
14:   end for
15:   for  $r \in \mathcal{R}, c \in P_r$  do
16:      $d(c, c') \leftarrow \text{solo 予測不一致率 } (C \text{ の副産物})$  { fitness sharing }
17:      $F(c) \leftarrow \phi_c \cdot s(c)$  { 式 (3.8), 式 (3.9) }
18:   end for
19:   for  $r \in \mathcal{R}$  do
20:      $\rho_r \leftarrow \arg \max_{c \in P_r} F(c)$  { 選抜 (エリート保存) }
21:   end for
22:   if  $t < G - 1$  then
23:     for  $r \in \mathcal{R}$  do
24:        $p \leftarrow \arg \max_{c \in P_r \setminus \{\rho_r\}} F(c)$  { 次世代生成 }
25:        $\alpha \sim \mathcal{U}(0.3, 0.7)$ 
26:        $child \leftarrow \text{Mutate}(\text{DeltaBlendSVD}(\rho_r, p, \alpha); \rho_{\text{mut}}, \sigma_{\text{mut}})$ 
27:        $P_r \leftarrow \{\rho_r, child\}$ 
28:     end for
29:   end if
30: end for
31: return  $\{\rho_r\}_{r \in \mathcal{R}}$ 
```

役割の子，計 m 個体）だけが固有の連合（自身の solo 1，代表との対 2，3 体 1 の計 4 個）を追加する．したがって世代あたりの実評価数は

$$N_{\text{coal}} = 7 + 4m \quad (3.16)$$

であり， $K = 2$ （役割あたり非代表候補 1）では $m = 3$ ， $N_{\text{coal}} = 19$ となる．キャッシュがなければ $6 \times 7 = 42$ 評価が必要であり，共有キャッシュにより約 55% が削減される．なおエリート代表自身も候補として評価されるが，その代表チーム文脈は代表のみの 7 連合と完全に一致するため追加コストを生まない．

LLM 呼び出し数． 連合 S の 1 問題あたりの生成回数は $|S| \cdot (R + 1)$ （round 0 + R ラウンド，各ラウンドで全員が 1 生成）である． $R = 1$ ， $N_{\text{fit}} = 100$ のとき，世代あたりの呼び出し数は

$$\underbrace{100 \times (3 \cdot 1 + 3 \cdot 4 + 1 \cdot 6)}_{\text{代表のみの 7 連合}} + \underbrace{3 \times 100 \times (1 \cdot 1 + 2 \cdot 4 + 1 \cdot 6)}_{\text{子 3 個体の固有 12 連合}} = 2,100 + 4,500 = 6,600 \quad (3.17)$$

であり， $G = 6$ 世代の進化全体で約 4.0×10^4 回（各生成は最大 512 トークン）となる．問題間は独立なため，クライアント側で問題単位に並列化（既定 16 並列）し，vLLM サーバの連続バッチングで吸収する．

その他のコスト． 厳密 Shapley 値の計算自体は $n = 3$ の全部分集合和で $O(2^n)$ だが $n = 3$ では無視できる．fitness sharing の行動距離は solo 評価の per-item 予測を再利用するため追加推論はゼロである．交叉のランダム化 SVD は各モジュールの $d_{\text{out}} \times d_{\text{in}}$ 行列に対する rank- $(r + 8)$ 分解であり，全体で CPU 数十秒程度と，推論コストに対して無視できる．進化全体で学習（勾配更新）は世代 0 の QLoRA 学習のみに限られる点が，RL による議論最適化（MAPoRL[12]）と対照的な本手法の計算的特徴である．

第4章 評価実験

本章では、第3章の提案手法を検証するための実装、ベンチマークと評価プロトコル、比較条件、統計設計、およびハイパーパラメータを述べる。本章の記述はすべて公開実装（`scripts/train_lora_persona.py`, `scripts/run_evolution.py`, `scripts/run_eval.py`, `scripts/run_eval_battery.py`, `scripts/cloud/`）と一致する。未実施の実験結果には言及しない。

4.1 実装

4.1.1 ベースモデルと QLoRA 学習

ベースモデルには **Qwen3-4B-Instruct-2507**[18]（Apache-2.0, Hugging Face 上でゲートなし公開）を用いる。4B級を選ぶ理由は、(i) 同規模帯では「素の debate が性能を悪化させる」ことが報告されており [11, 10]、チームレベル選択圧が debate を機能させるかという研究課題の検証に適した困難条件であること、(ii) 公表ベンチマーク値（MMLU-Pro 69.6, SuperGPQA 42.8）に改善余地が残ること、(iii) 進化ループで多数の LoRA を単一 GPU 上に同時サービングできる計算規模であることによる。

世代0の3個体（critic / pragmatist / explorer）は、役割別 SFT データ（各60会話例, JSONL形式, チャットテンプレート適用）を用いた **QLoRA**[55] で学習する。設定は以下のとおりである。

- **量子化**: ベースモデルを 4bit NF4 (double quantization 有効) でロードし、計算 dtype は GPU に応じて bfloat16 (A100 等) または float16 (T4, compute capability 7.5 のため bf16 非対応) へ自動フォールバックする。
- **LoRA 構成**: rank $r = 32$, $\alpha_{\text{LoRA}} = 2r = 64$, dropout 0.05, 対象モジュールは全層の q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj の7種。

- **最適化:** 学習率 2×10^{-4} , エポック数 3 (Vertex AI ジョブ投入設定. 学習スクリプト単体の既定値は 1), デバイスあたりバッチサイズ 1, 勾配累積 16, `paged_adamw_32bit`, `gradient_checkpointing` 有効 (学習時は KV キャッシュを無効化して競合を回避), `packing` 無効.
- **再現性:** グローバルシード 1234 (Python / NumPy / PyTorch / CUDA を統一固定). 学習コマンド・シード・ハードウェア構成は `metadata.json` として成果物に同梱する.

各役割のペルソナは, SFT により重み空間に焼き込まれると同時に, 推論時にも短い役割記述 (例: 批判的検証者「厳密な検証を重視する批判的思考家. 反証・例外・境界条件に敏感」) をシステムプロンプトとして与える.

4.1.2 vLLM Multi-LoRA サービング

全推論 (進化ループの連合評価・最終評価とも) は vLLM[56] の OpenAI 互換 API を通じて行う. サーバは `--enable-lora`, `--max_loras 8`, `--max_lora_rank 64`, `--max_model_len 32768`, `tensor` 並列 1 で起動し, ベースモデルを 1 つだけ GPU に常駐させたまま, リクエストの `model` フィールドで LoRA アダプタを問い合わせ単位に切り替える. 進化ループで世代ごとに生成される子アダプタは, 動的 LoRA ロード API (`/v1/load_lora_adapter`, `VLLM_ALLOW_RUNTIME_LORA_UPDATING=True`) でサーバ再起動なしに登録する.

生成パラメータは, 進化ループ内では `temperature 0.7`・`top-p 0.9`・最大 512 トークン, 最終評価では Qwen3 の公式推奨に従い `temperature 0.7`・`top-p 0.8`・`top-k 20`・最大 8,192 トークンとし, いずれもシード指定付きとする (エージェント × ラウンド, および Self-Consistency のサンプル添字ごとに決定的にオフセット. 第 3 章 3.2 節). 進化ループと最終評価で生成条件が異なる点は本研究の限界として第 5 章で述べる. クライアントは問題単位で 16 並列のリクエストを発行し, vLLM サーバ側の連続バッチングで GPU 利用率を確保する. API 呼び出しは最大 3 回の線形バックオフ付きリトライで保護する.

4.1.3 Vertex AI Spot 構成とプリエンブション耐性

計算は GCP Vertex AI Custom Training の **Spot**（プリエンブティブル）ジョブとして実行する（プロジェクトのクォータ上、オンデマンド GPU VM は利用不可）。工程ごとの構成を表 4.1 に示す。

表 4.1: Vertex AI Spot ジョブの工程別マシン構成

工程	マシン構成	理由
QLoRA 学習（世代 0）	n1-standard-8 + NVIDIA T4 ×1 (Spot)	4bit 量子化により 6GB 級で学習可能。fp16 フォールバックで対応
進化ループ／最終評価	a2-highgpu-1g (A100 40GB ×1, Spot, us-central1)	vLLM の Multi-LoRA カーネル (Punica/Triton) が compute capability ≥ 8.0 を要求し T4 では動作しないため

成果物（アダプタ・評価 JSON・世代ログ）は GCS バケットに Cloud Storage FUSE マウント（/gcs/...）経由で保存する。Spot はいつでもプリエンブトされるため、すべての評価ランナーは**問題単位の逐次 JSONL キャッシュ**を持ち、再実行時には評価済み問題 ID をスキップして途中から再開する。最終評価は複数条件を 1 ジョブにまとめるバッチリードライバで実行し、完了済みエントリの JSON が存在すれば条件ごとスキップする。進化ループも世代ごとに全ログを JSON へ書き出し、任意の世代から再開可能である。

4.2 ベンチマークと評価プロトコル

4.2.1 ベンチマーク選定

最終評価は表 4.2 に示す 3 ベンチマークで行う。いずれも Hugging Face 上でゲートなしに取得できる（認証トークン不要の方針を維持する）。

GSM8K[61] はベースモデルで 80–92% と飽和しているため配管確認（スモークテスト）専用とし、主張には用いない。GPQA-Diamond[62] はデータセットが HF ゲート付きであるため不採用とする。

表 4.2: 最終評価に用いるベンチマーク

ベンチマーク	抽出方法	問題数	選定根拠
MMLU-Pro[57]	test 分割から固定ランダム抽出	500	ベースの公表値 69.6 で飽和しておらず, MAD による改善報告と接続可能. 10 択で当て推量の影響が小さい
MATH-500[58, 59] Level 4-5	Level 4 以上に限定して抽出	200	数学推論は MAD の改善効果が最大と報告される領域. 高難度に限定して天井効果を回避
SuperGPQA[60]	固定ランダム抽出	300	ベースの公表値 42.8 と最も余地が大きい. 大学院水準の広分野知識推論

4.2.2 生成型評価と回答抽出

評価は lm-evaluation-harness 型の選択肢対数尤度方式ではなく, **生成型 (generative) 評価**で統一する. solo 条件と debate 条件を同一プロトコル・同一抽出口ジックで比較するためには, 両者とも自由生成テキストから回答を取り出す必要があるからである. 全エージェントに厳密な書式指示

Think step by step. Then give your final answer on the last line in exactly this format:

ANSWER: <letter | number | final simplified answer>

を与え, 出力末尾の ANSWER: 行を正規表現で最優先抽出する. ANSWER: 行が欠落した場合に限り, 文脈条件付きのフォールバック (選択肢タスクでは “answer is (X)” 等のパターン, 数値タスクでは最後の数値, 数式タスクでは最後の `\boxed{}`) を適用する. 数式回答は LaTeX 表記の正規化 (`\frac`→`/`, `\sqrt`→`sqrt()`), 数値の同値判定 (`12.0 = 12` 等) を経て比較する. 抽出不能な出力は無効票 (多数決から除外) とし, 単独評価では不正解として扱う. **すべての比較条件で同一の抽出・正規化・採点コードを共有し, 条件間の差が抽出ロジックの差に混入しないことを保証する.**

4.2.3 進化ループ内の適応度セット

進化ループの選択圧 (第 3 章の $v(S)$ 計測) には, MMLU-Pro test 分割 (約 12,000 問) から専用シード (777) で抽出した**固定 100 問**を全世代共通で用いる. 100 問という規模は, tinyBenchmarks[48] が示した「キュレートされた 100 例でフルベンチマークのスコアを平均誤差約 2% で推定できる」という結果に基づく. 適応度

セットは世代間の順位付け専用であり、その絶対値は主張に用いない。最終評価とはシード系列を分離して抽出するため（最終評価はシード 1–3）、標本の系統的な共有はないが、母集合が共通のため偶発的な重複は起こりうる（期待重複は 500 問抽出あたり約 4 問、1%未満）。適応度セットへの選択圧の過適合（進化版の「テストへの学習」）が疑われる場合に備え、最終評価がこの 100 問を含まない形でも集計できるよう問題 ID を全ログに記録する。

4.3 比較条件

最終評価は表 4.3 に示す 8 条件で行う（研究設計書 §6.2 の条件 1–6 に、プロンプトペルソナの寄与を分離する条件 3' と実験 2 の条件 7[‡] を追加。設計書の条件 7 = solo 適応度進化 A1 は未実施）。全条件で同一の問題集合・同一シード・同一抽出ロジックを用い、問題単位で対応づけ（paired）が可能な設計とする。debate 条件のラウンド数は $R = 1$ に統一する。

なお研究設計段階では solo 適応度への置換（A1）、fitness sharing 無効化（A2）、naive 交叉（A3）のアブレーションを計画し実行フラグとして実装したが（第 3 章参照）、実験 1 で進化の寄与自体が限定的（§4.6.1）と判明したため、計算資源を実験 2（処方箋の検証）に振り向け、これらは未実施である。この判断の含意は第 5 章で論じる。

4.4 統計設計

統計処理は Miller[49] の評価統計 5 原則（標準誤差の併記・クラスタ構造の考慮・リサンプルの扱い・paired 分析・検出力設計）に準拠する。

- **シードと反復**: 主要比較は $K = 3$ シード (1, 2, 3) で反復する。各（シード、問題）対は両条件で同一の生成条件を共有するため、対応ありデータとして扱う。
- **主検定（クラスタ構造の考慮）**: 同一問題への複数シードの回答は関連する反復測定であり、（シード、問題）対を独立観測とみなしてプールする検定は独立性の仮定を満たさない [49]。そこで主解析は**問題 ID をクラスタ単位**とし、問題ごとにシード平均を取った精度差 Δ_i に対する**クラスタ符号反転置**

表 4.3: 最終評価の比較条件

#	条件	構成	目的
1	ベース solo CoT	ベースモデル単体, ペルソナなし	絶対的な基準線
2	Self-Consistency@9	ベースモデルから 9 サンプル → 多数決 [8]	生成回数を揃えた非協調ベースライン. 3 エージェント × 最大 3 生成 (round 0 + 2 ラウンド) = 9 生成に相当. 既定 $R = 1$ では debate 側は 6 生成/問であり, SC@9 はベースライン側に生成回数で有利な保守的設定 (実測トークンでも SC@9 が総量で上回る; §4.6.6). 「MAD は計算量を揃えた SC に勝てない」という批判 [7] への直接の対処
3	ベース ×3 温度サンプリング debate	同一ベースモデル 3 体 (ペルソナプロンプトなし, シードオフセットのみ)	サンプリング多様性のみの debate (Self-MoA 型対照)
3'	ベース ×3 プロンプトペルソナ debate	同一ベースモデル 3 体 + 役割プロンプト	プロンプトによるペルソナ付与の寄与を分離 (重み焼き込み vs プロンプトの対照)
4	gen-0 LoRA チーム debate	SFT 直後の 3 ペルソナ LoRA	進化前のチーム性能. 条件 5 との差が進化の寄与
5	進化後チーム debate (主要条件)	提案手法 (Shapley + sharing, $G = 6$ 世代) の最終代表チーム	本研究の主張の中核
6	進化後 LoRA solo ×3	条件 5 の各個体を単独評価	チーム効果 (協調による上乘せ) と個体改善の分離
7 [‡]	再学習チーム debate (実験 2)	能力保持リプレイで再学習した 3 ペルソナ LoRA + 条件付き更新 + 匿名化 + logprob 重み付き投票	実験 1 の診断 (§4.6.2) に基づく処方の検証. ゲート方式 (§4.6.3) で各構成要素を検収した上での最終形

換検定 (20,000 回) で p 値を, クラスタブートストラップ (問題単位の再抽出, 10,000 回) で 95%信頼区間を求める. 参考値として (シード, 問題) 対プールの McNemar 正確検定 [50] も併記するが, その p 値は反保守的であるため結論には用いない¹.

- **同等性の主張:** 差の検定で有意でないことは同等性の証拠にならないため, 同等性を主張する場合は等価マージンを $\pm 2\text{pt}$ (本研究で意味があるとみなす最小効果量より小さい値) と定義した TOST 型判定——クラスタブートストラップの 90%信頼区間が $\pm 2\text{pt}$ に収まるか——を用いる.
- **多重比較補正:** 主要な仮説検定は各実験でプール比較 6 件とし, **Holm–Bonferroni 法** [63] で family-wise error rate を 5%に制御する. ベンチマーク別の内訳検定およびそれ以外の比較は探索的分析と位置づける.
- **頑健性確認:** 実験 2 の主検定 (条件 7[‡] vs SC@9) が 3 シードで境界的 ($p = 0.053$) となったため, **効果の維持を確認する目的を事前に明記した上で** seed 4–6 を追加し, 3 シード単独と 6 シード合算の両方を報告する. このシード追加は結果を見た後の逐次的な標本拡大 (optional stopping) に該当するため, 6 シード合算の p 値を確認的検定として扱うには本来逐次検定補正を要する. 本研究では補正を行わない代わりにこの経緯を明示し, かつ最終的な結論 (条件 7[‡] の有意な劣位) が標本拡大により**棄却側に不利な方向へ**確定した——すなわち optional stopping が偽陽性を利する典型的な構図とは逆である——ことを付記する.
- **開発と評価の分離:** 実験 2 の全ての設計選択 (リプレイ比率・集約方式・議論プロトコル) は, 最終評価と重複しない検収セット (seed 9) 上のゲート (§4.6.3) で確定してから最終評価に進んでおり, 最終評価セットへの適合を構造的に排除している.
- **検出可能効果量:** 対応あり検定 ($\alpha = 0.05$, 検出力 80%) の目安は $+10\text{pt} \rightarrow N \approx 180$, $+7\text{pt} \rightarrow N \approx 360$, $+5\text{pt} \rightarrow N \approx 700$ である. 3 ベンチマーク統合 ($N = 500 + 200 + 300 = 1,000$ 問, $K = 3$ シードによる分散低減を含

¹初稿では (シード, 問題) プールの McNemar 検定を主解析としていたが, 反復測定の間接相関を無視する点が不適切であるため, 問題 ID クラスタリングを考慮した解析へ差し替えた. 有意性の判定はいずれの解析でも変わらなかった. なお両者は推定対象が僅かに異なる (プールは観測単位, クラスタ解析は問題単位の平均差) ため点推定値も僅かに異なる.

む) では+4~5pt 程度の効果が検出可能であり, Du らが報告する MAD の効果量 (7~15pt) に対して十分な感度を持つ.

- **実行記録と再現性の限界:** 全実行についてシード・モデル revision・vLLM バージョン・生成パラメータ・問題 ID リストを結果 JSON に記録する. ただし同一シードを指定しても vLLM の生成は並列実行状態に依存して完全には再現しない (§4.6.4) ため, これらの記録が担保するのは監査可能性であり, ビット単位の再現ではない.

議論品質の LLM-as-judge 評価と世代を通じた行動多様性の推移分析は副次評価として計画したが, 測定環境の統制 (§4.6.4) に伴う再測定を優先したため未実施である.

4.5 ハイパーパラメータ

以下の値はすべて実装のデフォルト値 (コマンドライン引数の既定値, および Vertex ジョブ投入スクリプトの設定値) と一致する. QLoRA 学習の設定を表 4.4 に, 議論・生成の設定を表 4.5 に, 進化ループの設定を表 4.6 に, 最終評価の設定を表 4.7 に, サービング・インフラの設定を表 4.8 に示す.

表 4.4: QLoRA 学習 (世代 0) のハイパーパラメータ

項目	値
ベースモデル	Qwen/Qwen3-4B-Instruct-2507
量子化	4bit NF4, double quantization, 計算 dtype bf16 (T4 では fp16)
LoRA rank r / α_{LoRA} / dropout	32 / 64 / 0.05
対象モジュール	q, k, v, o, gate, up, down の各射影 (全層)
学習率/エポック	2×10^{-4} / 3 (Vertex 投入設定; スクリプト既定 1)
バッチサイズ/勾配累積	1 / 16
最適化器	paged_adamw_32bit (gradient checkpointing 有効, packing 無効)
SFT データ	役割別 60 会話例 $\times$ 3 役割
シード	1234

表 4.5: 議論・生成のハイパーパラメータ

項目	値
temperature / top-p / 最大トークン	0.7 / 0.9 / 512
議論ラウンド数 R	1 (round 0 の独立回答 + 1 更新ラウンド)
集約	最終ラウンド多数決 (同数はシード付き乱数, 無効票は除外)
シードオフセット	エージェント $\times$ ラウンド: $\text{seed} \cdot 10^4 + 100i + \rho$; SC サンプル: $\text{seed} \cdot 10^3 + k$
クライアント並列数 / リトライ	16 / 3 回 (線形バックオフ)

表 4.6: 進化ループのハイパーパラメータ

項目	値
世代数 G	6
サブ集団構成	3 役割 $\times K = 2$ (エリート + 子) = 6 LoRA
適応度	厳密 Shapley 値 $\times$ fitness sharing (--fitness-mode shapley)
適応度セット	MMLU-Pro 100 問, シード 777 (最終評価とシード分離)
sharing σ_{share}	0.3
交叉	ΔW 空間ブレンド + ランダム化 SVD 再分解 (delta)
混合比 α	$\mathcal{U}(0.3, 0.7)$ から世代・役割ごとに抽出
SVD	oversampling +8, power iteration 4 回, rank 32 に切詰め
突然変異率 ρ_{mut} / 幅 σ_{mut}	0.3 / 0.02 (テンソル標準偏差に対する相対値)
世代 0 変異体	$\rho_{\text{mut}} = 1.0, \sigma_{\text{mut}} = 0.02$
進化シード	1234

表 4.7: 最終評価の設定

項目	値
ベンチマーク	MMLU-Pro 500 / MATH-500 (Level 4–5) 200 / SuperGPQA 300
シード	$K = 3$ (1, 2, 3. 問題抽出・生成・同数決着に 共通使用)
Self-Consistency	$k = 9$
bootstrap 反復	$B = 10,000$
多重比較補正	Holm–Bonferroni (各実験のプール比較 6 件)

表 4.8: サービング・インフラの設定

項目	値
vLLM	--enable-lora --max_loras 8 --max_lora_rank 64 --max-model-len 32768, TP=1
動的ロード	/v1/load_lora_adapter (VLLM_ALLOW_RUNTIME_LORA_UPDATING=True)
学習ジョブ	Vertex AI Spot, n1-standard-8 + T4 ×1
進化・評価ジョブ	Vertex AI Spot, a2-highgpu-1g (A100 40GB ×1), us-central1
成果物保存	GCS (Cloud Storage FUSE マウント), 問題 単位 JSONL 逐次追記による再開設計

実験2（再学習, §4.6.3）で表 4.4 から変更した項目を表 4.9 に示す。学習関連の変更は忘却の抑制（rank・エポック・学習率の低減は LoRA の忘却がこれらとともに増加するという知見に基づく）とリプレイ長 CoT の切り捨て防止（学習系列長）を、議論・集約関連の変更は §4.6.3 の処方をそれぞれ目的とする。

表 4.9: 実験2の再学習で変更したハイパーパラメータ

項目	実験1（世代0）	実験2（再学習）
学習データ	ペルソナ例 60 例	ペルソナ例 60 例 + リプレイ 36 例（約 30%）
LoRA rank / α	32 / 64	16 / 32
エポック数	3	2
学習率	2×10^{-4}	1×10^{-4}
学習系列長上限	1,024 トークン（フレームワーク既定）	8,192 トークン
議論の更新指示	標準（自由更新）	条件付き（自己誤り特定時のみ変更可）
発言の提示	役割名付き	匿名化 + 提示順シャッフル
チーム集約	多数決	logprob 重み付き投票

4.6 実験結果

本節では実験を2段階に分けて報告する。**実験1**は §4.3 の比較条件による主実験であり、チーム化の効果と進化的最適化の寄与を測定するとともに、敗因の診断

(損失分解)を行う。実験2は実験1の診断に基づく処方(能力保持リプレイ・検証型集約・議論プロトコル改良)を、実測ゲート方式で検証する追加実験である。

4.6.1 実験1: 主実験の結果

表4.10に全条件の精度($K=3$ シード平均)を示す。いずれの条件も回答抽出失敗率は3%以下であり、条件間の非対称性はない。

表 4.10: 実験1の主要結果(精度, $K=3$ シード平均)

条件	MMLU-Pro	MATH-500	SuperGPQA
1: ベース solo	0.639	0.830	0.436
2: Self-Consistency@9	0.667	0.862	0.467
3: 素の議論	0.598	0.870	0.467
3': プロンプトペルソナ議論	0.624	0.860	0.466
4: gen-0 LoRA チーム	0.684	0.770	0.407
5: 進化後 LoRA チーム	0.683	0.813	0.399
6: 進化後 solo 最良	0.661	0.698	0.364

主要な検定結果(問題IDクラスタの符号反転置換検定, §4.4)は以下のとおりである。

- **チーム化の効果(MMLU-Pro)**: LoRA ペルソナチーム(条件4)はベース単体に対し+4.3pt [+2.0, +6.6] ($p=0.0004$)、素の議論に対し+8.4pt 相当の有意な優位を示した。
- **生成回数を揃えた比較**: 進化後チーム(条件5)はSC@9に対しMMLU-Proで+1.6pt(非有意)だが、3ベンチマーク全体では-1.8pt [-3.5, -0.2] ($p=0.028$)と**有意に劣った**。
- **進化の寄与**: 条件5と条件4の差はMATH-500の+4.3pt [+1.9, +6.8] ($p=0.0005$)のみ有意で、全体では+0.2pt(非有意)であった。
- **ベンチマーク依存性**: 素の議論はMATH-500で+4.2pt ($p=0.0003$)・SuperGPQAで+3.1pt ($p=0.020$)と有意に有効だが、MMLU-Proでは-4.1pt ($p=0.001$)と有意に有害だった。

すなわち実験1の結論は「LoRA ペルソナチームは知識推論（MMLU-Pro）でのみ有効であり，生成回数を揃えた Self-Consistency には総合で及ばない」である．

4.6.2 実験1の診断：損失分解

敗因を特定するため，各問題について「3体のうち少なくとも1体が正解した場合」（oracle 上限）を計算し，チーム誤差を（i）個体能力の損失，（ii）集約の損失に分解した（表 4.11）．

表 4.11: 損失分解（seed 1）：oracle 上限と集約損失

ベンチマーク	solo 平均	oracle	多数決	議論後	集約損失
SuperGPQA	0.335	0.517	0.363	0.387	-0.130
MMLU-Pro	0.673	0.800	0.702	0.714	-0.086
MATH-500	0.667	0.815	0.705	0.810	-0.005

全列 seed 1 の値．「多数決」は 3 体の solo 回答の多数決で，票が同数に割れた場合は固定シードの
一様乱択でタイブレイクする．

3つの発見が得られた．第一に，**個体能力の毀損**である．ペルソナ SFT 後の solo 精度はベース単体に対し SuperGPQA で -7.2pt，MATH-500 の Level 5 層で -27pt 低下していた．診断用に収集した生成ログの分析から，ペルソナ SFT（平均 779 字の短い応答のみで学習）がベースモデルの思考連鎖を中央値 2,423 字から 1,188 字へ圧縮しており，長い導出を要する問題で選択的に失敗することが確認された．第二に，**集約の損失**である．SuperGPQA では毀損した 3 体ですら oracle 上限が 0.517 とベース単体（seed 1 で 0.407）を +11pt 上回るにもかかわらず，多数決＋議論はその 38.7% しか回収していない．正解が少数派に留まる問題では多数決は構造的に失敗するうえ，議論が正しい多数派を崩す事例も確認された（MMLU-Pro 500 問中，議論前に多数派が正解だった問題のうち 26 問が議論後に不正解へ転じた）．一方 MATH-500 では集約損失がほぼゼロであり，検証可能な領域では正しい解が議論を通じて自然に採択されることを示す．第三に，**選抜ノイズ**である．進化ログの再分析により，適応度セット 100 問での測定は標準誤差 ± 4.9 pt を持ち，同一個体の測定チーム精度が世代間で $\pm 4 \sim 7$ pt 変動していた．毎世代の最大値選抜はノイズの上振れを拾う正のバイアス（勝者の呪い）を持ち，開発セットでの +12pt の改善が最終評価で ± 0 に消えた現象を説明する．さらに進化前後のアダプタを直接比較すると， ΔW の Frobenius ノルム比は全役割で 1.000 であるだけでな

く、 ΔW 同士の cosine 類似度も全役割・全 252 モジュールで 0.9996 以上（連結 ΔW で 0.9999–1.0001）であった．すなわち進化後の最終チームのアダプタは、重みとしては SFT 直後の gen-0 アダプタと実質的に同一である．演算子単位で測っても、突然変異 1 回で $\cos = 0.9997$ ，交叉 1 回で $\cos = 0.9998$ ，gen-1 から gen-5 までの 4 世代分でも $\cos = 0.9998$ であり、本実験の進化演算子（ノルム保存の相対スケール変異と $\alpha \in [0.3, 0.7]$ の内挿交叉）は重み空間をほとんど動かしていなかった．したがって MATH-500 で観測された進化の寄与 +4.3pt は、重み空間における意味のある移動（たとえば損傷成分の打ち消し）によるものとは考えにくく、固定された極小の重み摂動に対して生成過程が敏感に応答した結果——同一設定でも生成環境の違いにより +6pt 級の系統差が生じるという §4.6.4 の観察と同種の感度——として説明するのが最も保守的である（第 5 章で詳述）．

4.6.3 実験 2: 処方の検証（ゲート方式）

実験 1 の診断に基づき、以下の処方を実測ゲート方式（各段階に事前定義した合格基準を設け、不合格の変更は採用しない）で検証した．

G0（能力保持リプレイの生成） ベースモデル自身に MATH 訓練 split Level 4–5 および MMLU-Pro 検証 split の問題を解かせ、正解が検証できた長い思考連鎖 36 例（平均 6,503 字）を採取した．

G1（再学習と個体能力の検収） 既存ペルソナ例 60 例にリプレイ 36 例（約 38%）を混合し、rank 16・2 エポック・学習率 1×10^{-4} ・系列長 8,192 トークンで 3 ペルソナを再学習した（run002）．solo 精度は MMLU-Pro 0.665–0.695，MATH-500 0.775–0.845，SuperGPQA 0.405–0.440 となり、全ベンチマークで事前基準（0.63/0.75/0.37）を満たした．**能力毀損は事前基準を満たす水準まで回復し、一部はベース単体を上回った．**

G2（集約方式の選定） 議論プロトコルに条件付き更新（自己の誤りを特定できた場合のみ回答変更を許可）と発言の匿名化を導入した上で、SuperGPQA 150 問で集約方式を比較した．結果は多数決 0.433・logprob 重み付き投票 0.440・GenSelect 型裁定 0.433 であり、重み付き投票を採用した（裁定型の上積みは確認されなかった）．

G3 (チーム性能の確認) 再学習チーム (以下**条件 7[‡]**: リプレイ再学習 × 条件付き議論 × 匿名化 × 重み付き投票) を seed 1 の 3 ベンチマークで評価し, MMLU-Pro 0.754 · MATH-500 0.855 · SuperGPQA 0.430 を得てゲートを通過した (この時点の比較対象は実験 1 の測定値であり, 後述 §4.6.4 の環境統制前である点に注意) .

4.6.4 測定環境の系統差の発見と統制

実験 2 の初期評価 (条件 7[‡] を 3 シードで評価し実験 1 の測定値と比較) では, 条件 7[‡] が SC@9 をプールで +1.3pt 上回る ($p = 0.053$; MMLU-Pro 単独では +5.5pt 相当) という境界的な結果が得られた. 効果の維持を確認する目的で seed 4–6 を追加したところ優位が消失し, さらに SC@9 の絶対精度がシード群間で不連続に変化する (MMLU-Pro で 0.66–0.69 → 0.71–0.76) という不自然なパターンが観察された. シード群の境界は評価用コンテナイメージの再ビルド時点と一致していた.

そこで同一問題・同一シード・同一生成設定で SC@9 を新旧両イメージで実行する統制実験を行った結果, **同一の 500 問に対し旧イメージ 0.688 ・新イメージ 0.752 と, イメージ差のみで +6pt 級の系統差が確認された** (予測の一致率は 86% に留まり, 生成自体が変化している). vLLM 本体のバージョンは固定 (v0.8.5) であり, 差はイメージ再ビルド時に更新された依存ライブラリに起因すると推定される. 興味深いことに, この系統差は**ベースモデルの素の生成に強く現れ (+8pt 級)**, **LoRA アダプタを適用した生成にはほとんど現れない** (旧チーム = 条件 5 の実験 1 進化後チームの MMLU-Pro は旧 0.714/新 0.712 とほぼ不変. 以下, 条件 5 を「旧チーム」, 条件 7[‡] を「再学習チーム」と呼ぶ) .

この発見を受け, 主要 4 条件 (ベース単体・SC@9・旧チーム・再学習チーム) を**新イメージに統一して全面的に再測定**し, 以降の比較はすべて同一環境の測定値のみで行う. なお実験 1 の内部比較 (§4.6.1–4.6.2) はすべて旧イメージ内の対応あり比較であるため結論は影響を受けないが, 実験 1 と実験 2 の数値の直接比較は不能である. また同一 seed を指定しても vLLM の生成は並列実行状態に依存して完全には再現しないことも確認しており, 評価インフラの再現性は小型 LLM 評価の系統誤差要因として軽視できない.

4.6.5 実験 2: 最終評価（同一測定環境）

新イメージに統一した最終結果を表 4.12 に示す. SC@9 と条件 7[‡] は 6 シード (1–6), ベース単体と旧チームは 3 シード (1–3) で評価した.

表 4.12: 実験 2 の最終結果（同一測定環境, 精度）

条件	MMLU-Pro	MATH-500	SuperGPQA	シード数
1: ベース単体	0.727	0.818	0.431	3
2: SC@9	0.740	0.873	0.486	6
5: 進化後チーム（実験 1 の構成）	0.685	0.793	0.420	3
7 [‡] : 再学習チーム	0.716	0.867	0.431	6

主要な検定結果（問題 ID クラスタの符号反転置換検定, $[\cdot, \cdot]$ はクラスタブートストラップ 95%信頼区間, Holm 補正後いずれも判定不変）:

- **主検定（対 SC@9, 6 シード・固有問題 4,683 件）**: 条件 7[‡] は -3.49pt $[-4.50, -2.56]$ ($p < 10^{-4}$) と**有意に劣った**. ベンチマーク別では MMLU-Pro -2.4pt $[-3.6, -1.3]$ ($p = 0.0001$), MATH-500 -0.8pt $[-2.4, +0.7]$ ($p = 0.35$, 差は検出されず), SuperGPQA -5.5pt $[-7.4, -3.7]$ ($p < 10^{-4}$) である².
- **処方の効果（対旧チーム, 3 シード・固有問題 2,584 件）**: 条件 7[‡] は旧チームに対し $+2.68\text{pt}$ $[+1.23, +4.13]$ ($p = 0.0003$, Holm 補正後有意) と**一貫して優った** (MMLU-Pro $+3.7\text{pt}$ · MATH-500 $+6.1\text{pt}$ · SuperGPQA $\pm 0.0\text{pt}$). 診断に基づく処方（リプレイ再学習・条件付き議論・匿名化・重み付き投票）の効果は測定環境の統制後も頑健である.
- **対ベース単体**: 条件 7[‡] は -0.32pt $[-1.66, +1.04]$ ($p = 0.65$) で差は検出されず, 事前定義した等価マージン $\pm 2\text{pt}$ に対する同等性判定 (90%信頼区間 $[-1.47, +0.81] \subset \pm 2\text{pt}$) により**同等性が成立した**. 実験 1 で確認された「ペルソナ SFT チームの能力毀損」(旧チームはベースに -3.00pt , $p = 0.0001$ で有意に劣る) はベース水準まで回復している. ベンチマーク別では MATH-500 のみ $+3.4\text{pt}$ $[+0.8, +6.0]$ ($p = 0.010$) と有意に上回る.

²参考: (シード, 問題) プールの McNemar 正確検定では -2.98pt (勝ち 223 問, 負け 402 問, $p < 10^{-6}$). 点推定の差はクラスタ解析が各問題を等重み平均するのに対しプールが各観測を等重み平均することによる.

なお「MATH-500でSC@9と同等」という表現については、差は検出されなかったものの90%信頼区間 $[-2.13, +0.45]$ の下限が等価マージン -2pt をわずかに超えるため、**同等性は未確定**である（差がないとも 2pt 以上劣るとも断定できない）。

計算量の観点では、条件7[‡]は1問あたり6生成とSC@9の9生成より少ないが、議論の第2ラウンドは他エージェントの発話全文を入力に含むため入力トークン数は生成回数に比例しない。実トークン数の集計は§4.6.6に示す。本比較は「生成回数がより少ない相手に負けた」ことを示すが、厳密な compute-matched 比較（総トークン・GPU時間の一致）ではない点に注意されたい。実験2の到達点は「処方によりチームをベース単体と同等（数学では有意に優位）まで回復させたが、生成回数マッチの Self-Consistency には及ばない」である。

4.6.6 追加分析: sharing の事後検証・カテゴリ別効果・計算量の実測

査読的観点からの再検証として、以下の3つの追加分析を行った。

(a) **fitness sharing の事後検証** — **本実験の構成では選抜に作用しなかった** §3.3 の fitness sharing は、役割内サブ集団が $K = 2$ の場合、行動距離の対称性 ($d(a, b) = d(b, a)$) により2個体の sharing 係数が常に同値となり、 $\arg \max_c \phi_c s(c) = \arg \max_c \phi_c$, すなわち**役割内選抜に一切影響しない**。進化ログの全記録（6世代 $\times$ 3役割 = 18ケース）を検証した結果、係数は全ケースで役割内同値であり、raw 適応度（Shapley 値）による順位と sharing 適用後の順位は完全に一致していた。さらに18ケース中16ケースでは行動距離が niche 半径 $\sigma_{\text{share}} = 0.3$ を超えており、係数自体が1.0（割引の不発動）であった。したがって**本実験で実際に働いた選択圧は Shapley 値のみ**であり、「fitness sharing により多様性を維持した」という設計意図は $K = 2$ の構成では機能していない。この設計上の欠陥は本研究の重要な反省点であり、sharing を有効に作用させるには $K \geq 3$ のサブ集団が必要である（Shapley 値は負になり得るため、その場合は非負化など sharing との整合にも別途注意を要する）。

(b) **MMLU-Pro のカテゴリ別分析** — 「**検証可能性**」仮説はベンチマーク内では**再現しない**。実験1で観察された議論効果の反転（MATH-500・SuperGPQA で正、MMLU-Pro で負）を「検証可能な領域では議論が有効」と解釈できるかを検証するため、MMLU-Pro の14分野を定量系（math, physics, chemistry, engineering,

computer science: 検算可能性が高い) と知識系 (law, history, philosophy 等) に事後的に分け、問題 ID クラスタ解析で素の議論 (条件 3) のベース比の効果を分野別に測定した。結果は仮説の予測と**一致しなかった**: 定量系 -3.4pt ($p = 0.11$)・知識系 -4.7pt ($p = 0.002$) でグループ間差は非有意 ($p = 0.61$) であり、特に MMLU-Pro の math カテゴリでは議論により -9.3pt ($p = 0.04$) と**悪化**した (MATH-500 では $+4.2\text{pt}$ の改善であるにもかかわらず)。すなわち、実験 1 で観察された反転は問題内容の「検証可能性」よりも**ベンチマーク単位の特性** (出題形式・難易度分布・選択肢の有無などの複合) に結びついており、本論文の「検証可能性による統一的説明」は**ベンチマーク間の観察に基づく仮説の域を出ない**。この分析はカテゴリ分けを事後に定義した探索的なものであるが、仮説の適用限界を示す証拠として報告する。

(c) 計算量の実測 — 「生成回数マッチ」の実態 「生成回数を揃えた比較は compute-matched と言えるのか」という疑問に答えるため、LLM 呼び出しの完全記録 (入力メッセージ全文と生成全文) から、新環境の全呼び出しについて Qwen3-4B の実トークナイズで入出力トークン数を集計した (表 4.13)。議論の第 2 ラウンドは他エージェントの発話全文を入力に含むため、条件 7[‡] の入力は SC@9 の約 5 倍に達する。一方、自己回帰生成の計算コストを支配する**出力トークンは SC@9 が約 2.8 倍多く**、入出力合計でも SC@9 (18,419 トークン/問) が条件 7[‡] (15,804 トークン/問) を上回った。したがって本比較は厳密な compute-matched ではないものの、**チーム側が計算量の点で優遇されていた比較ではなく**、SC@9 は総トークンでもチームを上回る強いベースラインであった。本論文では両条件の関係を「生成回数を揃えた比較 (チーム 6 生成 < SC@9 の 9 生成)」と表現し、トークン実測値を上記のとおり併記する。

表 4.13: 計算量の実測 (新環境・1 問あたり平均トークン数)

条件	呼び出し数	入力トークン	出力トークン	合計
7 [‡] : 再学習チーム (議論 2 ラウンド)	6.0	9,925	5,879	15,804
2: SC@9	9.0	1,955	16,464	18,419

条件 7[‡] は 6 シード 6,000 問 (36,000 呼び出し) の平均。SC@9 は条件 2 のみを含むジョブ

(recheck・robust, 計 3,500 問・31,500 呼び出し、ベンチマーク構成比は本評価と同一) の平均。

第5章 考察

5.1 実験結果の解釈: 議論の効果は2軸のトレードオフで決まる

実験1の最も重要な発見は、マルチエージェント議論の効果が単一の符号を持たず、ベンチマークによって系統的に反転することである。素の議論は MATH-500 で +4.2pt・SuperGPQA で +3.1pt と有意に有効だが、MMLU-Pro では -4.1pt と有意に有害だった（いずれも問題 ID クラスタ解析; §4.4）。逆に LoRA ペルソナチームは MMLU-Pro でのみ有効だった。この対照は、議論チームの性能を (i) **多様性の利得**（異なる推論経路が正解を発見する確率の向上）と (ii) **個体能力の毀損**（ペルソナ注入が支払うコスト）という2軸のトレードオフとして整理すると一貫して説明できる。

MMLU-Pro のような知識推論では、温度サンプリングだけでは推論経路の多様性が乏しく（実験1で素の議論はベース単体より悪化）、重みに焼き込まれたペルソナが供給する視点の多様性が利得をもたらす。一方でペルソナ SFT の能力毀損は比較的軽微であり、差し引きで正となる。MATH-500 や SuperGPQA のような長い導出を要する領域では、多様性は温度サンプリングでも十分に確保できる（素の議論や SC@9 が強い）一方、SFT による能力毀損が致命的となり、差し引きが負に転じる。

この整理は先行研究間の見かけ上の矛盾（「議論は多数決に劣る」とする報告と「議論が小型モデルで有効」とする報告の併存）を説明しうる。特に MATH-500 における素の議論の有意な効果は、「議論単体は信念のマルチンゲールを誘導し期待正解率を改善しない」という近年の定理的整理 [29] が少なくとも MATH-500 というベンチマークでは成り立たないことを示す反例である。この反転の機構として本論文は「検証可能な問題では他者の解の正誤を自己検算でき、信念更新が訂正方向へ偏る」という**検証可能性仮説**を提示し、MATH-500 の集約損失がほぼゼロである観察（表 4.11）はこれと整合する。ただし §4.6.6 のカテゴリ別分析が示す

とおり、この仮説は MMLU-Pro 内部の定量系カテゴリでは再現しなかった (math カテゴリではむしろ -9.3pt の悪化)。したがって本研究のデータから直接支持されるのは「効果がベンチマーク単位で反転する」ことまでであり、反転を規定する要因が問題内容の検証可能性なのか、出題形式 (選択肢の有無)・難易度分布・出力長などベンチマーク構成の複合なのかの分離は今後の課題である。

5.2 損失分解が導いた処方とその効果

実験 1 の診断 (§4.6.2) はチームの誤差を個体能力損失と集約損失に分解し、それぞれに対応する処方を実験 2 で検証した。

能力毀損の機構と修復. ペルソナ SFT がベースモデルの思考連鎖を半分以下 (中央値 $2,423$ 字 $\rightarrow 1,188$ 字) に圧縮していたという生成ログの観察は、毀損の主因が「短い応答スタイルの刷り込みによる長い導出能力の選択的破壊」であることを示す。これは SFT データとモデル分布のギャップが忘却を生むという近年の知見と整合する。処方としてベースモデル自身が生成した検証済みの長い思考連鎖 (平均 $6,503$ 字) を約 38% 混合して再学習したところ、solo 精度は 3 ベンチマークすべてで基準を満たし、一部はベース単体を上回った (G1)。再学習チームは旧チームを同一測定環境で MMLU-Pro $+3.7\text{pt}$ ・MATH-500 $+6.1\text{pt}$ 上回った。ただし本研究はペルソナ間の行動多様性の直接測定 (回答不一致率の推移など) を最終評価では実施していないため、「多様性を保ったまま能力を回復した」とまでは主張できない——ここで言えるのはチームとしての性能が回復したことである。なお再学習は、リプレイデータの追加と同時に rank ($32 \rightarrow 16$)・学習率・エポック数・系列長 ($1,024 \rightarrow 8,192$) も変更しており、回復のどこまでがリプレイ自体の寄与かは分離できていない (交絡; §5.5)。

集約損失と検証型集約. SuperGPQA では 3 体のうち少なくとも 1 体が正解している問題が 51.7% あるにもかかわらず、多数決+議論は 38.7% しか回収していなかった。logprob に基づく重み付き投票は $+0.7\text{pt}$ の改善に留まり、比較選択型の裁定 (GenSelect 型) は上積みを示さなかった (G2)。集約損失の大部分は依然として未回収であり、「正解が少数派である問題」の回収は 4B 級では未解決の課題として残る。なお実験 2 で solo 能力が修復された結果、議論後に票が割れる問題自体が減少したため、集約改善の寄与余地が実験 1 の見積もりより縮小した点には注意が必要である。

条件付き更新と匿名化.「自己の推論に具体的な誤りを特定できた場合のみ回答変更を許す」条件付き更新はパイロットで +1.0pt (非有意) と小さいが悪化のない効果を示し、発言の匿名化と併せて採用した. これらは追従 (sycophancy) による正解の破壊——実験 1 では 500 問中 26 問で正しい多数派が議論後に崩壊していた——への対処であり、議論の信念更新を訂正方向へ偏らせる介入として位置づけられる.

5.3 進化的最適化の再解釈: 選抜ではなく修復

本研究の当初の中心仮説は「チームレベル適応度 (厳密 Shapley 値) による選択圧が協調的な個体を選抜する」であった. 実験 1 の結果はこの仮説を支持しない. 進化の寄与は MATH-500 の +4.3pt (有意) のみで、選抜対象とした MMLU-Pro ではゼロだった. さらに機構分析 (§4.6.2) は当初の想定より根本的な問題を明らかにした. 進化前後の LoRA の ΔW は Frobenius ノルム比 1.000 に加え **cosine 類似度 0.9997–1.0000 でほぼ同一**であり、突然変異 1 回あたり $\cos = 0.9997$, 交叉 1 回あたり $\cos = 0.9998$ しか重みを動かしていなかった. すなわち本実験の進化は**重み空間の探索としてほとんど機能しておらず**, 6 世代を通じて初期個体の極近傍に閉じていた. 初稿では「ノルム保存の下での方向回転が損傷成分を打ち消した (修復機構)」と解釈したが, cosine 解析によりこの解釈は**棄却**される——方向は回転していなかった. MATH-500 の +4.3pt は, 固定された極小の重み摂動に対する生成過程の敏感な応答 (評価環境の違いだけで +6pt 級の系統差が生じるという §4.6.4 の観察と同種の感度) として説明するのが最も保守的であり, 重み空間における意味のある「修復」があったとは言えない.

この帰結を選抜ノイズ・sharing 無効の検証と合わせると, 本実験の進化ループは三重の機能不全を抱えていたことになる. (i) **探索の不全**: 進化演算子の実効摂動が極小で, 候補間に意味のある差が生成されていなかった. (ii) **多様性圧の不全**: fitness sharing は $K = 2$ 構成で選抜中立だった (§4.6.6). (iii) **選抜の不全**: 適応度 100 問の標準誤差 $\pm 4.9\text{pt}$ の下での毎世代最大値選抜は 1~2pt 差の真の優劣を判別できず (必要問題数の試算は 1 判断あたり約 2,600 問), 開発セット上の見かけの改善 (+12pt) は勝者の呪いとして説明される. 重要なのは, これらがいずれも**実装・設計パラメータの不備**であって, チームレベル適応度という枠組み自体の反証ではないことである. 本研究が実証的に示せたのは「本実装は枠組みの有効性を

検証できる状態になかった」までであり、枠組みの検証には変異幅の拡大・ $K \geq 3$ のサブ集団・識別力の高い適応度セット（IRT 型の問題厳選や逐次半減法）を備えた再実験、および solo 適応度・ランダム選抜との対照（アブレーション A1）が必要である。一方、能力回復という目的に対しては実験 2 のリプレイ再学習が確実に機能した（再学習チームは進化後チームをクラスタ解析で +2.7pt 上回る）ため、本研究では処方 of 検証を優先した。

5.4 Self-Consistency との比較の最終形

生成回数を揃えた Self-Consistency (SC@9) は本研究を通じて最強のベースラインであり続け、測定環境を統一した最終評価では、診断に基づく処方を尽くした再学習チームですら -3.5pt [-4.5, -2.6] (問題 ID クラスタ解析, $p < 10^{-4}$) と有意に及ばなかった。「評価設計を厳密にすると MAD の優位は消える」という批判 [7] を、(i) 生成回数を揃えた比較（トークン実測では SC@9 の方が総トークンで多く、チーム側が計算量で優遇された比較ではない; §4.6.6）、(ii) 問題 ID クラスタリングを考慮した対応あり検定と多重比較補正、(iii) 能力毀損の回復と集約改善という対策の実施、(iv) 測定環境の統制、のすべてを満たした上で確認した結果であり、本研究で最も統制の効いた知見である。

敗因の構造は明快である。SC@9 の強さは「同一分布からの独立な 9 サンプルの多数決」がもたらす分散削減にあり、ベース単体 (1 サンプル) に対して +2.8pt ($p < 10^{-4}$) を安定して稼ぐ。一方チーム議論は 6 生成をペルソナ 3 体 × 2 ラウンドに配分するため、独立サンプル数では 3 にすぎず、議論による情報交換がその差を埋める必要がある。実験 2 の集約改善後もこのギャップは埋まらなかった。例外は MATH-500 であり、チームと SC@9 の差は検出されず (-0.8pt, $p = 0.35$ 。ただし 90% 信頼区間 [-2.13, +0.45] の下限が等価マージン -2pt をわずかに超えるため同等性は未確定)、ベース単体には +3.4pt ($p = 0.010$) と有意に優る。MATH-500 では議論の 1 ラウンドが誤答の訂正として機能し、少ないサンプル数をほぼ補償したことを示す。

なお実験 2 の途中経過 (測定環境の統制前) では「チームが SC@9 を MMLU-Pro で +5.5pt 上回る」という結果が一時得られたが、これは評価イメージ間の系統差 (§4.6.4) の産物であった。系統差はベースモデルの素の生成に選択的に現れ LoRA 適用時にはほぼ現れないため、ベース系条件だけが過小評価され、チーム側が見

かけ上優位になるという質の悪いバイアスを生む。マルチエージェント議論の評価においてベースライン測定の環境同一性がいかに重要かを示す事例である。

5.5 本研究の限界

- **規模の限界:** 3 エージェント・単一モデル系列 (Qwen3-4B)・3 ベンチマークでの結果であり、より大きなモデルや異種モデル混成チームへの一般化は未検証である。特に「能力毀損」はベースモデルの事後学習の質に依存するため、モデル系列が変われば定量関係は変わりうる。
- **実験 1 と実験 2 の数値の非互換:** 評価イメージ間の系統差 (§4.6.4) により、実験 1 (旧環境) と実験 2 (新環境) の絶対値は直接比較できない。実験 1 の内部比較 (領域依存性・損失分解) と実験 2 の内部比較 (処方の効果・対 SC@9) はそれぞれ同一環境内の対応あり比較として有効だが、例えば「実験 1 の素の議論と実験 2 の再学習チーム」のような環境跨ぎの比較は本論文では行っていない。
- **シード数の非対称:** 最終評価は SC@9 と再学習チームが 6 シード、ベース単体と旧チームが 3 シードであり、後者を含む検定は検出力がやや低い。
- **進化ループの機能不全:** 実験 1 の進化は、(i) 進化演算子の実効摂動が極小 (ΔW の cosine 類似度 0.9997 以上)、(ii) fitness sharing が $K = 2$ で選抜中立、(iii) 適応度測定の標準誤差 $\pm 4.9\text{pt}$ に対し候補間差が小さい、という三重の機能不全を抱えていた (§5.3)。したがって本研究は「チームレベル適応度による進化」の有効性を支持も反証もできていない。変異幅の拡大・ $K \geq 3$ ・識別力厳選と逐次半減法を備えた再実験 (設計は研究設計書 v3 §3.4 として保存)、および solo 適応度・ランダム選抜との対照 (A1) が必要である。
- **進化ループの生成条件:** 進化ループは最大 512 トークン・top-p 0.9 の旧生成設定で実行されており、最終評価 (8,192 トークン・top-p 0.8) と生成条件が異なる。ループ内部の比較は全個体で条件が揃っているため公正だが、進化時と評価時の挙動差は残る。
- **未実施のアブレーション:** solo 適応度進化 (A1) 等は計算資源の制約から未実施であり、チームレベル適応度の寄与の直接分離は今後の課題である。A2

(sharing 無効化) は $K = 2$ 構成では自明に無差となるため、そもそも本構成では検証不能であった。

- **リプレイ再学習の交絡:** 実験 2 の再学習はリプレイデータの追加と同時に rank・学習率・エポック数・系列長も変更しており、能力回復のどこまでがリプレイ自体の寄与かは分離できない。「思考連鎖の圧縮が能力毀損の原因」という機構の説明も、圧縮と精度低下の相関および圧縮解消と精度回復の同時観察に基づく仮説であり、因果の単離実験（リプレイのみを変えた対照）は行っていない。
- **検証可能性仮説の適用限界:** 議論効果の反転を「問題の検証可能性」で説明する解釈は、ベンチマーク間の観察とは整合するが MMLU-Pro 内部のカテゴリ別分析では再現しなかった (§4.6.6)。本研究のデータが直接支持するのは「ベンチマーク依存の反転」までである。
- **評価領域:** 全ベンチマークが英語の選択式・短答式であり、生成型タスクや日本語タスクへの外的妥当性は限定的である。

第6章 結論

6.1 まとめ

本研究は、4B 級小型言語モデルに LoRA でペルソナを焼き込んだ3体のエージェント集団を構成し、議論によるチーム推論とその進化的最適化を、計算量を揃えた Self-Consistency という厳しい基準に対して検証した。得られた知見は以下の4点に要約される。

第一に、議論の効果はベンチマーク依存であり、「多様性の利得」と「ペルソナ注入による能力毀損」の2軸のトレードオフとして整理できる。素の議論は数学 (MATH-500, +4.2pt) と高難度科学 (SuperGPQA, +3.1pt) で有意に有効だが知識推論 (MMLU-Pro, -4.1pt) で有意に有害であり、重みペルソナチームはその逆の符号を示した。この反転は「議論は多数決に勝てない」とする近年の理論的整理と「小型モデルでも議論が効く」とする報告の併存を説明しうる。ただし反転を「問題の検証可能性」に帰する解釈は仮説にとどまる——MMLU-Pro 内部のカテゴリ別分析 (§4.6.6) では定量系カテゴリでも議論は有効化せず、反転の規定要因がベンチマーク構成 (形式・難易度・選択肢の有無) の複合である可能性を排除できない。

第二に、チーム誤差は個体能力損失と集約損失に分解でき、それぞれに実効的な処方が存在する。ペルソナ SFT は短い応答スタイルの刷り込みによって思考連鎖を半減させ長い導出能力を選択的に破壊していたが、ベースモデル自身が生成した検証済み長 CoT のリプレイ混合 (約 38%) を含む再学習によりベース水準 (等価マージン $\pm 2\text{pt}$ の同等性が成立) まで回復し、一部はベース単体を上回った (ただし再学習では rank・学習率等も同時に変更しており、リプレイ単独の寄与は分離できていない)。集約損失 (正解を持つ個体の答えをチームが採用できない損失, 最大 13pt) に対しては、logprob 重み付き投票・条件付き更新・発言匿名化が小幅の改善を与えたが、大部分は未回収の課題として残る。

第三に、チームレベル適応度による進化的最適化は、本実験の実装では機能す

る状態になかった。進化前後の ΔW はノルム比 1.000 かつ cosine 類似度 0.9997–1.0000 でほぼ同一であり、進化演算子は重み空間をほとんど動かしていなかった（探索の不全）。fitness sharing は $K = 2$ 構成で選抜中立であり（多様性圧の不全）、適応度測定の標準誤差（100 問で $\pm 4.9\text{pt}$ ）に起因する勝者の呪いが選抜を無情報化していた（選抜の不全）。開発セットでの見かけの改善（+12pt）は最終評価に汎化せず、MATH-500 で観測された +4.3pt も極小の重み摂動に対する生成過程の感度として説明するのが最も保守的である。したがって本研究は枠組み自体の有効性を支持も反証もしておらず、能力回復という目的にはリプレイ再学習が確実な処方であった。

第四に、診断に基づく処方（リプレイ再学習 $\times$ 条件付き議論 $\times$ 匿名化 $\times$ 重み付き投票）を実測ゲート方式で積み上げた最終チームは、測定環境を統一した最終評価において旧チームに +2.7pt（問題 ID クラスタ解析, $p = 0.0003$ ）と有意に優り、ペルソナ SFT が生んだ能力毀損をベース単体との同等性（等価マージン $\pm 2\text{pt}$ ）が成立する水準（MATH-500 では +3.4pt 有意優位）まで回復させた。しかし生成回数を揃えた SC@9 には -3.5pt ($p < 10^{-4}$) と有意に及ばず、「対策を尽くしても 4B 級のチーム議論は同等の生成予算の多数サンプリングに勝てない」という統制された負の結果が本研究の主結論である。付随して、評価コンテナイメージ間の系統差（同一設定で +6pt 級、ベース素生成に選択的に作用しチーム側を見かけ上優位にするバイアス）を検出・統制した過程は、小型 LLM 評価の再現性に対する方法論的警鐘である。

6.2 今後の課題

- **サンプリングと議論のハイブリッド**: 本研究のチームは 1 問あたり 6 生成と SC@9 より少ない計算量で比較したが、各エージェントがまず Self-Consistency@3 で自己集約してから議論する構成（3 体 $\times$ 3 サンプル = 9 生成）は SC@9 と計算量が完全に一致し、独立サンプルの分散削減と議論の誤り訂正を同時に得られる可能性がある。本研究の実測（チーム化ゲインと集約損失の分解値）に基づけば、これが 4B 級で SC@9 に到達しうる残された最有力の設計である。
- **集約損失の本格的な回収**: oracle 上限との差は依然大きい。検証器の学習（RLVR による集約器訓練）や、正解が少数派の問題を対象とした再帰的自

己集約の導入が有望である。

- **選抜として機能する進化の再検証:** 識別力の高い問題の厳選（IRT ベースの縮約評価）と逐次半減法により選抜ノイズを抑えた上で，チームレベル適応度が誤り相関の低い個体を選抜できるかを検証すること．本研究で保存した設計（研究設計書 v3 §3.4）が出発点となる．
- **エージェント数と役割設計の拡張:** $n > 3$ への拡張（Shapley 値の近似計算），および「性格」ではなく「推論戦略」（順方向導出・逆方向検証・具体例代入）としてのペルソナ設計の検証．
- **ペルソナ注入方式の比較:** 重み SFT・プロンプト・activation steering の 3 方式を能力毀損と多様性利得の 2 軸上で直接比較し，領域に応じた注入方式の選択則を確立すること．
- **異種モデル混成と大規模化:** 異なるベースモデルの混成チームや，より大きなモデル規模での 2 軸トレードオフの定量関係の検証．

謝辞

本研究が順調に展開できたのは、指導教員の余俊助教から提供いただいた実験環境と貴重な指導、また、研究室全員からはいろいろな貴重なご意見をいただいた。心から感謝します。

参考文献

- [1] Junyou Li et al. More agents is all you need. arXiv:2402.05120, 2024.
- [2] Huan-ang Gao et al. A survey of self-evolving agents: What, when, how, and where to evolve on the path to artificial super intelligence. *Transactions on Machine Learning Research*, 2026. arXiv:2507.21046.
- [3] Jinyuan Fang et al. A comprehensive survey of self-evolving AI agents: A new paradigm bridging foundation models and lifelong agentic systems. arXiv:2508.07407, 2025.
- [4] Edward J. Hu et al. LoRA: Low-rank adaptation of large language models. arXiv:2106.09685 (ICLR 2022), 2021.
- [5] Yilun Du, Shuang Li, Antonio Torralba, Joshua B. Tenenbaum, and Igor Mordatch. Improving factuality and reasoning in language models through multiagent debate. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2305.14325.
- [6] Tian Liang et al. Encouraging divergent thinking in large language models through multi-agent debate. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2024. arXiv:2305.19118.
- [7] Andries Smit, Paul Duckworth, Nathan Grinsztajn, Thomas D. Barrett, and Arnu Pretorius. Should we be going MAD? A look at multi-agent debate strategies for LLMs. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2311.17371.
- [8] Xuezhi Wang et al. Self-consistency improves chain of thought reasoning in language models. In *Proceedings of the 11th International Conference on Learning Representations (ICLR)*, 2023. arXiv:2203.11171.
- [9] Andrea Wynn, Harsh Satija, and Gillian Hadfield. Talk isn’t always cheap: Understanding failure modes in multi-agent debate. arXiv:2509.05396, 2025. ICML 2025 MAS Workshop.
- [10] Blaž Bertalaníč and Carolina Fortuna. The cost of consensus: Isolated self-correction prevails over unguided homogeneous multi-agent debate. arXiv:2605.00914, 2026.
- [11] Hangfan Zhang, Zhiyao Cui, Jianhao Chen, Xinrun Wang, Qiaosheng Zhang, Zhen Wang, Dinghao Wu, and Shuyue Hu. Stop overvaluing multi-agent debate — we must rethink evaluation and embrace model heterogeneity. arXiv:2502.08788, 2025. 初版タイトル: If Multi-Agent Debate Is the Answer, What Is the Question?
- [12] Chanwoo Park, Seungju Han, Xingzhi Guo, Asuman Ozdaglar, Kaiqing Zhang, and Joo-Kyung Kim. MAPoRL: Multi-agent post-co-training for collaborative large language models with reinforcement learning. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL)*, 2025. arXiv:2502.18439.

- [13] Yiqun Zhang, Peng Ye, Xiaocui Yang, Shi Feng, Shufei Zhang, Lei Bai, Wanli Ouyang, and Shuyue Hu. Nature-inspired population-based evolution of large language models. arXiv:2503.01155, 2025. GENOME/GENOME+ の提案論文.
- [14] Roger Creus Castanyer, Geoffrey Bradway, Lorenz Wolf, Maxwell Lin, Augustine N. Mavor-Parker, and Matthew James Sargent. PopuLoRA: Co-evolving LLM populations for reasoning self-play. arXiv:2605.16727, 2026.
- [15] Anders Krogh and Jesper Vedelsby. Neural network ensembles, cross validation, and active learning. In *Advances in Neural Information Processing Systems 7 (NeurIPS)*, 1995.
- [16] Jean-Baptiste Mouret and Jeff Clune. Illuminating search spaces by mapping elites. arXiv:1504.04909, 2015.
- [17] Danny Wood, Tingting Mu, Andrew Webb, Henry Reeve, Mikel Luján, and Gavin Brown. A unified theory of diversity in ensemble learning. *Journal of Machine Learning Research*, 24, 2023. arXiv:2301.03962.
- [18] Qwen Team. Qwen3 technical report. arXiv:2505.09388, 2025. Qwen3-4B-Instruct-2507 モデルカード (Hugging Face) .
- [19] Mitchell A. Potter and Kenneth A. De Jong. A cooperative coevolutionary approach to function optimization. In *Parallel Problem Solving from Nature (PPSN III)*. Springer, 1994.
- [20] Lloyd S. Shapley. A value for n -person games. In *Contributions to the Theory of Games II*. Princeton University Press, 1953.
- [21] Amirata Ghorbani and James Zou. Data Shapley: Equitable valuation of data for machine learning. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019. arXiv:1904.02868.
- [22] Benedek Rozemberczki et al. The Shapley value in machine learning. In *Proceedings of the 31st International Joint Conference on Artificial Intelligence (IJCAI), Survey Track*, 2022.
- [23] David E. Goldberg and Jon Richardson. Genetic algorithms with sharing for multimodal function optimization. In *Proceedings of the 2nd International Conference on Genetic Algorithms (ICGA)*, 1987.
- [24] George Stoica, Pratik Ramesh, Boglarka Ecsedi, Leshem Choshen, and Judy Hoffman. Model merging with SVD to tie the Knots. In *Proceedings of the 13th International Conference on Learning Representations (ICLR)*, 2025. arXiv:2410.19735 (KnOTS).
- [25] Vighnesh Subramaniam et al. Multiagent finetuning: Self improvement with diverse reasoning chains. In *Proceedings of the 13th International Conference on Learning Representations (ICLR)*, 2025. arXiv:2501.05707.
- [26] Ankur Samanta et al. Self-improvement of language models by post-training on multi-agent debate. arXiv:2509.15172, 2025. MACA (Multi-Agent Consensus Alignment) の提案論文.
- [27] Junlin Wang, Jue Wang, Ben Athiwaratkun, Ce Zhang, and James Zou. Mixture-of-agents enhances large language model capabilities. In *Proceedings of the 13th International Conference on Learning Representations (ICLR)*, 2025. arXiv:2406.04692.

- [28] Wenzhe Li, Yong Lin, Mengzhou Xia, and Chi Jin. Rethinking mixture-of-agents: Is mixing different large language models beneficial? [arXiv:2502.00674](#), 2025. Self-MoA の提案論文.
- [29] Hyeong Kyu Choi, Xiaojin Zhu, and Sharon Li. Debate or vote: Which yields better decisions in multi-agent large language models? In *Advances in Neural Information Processing Systems 38 (NeurIPS)*, 2025. [arXiv:2508.17536](#), NeurIPS 2025 Spotlight.
- [30] Lars Benedikt Kaesberg, Jonas Becker, Jan Philip Wahle, Terry Ruas, and Bela Gipp. Voting or consensus? Decision-Making in multi-agent debate. In *Findings of the Association for Computational Linguistics: ACL 2025*, 2025. [arXiv:2502.19130](#).
- [31] Xiaochen Zhu, Caiqi Zhang, Yizhou Chi, Tom Stafford, Nigel Collier, and Andreas Vlachos. Demystifying multi-agent debate: The role of confidence and diversity. [arXiv:2601.19921](#), 2026.
- [32] Mitchell Wortsman et al. Model soups: Averaging weights of multiple fine-tuned models improves accuracy without increasing inference time. In *Proceedings of the 39th International Conference on Machine Learning (ICML)*, 2022. [arXiv:2203.05482](#).
- [33] Gabriel Ilharco et al. Editing models with task arithmetic. In *Proceedings of the 11th International Conference on Learning Representations (ICLR)*, 2023. [arXiv:2212.04089](#).
- [34] Prateek Yadav et al. TIES-Merging: Resolving interference when merging models. In *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. [arXiv:2306.01708](#).
- [35] Le Yu et al. Language models are super mario: Absorbing abilities from homologous models as a free lunch. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. [arXiv:2311.03099](#) (DARE).
- [36] Akshara Prabhakar, Yuanzhi Li, Karthik Narasimhan, Sham Kakade, Eran Malach, and Samy Jelassi. LoRA soups: Merging LoRAs for practical skill composition tasks. In *Proceedings of the 31st International Conference on Computational Linguistics (COLING), Industry Track*, 2025. [arXiv:2410.13025](#).
- [37] Enneng Yang, Li Shen, Guibing Guo, Xingwei Wang, Xiaochun Cao, Jie Zhang, and Dacheng Tao. Model merging in LLMs, MLLMs, and beyond: Methods, theories, applications, and opportunities. *ACM Computing Surveys*, 2026. [arXiv:2408.07666](#), DOI: 10.1145/3787849.
- [38] Takuya Akiba, Makoto Shing, Yujin Tang, Qi Sun, and David Ha. Evolutionary optimization of model merging recipes. *Nature Machine Intelligence*, 2025. [arXiv:2403.13187](#).
- [39] Chengsong Huang et al. LoraHub: Efficient cross-task generalization via dynamic LoRA composition. In *Proceedings of the 1st Conference on Language Modeling (COLM)*, 2024. [arXiv:2307.13269](#).
- [40] Shangbin Feng et al. Model swarms: Collaborative search to adapt LLM experts via swarm intelligence. In *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, 2025. [arXiv:2410.11163](#).
- [41] Dongxin Guo, Jikun Wu, and Siu Ming Yiu. EvoPref: Multi-objective evolutionary optimization discovers diverse LLM alignments beyond gradient descent. [arXiv:2605.09777](#), 2026.

- [42] Adrian Robert Minut, Tommaso Mencattini, Andrea Santilli, Donato Crisostomi, and Emanuele Rodolà. Mergenetic: A simple evolutionary model merging library. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL), System Demonstrations*, 2025. arXiv:2505.11427.
- [43] David H. Wolpert and Kagan Tumer. An introduction to collective intelligence. arXiv:cs/9908014, 1999.
- [44] Jakob Foerster et al. Counterfactual multi-agent policy gradients. In *Proceedings of the 32nd AAAI Conference on Artificial Intelligence*, 2018. arXiv:1705.08926 (COMA).
- [45] Max Jaderberg et al. Population based training of neural networks. arXiv:1711.09846, 2017.
- [46] Joel Lehman and Kenneth O. Stanley. Abandoning objectives: Evolution through the search for novelty alone. *Evolutionary Computation*, 19(2), 2011.
- [47] Kalyanmoy Deb, Amrit Pratap, Sameer Agarwal, and T. Meyarivan. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6(2), 2002.
- [48] Felipe Maia Polo et al. tinyBenchmarks: Evaluating LLMs with fewer examples. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*, 2024. arXiv:2402.14992.
- [49] Evan Miller. Adding error bars to evals: A statistical approach to language model evaluations. arXiv:2411.00640, 2024.
- [50] Rotem Dror, Gili Baumer, Segev Shlomov, and Roi Reichart. The hitchhiker’s guide to testing statistical significance in natural language processing. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL)*, 2018.
- [51] Yuntong Hu, Yuting Zhang, Matthew Trager, Yi Zhang, Shuo Yang, Wei Xia, and Stefano Soatto. EvoMAS: Evolutionary generation of multi-agent systems. arXiv:2602.06511, 2026. ICML 2026 採録.
- [52] Zhezheng Hao et al. Evolve as a team: Collaborative self-evolution for LLM-based multi-agent systems. arXiv:2605.29790, 2026.
- [53] Qian Zhang, Yan Zheng, Jinyi Liu, Hebin Liang, and Lanjun Wang. Key decision-makers in multi-agent debates: Who holds the power? arXiv:2511.11040, 2025. MADC • Truth Last 戦略の提案論文.
- [54] Nathan Halko, Per-Gunnar Martinsson, and Joel A. Tropp. Finding structure with randomness: Probabilistic algorithms for constructing approximate matrix decompositions. *SIAM Review*, 53(2), 2011. arXiv:0909.4061.
- [55] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems 36 (NeurIPS)*, 2023. arXiv:2305.14314.
- [56] Woosuk Kwon et al. Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th ACM Symposium on Operating Systems Principles (SOSP)*, 2023. arXiv:2309.06180 (vLLM).

- [57] Yubo Wang et al. MMLU-Pro: A more robust and challenging multi-task language understanding benchmark. In *Advances in Neural Information Processing Systems 37 (NeurIPS), Datasets and Benchmarks Track*, 2024. arXiv:2406.01574.
- [58] Hunter Lightman et al. Let’s verify step by step. arXiv:2305.20050 (ICLR 2024), 2023. MATH-500 はこの評価分割に由来.
- [59] Dan Hendrycks et al. Measuring mathematical problem solving with the MATH dataset. In *Advances in Neural Information Processing Systems 34 (NeurIPS), Datasets and Benchmarks Track*, 2021. arXiv:2103.03874.
- [60] M-A-P Team, Xinrun Du, et al. SuperGPQA: Scaling LLM evaluation across 285 graduate disciplines. arXiv:2502.14739, 2025.
- [61] Karl Cobbe et al. Training verifiers to solve math word problems. arXiv:2110.14168, 2021. GSM8K の提案論文.
- [62] David Rein et al. GPQA: A graduate-level google-proof Q&A benchmark. arXiv:2311.12022 (COLM 2024), 2023.
- [63] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 1979.